

车云协同液罐车防侧翻 行驶规划与控制研究

(申请清华大学工学硕士学位论文)

培 养 单 位： 车辆与运载学院

学 科： 机械工程

研 究 生： 戚 笑 景

指 导 教 师： 罗 禹 贡 研究员

副指导教师： 高 博 麟 副研究员

二〇二六年四月

Vehicle Cloud Collaborative Anti-rollover Planning and Control for Tank Trucks

Thesis submitted to

Tsinghua University

in partial fulfillment of the requirement

for the degree of

Master of Science

in

Mechanical Engineering

by

Qi Xiaojing

Thesis Supervisor: Professor Luo Yugong

Associate Supervisor: Professor Gao Bolin

April, 2026

学位论文指导小组、公开评阅人和答辩委员会名单

指导小组名单

李 XX	教授	清华大学
王 XX	副教授	清华大学
张 XX	助理教授	清华大学

公开评阅人名单

刘 XX	教授	清华大学
陈 XX	副教授	XXXX 大学
杨 XX	研究员	中国 XXXX 科学院 XXXXXXXX 研究所

答辩委员会名单

主席	赵 XX	教授	清华大学
委员	刘 XX	教授	清华大学
	杨 XX	研究员	中国 XXXX 科学院 XXXXXXXX 研究所
	黄 XX	教授	XXXX 大学
	周 XX	副教授	XXXX 大学
秘书	吴 XX	助理研究员	清华大学

关于学位论文使用授权的说明

本人完全了解清华大学有关保留、使用学位论文的规定，即：

清华大学拥有在著作权法规定范围内学位论文的使用权，其中包括：（1）已获学位的研究生必须按学校规定提交学位论文，学校可以采用影印、缩印或其他复制手段保存研究生上交的学位论文；（2）为教学和科研目的，学校可以将公开的学位论文作为资料在图书馆、资料室等场所供校内师生阅读，或在校园网上供校内师生浏览部分内容；（3）按照上级教育主管部门督导、抽查等要求，报送相应的学位论文。

本人保证遵守上述规定。

作者签名： _____

导师签名： _____

日 期： _____

日 期： _____

摘 要

面向高等级公路典型运行环境下危险品液罐车侧翻风险高、诱因耦合复杂与处置窗口短等挑战,本论文以“云端预测性规避风险、车端实时稳定保障”为目标,研究车云协同条件下液罐车防侧翻行驶规划与控制方法,构建从体系架构推导到算法设计与多源验证的完整技术链路。

围绕车云协同信息物理融合系统的开放演进与多主体独立运行特征,提出适配车云协同场景的 So-MBSoSE 分场景体系建模流程,形成“战略—运行—服务—资源”四阶段架构推导与闭环验证方法,并完成面向液罐车防侧翻的 CT2ROP 场景任务体系架构设计与指标可满足性验证。在云端侧,利用“广域感知+并行算力”优势,构建交通图特征表示并提出自回归图扩散交互式预测模型 Graphflow,实现周车长时域、非确定性行为预测;在此基础上训练强化学习决策器输出速度/换道的预测性决策,并设计换道平滑轨迹生成方法以提升建议可执行性与侧翻风险可控性。在车端侧,面向高频闭环控制对实时性与安全约束可保证性的需求,建立考虑液体晃动影响的应急轨迹规划模型,将避障与防侧翻等安全约束融入约束迭代 LQR 求解,形成可实时求解的短时域应急轨迹生成方法。

在稳定性干预与控制层面,提出横纵向耦合液体晃动的滑动伸缩天平快速建模方法,在力/力矩输出层面逼近高保真流体仿真结果,满足超实时推演需求;进一步构建“基础解析模型+可学习残差”的重线性化框架,通过残差强化学习补偿线性化误差并实现工况自适应。基于车液耦合动力学,设计多约束模型预测控制策略,将轨迹跟踪、执行器约束、舒适性约束与侧翻风险指标(等效 LTR 约束)统一纳入最优化,并引入无模型自适应滑模残差补偿与差动制动以提升鲁棒性与稳定裕度。

为验证方法有效性与工程实时性,搭建 MATLAB/Simulink 桥接的 Star-CCM+ 与 TruckSim 联合仿真平台,并构建云控缩比液罐车模型试验平台开展实证检验。结果表明:在短距双移线等极限工况下,所提策略能够显著抑制侧倾与液体剧烈晃动,侧倾角峰值相对基线策略最大降低约 42%;在线优化平均求解时间约 13.2 ms,峰值小于 20 ms,满足工程实时性要求。综上,本论文为车云协同液罐车安全行驶提供了可追溯的体系架构依据与可验证的防侧翻规划控制方案。

关键词: 车云协同; 液罐车; 防侧翻; 图扩散预测; 模型预测控制

Abstract

Hazardous-material tanker trucks exhibit high rollover risk on highways due to coupled inducing factors and short reaction windows. This thesis develops a vehicle–cloud collaborative planning and control framework with the objective of *cloud-side predictive risk avoidance* and *vehicle-side real-time stability assurance*, and establishes an end-to-end pipeline from architecture derivation to algorithm design and multi-source validation.

To address the open and evolutionary nature of intelligent vehicle–cloud–road cyber-physical systems with multiple independent agents, a scenario-oriented So-MBSOSE modeling workflow is proposed, enabling closed-loop derivation and verification across four layers (strategy–operation–service–resource). An anti-rollover mission architecture for tanker trucks is then constructed and its key performance constraints are verified for satisfiability. On the cloud side, leveraging wide-area perception and parallel computing, a traffic-graph representation is built and an autoregressive graph-diffusion interactive prediction model Graphflow is proposed to produce long-horizon stochastic predictions of surrounding vehicles. Based on this world model, a reinforcement-learning decision policy is trained to provide predictive speed and lane-change decisions, and a smooth lane-change trajectory generator is designed to improve executability while limiting rollover risk. On the vehicle side, an emergency trajectory planning model that accounts for liquid sloshing is formulated, where obstacle-avoidance and anti-rollover constraints are embedded into a constrained iterative LQR solver to enable real-time short-horizon emergency trajectories.

For stability intervention and control, a fast longitudinal–lateral coupled liquid-sloshing model based on a sliding telescopic lever is developed, which approximates high-fidelity fluid simulations in the force/moment output space and achieves ultra-real-time prediction. A re-linearization scheme with a learnable residual (trained via residual reinforcement learning) is further introduced to compensate linearization errors and adapt to operating conditions. A constrained model predictive control strategy is then designed to jointly handle trajectory tracking, actuator constraints, comfort constraints, and rollover-risk constraints (e.g., equivalent LTR), with robustness and stability margins enhanced via model-free adaptive sliding-mode residual compensation and differential braking.

Co-simulation (MATLAB/Simulink bridged with Star-CCM+ and TruckSim) and

scaled model experiments demonstrate that, in extreme short-distance double-lane-change maneuvers, the proposed strategy suppresses roll and violent sloshing effectively, reducing peak roll angle by up to 42 % compared with baseline methods, while meeting real-time computation requirements (13.2 ms on average and <20 ms at peak). Overall, this thesis provides a verifiable and deployable solution for vehicle–cloud collaborative anti-rollover driving of hazardous-material tankers.

Keywords: vehicle–cloud collaboration; tanker truck; anti-rollover; graph diffusion prediction; model predictive control

目 录

摘 要.....	I
Abstract.....	II
目 录.....	IV
插图清单.....	V
附表清单.....	VI
符号和缩略语说明.....	VII
第 1 章 引言	1
1.1 研究背景及意义	1
1.2 国内外研究现状	3
1.2.1 车液耦合机理与液罐车动力学建模研究现状.....	3
1.2.2 液罐车防侧翻主被动安全措施研究现状.....	8
1.2.3 车云协同预测性决策与规划研究现状.....	12
1.2.4 车云协同体系架构构建方法研究现状.....	15
1.3 本文研究内容	17
1.3.1 本文研究对象.....	17
1.3.2 研究现状总结及存在的问题.....	17
1.3.3 总体研究方案.....	18
第 2 章 总结与展望	20
2.1 全文总结	20
2.2 主要创新点	21
2.3 研究展望	21
参考文献.....	22
附录 A 补充内容	32
致 谢.....	75
声 明.....	76
个人简历、在学期间完成的相关学术成果.....	77
指导教师评语.....	79
答辩委员会决议书.....	80

插图清单

图 1.1	液罐车事故及其严重后果	1
图 1.2	车路云一体化系统架构 ^[15]	2
图 1.3	车液耦合机理说明 ^[19,24-26]	4
图 1.4	液体晃动建模方法	5
图 1.5	液体晃动机械等效模型发展	6
图 1.6	液罐车防侧翻被动安全措施	8
图 1.7	现有车辆防侧翻控制方法	11
图 1.8	预测决策一体化思想及其向云端的拓展	13
图 1.9	研究对象示意图	17
图 1.10	本文研究框架.....	19

附表清单

符号和缩略语说明

A2C	优势演员-评论家 (Advantage Actor-Critic)
A3C	异步优势演员-评论家 (Asynchronous Advantage Actor-Critic)
ABM	基于智能体的建模 (Agent-based Modeling)
ADP	近似动态规划 (Approximated Dynamic Programming)
ARC-IT	协同式智能交通系统参考架构
ART	防侧翻轨迹跟踪 (Anti-Rollover Tracking)
ARS	增强随机搜索 (Augmented Random Search)
ASTGNN	注意力式时空图神经网络 (Attention-based Spatio-Temporal GNN)
A*	A 星全局路径搜索算法 (A-star Search)
BEV	鸟瞰图 (Bird's-Eye View)
Bi-RRT	双向快速拓展随机树 (Bidirectional RRT)
CBF	控制屏障函数 (Control Barrier Function)
CFD	计算流体动力学 (Computational Fluid Dynamics)
CFDL	紧格式动态线性化 (Compact Form Dynamic Linearization)
CFM	计算流体力学 (Computational Fluid Mechanics)
CICV	国家智能网联汽车创新中心
CILQR	约束迭代线性二次调节 (Constrained iLQR)
CKDS	运动-动力学耦合半挂车模型 (Coupled Kino-Dynamic Semi-trailer Model)
CLIP	PPO 剪切机制/剪切代理目标 (Clipped surrogate objective)
CN	控制器嵌套 (Controller Nesting)
CNN	卷积神经网络 (Convolutional Neural Network)
CPCC	云控预测性巡航控制 (Cloud-based Predictive Cruise Control)
CPS	信息物理系统 (Cyber-Physical System)
CPSoS	信息物理体系 (Cyber-Physical System of Systems)
CT2ROP	车云协同液罐车防侧翻
CVRIA	美国网联汽车参考应用架构
DC	扩散卷积 (Diffusion Convolution)
DCRNN	扩散卷积循环神经网络 (Diffusion Convolutional Recurrent Neural Network)

DB	差动制动 (Differential Braking)
DDIM	去噪扩散隐式模型 (Denoising Diffusion Implicit Model)
DDPM	去噪扩散概率模型 (Denoising Diffusion Probabilistic Model)
DLC	双移线 (Double Lane Change)
DL	深度学习 (Deep Learning)
DOF	自由度 (Degree of Freedom)
DQN	深度 Q 网络 (Deep Q-Network)
DMTP	双质量椭圆规摆 (Double Mass Trammel Pendulum)
DSF	动态稳定因数 (Dynamic Stability Factor)
EBM	基于事件的建模 (Event-based Modeling)
FFDL	全格式动态线性化 (Full Form Dynamic Linearization)
FFN	前馈神经网络 (Feedforward Neural Network)
FCN	全卷积网络 (Fully Convolutional Network)
FM	流匹配 (Flow Matching)
FPN	特征金字塔网络 (Feature Pyramid Network)
FVM	有限体积法 (Finite Volume Method)
GAN	生成对抗网络 (Generative Adversarial Network)
GAE	广义优势估计 (Generalized Advantage Estimation)
GAP	全局注意力池化 (Global Attention Pooling)
GAT	图注意力网络 (Graph Attention Network)
GATv2	改进图注意力网络 (Graph Attention Network v2)
GCN	图卷积网络 (Graph Convolutional Network)
GGA	全局图注意力层 (Global Graph Attention)
GMAN	图多头注意力网络 (Graph Multi-Attention Network)
GNN	图神经网络 (Graph Neural Network)
GNSS	全球卫星导航系统 (Global Navigation Satellite System)
GPM	广义摆模型 (Generalized Pendulum Model)
GraphFlow	本文提出的图扩散交互式预测模型/世界模型
GPU	图形处理器 (Graphics Processing Unit)
GT	图 Transformer (Graph Transformer)
HAN	异质图注意力网络 (Heterogeneous Attention Network)
HER	事后经验回放 (Hindsight Experience Replay)
H_∞	H_∞ 鲁棒控制
HIL	硬件在环 (Hardware-in-the-loop)
HW	车头距离 (Headway)

ICV	智能网联汽车 (Intelligent and Connected Vehicles)
ICV-7S	智能网联汽车 7S 架构框架
IDM	智能驾驶员模型 (Intelligent Driver Model)
IMU	惯性测量单元 (Inertial Measurement Unit)
IPOPT	非线性优化求解器 IPOPT (Interior Point OPTimizer)
iLQR	迭代线性二次型调节器 (Iterative Linear Quadratic Regulator)
ITS	智能交通系统 (Intelligent Transportation Systems)
IVCPS	智能汽车信息物理系统 (Intelligent Vehicle CPS)
KF	卡尔曼滤波 (Kalman Filter)
LDP	线性化双摆模型 (Linearized Dual Pendulum)
LiDAR	激光雷达 (Light Detection and Ranging)
LLM	大语言模型 (Large Language Model)
LQR	线性二次型调节器 (Linear Quadratic Regulator)
LTR	侧向载荷转移率 (Lateral-load Transfer Ratio)
LTR_{eq}	等效侧向载荷转移率 (Equivalent Lateral-load Transfer Ratio)
MBSoS	基于模型的体系工程 (Model-Based SoS Engineering)
MCMC	马尔科夫链蒙特卡罗 (Markov Chain Monte Carlo)
MDP	马尔可夫决策过程 (Markov Decision Process)
MEI	修正紧急因子 (Improved Emergency Index)
MFAC	无模型自适应控制 (Model-Free Adaptive Control)
MFASMC	无模型自适应滑模控制
MIMO	多输入多输出 (Multiple-Input Multiple-Output)
MOBIL	最小化由换道引起的总制动 (Minimize the Overall Braking Induced by Lane changes)
MLP	多层感知器 (Multilayer Perceptron)
MPC	模型预测控制 (Model Predictive Control)
MPN	消息传递网络 (Message Passing Network)
MPV	多用途车辆 (Multi-Purpose Vehicle)
MSE	均方误差 (Mean Squared Error)
NAT	邻域注意力网络 (Neighborhood Attention Network)
NAF	北约架构框架 (NATO Architecture Framework)
PACC	基于云的预测性自适应巡航控制 (Cloud-based Predictive Adaptive Cruise Control)
PATH	加州高速公路先进技术计划 (PATH)
PE	位置编码 (Position Embedding)

PF	偏格式 (Partial Form)
PFDL	偏格式动态线性化 (Partial Form Dynamic Linearization)
PID	比例-积分-微分控制 (Proportional-Integral-Derivative)
POMDP	部分可观测马尔可夫决策过程 (Partially Observable MDP)
PPO	近端策略优化 (Proximal Policy Optimization)
QP	二次规划 (Quadratic Programming)
QS	准静态模型法 (Quasi-Static Model)
RFLP	需求-功能-逻辑-物理 (Requirement-Functional-Logical-Physical)
RGB	红绿蓝三通道颜色空间 (Red-Green-Blue)
RL	强化学习 (Reinforcement Learning)
RNN	循环神经网络 (Recurrent Neural Network)
ROS	机器人操作系统 (Robot Operating System)
RSU	路侧单元 (Road Side Unit)
RTK	实时动态载波相位差分定位 (Real-Time Kinematic)
RTX	NVIDIA RTX 系列 GPU (RTX-series GPU)
RRT	快速拓展随机树 (Rapidly-exploring Random Tree)
RTTC	二维碰撞时间 (Reciprocal Time-to-Collision)
SAC	软演员-评论家 (Soft Actor-Critic)
SD Wrapper	稳域包裹 (Stable Domain Wrapper)
SE	结构编码 (Structural Embedding)
SGD	随机梯度下降 (Stochastic Gradient Descent)
SISO	单输入单输出 (Single-Input Single-Output)
SLC	单移线 (Single Lane Change)
SMC	滑模控制 (Sliding Mode Control)
So-MBSOSE	分场景基于模型与仿真的体系工程
SoS	体系 (System-of-Systems)
SQP	序列二次规划 (Sequential Quadratic Programming)
SSCL	调度采样课程学习 (Scheduled Sampling Curriculum Learning)
SSF	静态稳定因数 (Static Stability Factor)
SSI	替代安全指标 (Surrogate Safety Index)
STGCN	时空图卷积网络 (Spatio-Temporal Graph Convolutional Network)
STL	滑动伸缩天平模型 (Sliding Telescopic Libra)
STTN	时空 Transformer 网络 (Spatio-Temporal Transformer Network)
SUMO	交通仿真软件 SUMO (Simulation of Urban MObility)
SUV	运动型多用途车 (Sport Utility Vehicle)

SysML	系统建模语言 (Systems Modeling Language)
TCN	时序卷积网络 (Temporal Convolutional Network)
TD3	双延迟深度确定性策略梯度
THW	T_{hw} 车头时距 (Time-Headway)
TPSP	组合双摆 (Combined Single and Trammel Pendulum)
TP	椭圆规摆 (Trammel Pendulum)
TraCI	SUMO 软件交通模拟接口 (Traffic Control Interface)
TRPO	信赖域策略优化 (Trust Region Policy Optimization)
TTC	碰撞时间 (Time-to-Collision)
TQC	截断分位数评论家 (Truncated Quantile Critics)
TreeSearch	本文实现的树搜索决策基线方法
UAF	统一架构框架 (Unified Architecture Framework)
UAFML	统一架构框架建模语言 (UAF Modeling Language)
UKF	无迹卡尔曼滤波 (Unscented Kalman Filter)
V2X	车联网 (Vehicle-to-everything)
VLA	视觉语言动作模型 (Visual-Language Action Model)
VLM	视觉语言模型 (Visual-Language Model)
ZOH	零阶保持 (Zero Order Hold)
A, B, C, D	状态空间模型矩阵
$\mathcal{A}$	邻接矩阵
b_k^x	第 k 步状态约束对应的控制屏障函数 (CBF)
$\mathcal{E}$	图边集合
$f_k^x(\cdot)$	第 k 步状态约束函数 (用于构造 CBF)
$f(\mathbf{x}, u)$	车辆闭环系统状态方程 ($\dot{\mathbf{x}} = f(\mathbf{x}, u)$)
J	优化目标/代价函数
$\mathcal{L}_{lim}$	近似 LTR 的 CBF 约束上限
$\mathcal{L}_{lim}^0$	CBF 约束初始上限
$L_{\max}$	时间编码中的预设常数
$L^{\text{CLIP}}(\theta)$	PPO 剪切代理目标函数
N_c	控制时域个数
N_p	预测时域长度
N_r	约束时域个数
p_k	第 k 步状态权重向量
p_{N_p}	终端状态权重向量
$p_t(x)$	时间 t 的样本分布

Q	代价函数权重矩阵
Q_k	第 k 步状态权重矩阵
Q_{N_p}	终端状态权重矩阵
$Q_{\theta}(s, a)$	动作价值函数
Q_i	用于描述摆模型的广义力
R	代价函数权重矩阵
R_k	第 k 步输入权重矩阵
$\mathcal{U}$	控制输出空间 ($\mathcal{U} \subseteq \mathbb{R}^m$)
$\mathcal{U}_{\text{con}}$	控制输出约束集 ($\mathcal{U}_{\text{con}} \subseteq \mathcal{U}$)
$\mathcal{V}$	图节点集合
$V_{\theta}(s)$	状态价值函数
$V(\mathbf{x})$	李雅普诺夫函数 ($V : \mathcal{X}_2 \rightarrow \mathbb{R}_{\geq 0}$)
$\dot{V}(\mathbf{x})$	李雅普诺夫函数的导数
$\mathcal{G}$	图结构场景/路网
C_1	基础控制器 ($C_1 : \mathcal{X} \rightarrow \mathcal{U}$)
C_2	嵌套控制器 ($C_2 : \mathcal{X} \rightarrow \mathcal{U}$)
C_{CN}	嵌套控制器集合 ($C_{\text{CN}} = \{C_1, C_2\}$)
C_{human}	人类驾驶员控制器
$\mathcal{X}$	系统状态空间 ($\mathcal{X} \subseteq \mathbb{R}^n$)
$\mathcal{X}_1$	标称可行且稳定的核心状态空间区域
$\mathcal{X}_2$	实际可行且稳定的扩展状态空间区域 ($\mathcal{X}_2 = \mathcal{X}_1 \cup \mathcal{M}_1 \cup \mathcal{M}_2$)
$\mathcal{X}_3$	控制器输出线性组合的过渡状态空间区域 ($\mathcal{X}_3 = \mathcal{X} \setminus (\mathcal{X}_1 \cup \mathcal{M}_2)$)
$\partial \mathcal{X}_2$	状态空间区域 $\mathcal{X}_2$ 的边界函数 ($\partial \mathcal{X}_2 : g(\mathbf{x}) = 0$)
$\mathcal{M}_1$	模型误差补偿余量
$\mathcal{M}_2$	稳定性保障余量
$\hat{A}_t$	优势函数估计
a	牵引车前轮轴到质心的距离
a_{deccel}	车辆减速度
a_{dev}	STL 模型中浴盆曲面偏置的自衰减系数
a_{ij}	节点 $i \rightarrow j$ 的连接关系/权重
a_p	STL 模型中滑动平面曲线长半轴
a_t	罐体截面长轴半轴 (椭圆率计算用)
a_{veh}	车辆加速度 (单位 m/s^2)
b	牵引车后轮轴到质心的距离
b_{dev}	STL 模型中浴盆曲面偏置的输入换算系数

b_p	STL 模型中滑动平面曲线短半轴
b_t	罐体截面短轴半轴（椭圆率计算用）
c	牵引车牵引销铰接点到质心的距离
c_i	悬架侧倾阻尼（ $i = 1, 2$ 分别代表牵引车、挂车）
c_{M1}	牵引车制动力矩-减速度转换系数
c_{M2}	挂车制动力矩-减速度转换系数
c_{brk}	制动压力-减速度转换系数
c_{con}	边连接类型（顺次/向左/向右/路口等，one-hot 编码）
c_{edge}	道路类型（高速主路、匝道）
c_{ego}	自车占用水平/自车存在性（取值范围 $[0, 1]$ ， $c_{ego} \geq 0.95$ 表示自车占据该节点）
c_{free}	自由边标记（路段起点/终点/中间等）
c_{int}	车辆意图特征（直行/汇出/汇入等的概率或 one-hot 编码）
c_{lane}	车道位置类型（车道中线/左侧/右侧，道路左边界/右边界，路口连接）
c_{nav}	节点是否位于导航路线内（0/1）
c_{occ}	车辆占用水平（不包含自车，取值范围 $[0, 1]$ ）
c_{risk}	风险场特征（融合静态占据风险与动态速度风险，归一化至 $[0, 1]$ ，表征局部风险水平）
c_{veh}	车辆类型特征（one-hot 编码）
c_{damp}	STL 模型中小球晃动的阻尼系数
c_x	STL 模型中浴盆 X 向移动阻尼系数
c_v	PPO 价值函数损失系数
c_e	PPO 熵正则系数
$c_v^+(i)$	节点 i 的正归一化相对速度风险分量（自车与周边车辆的正向相对速度映射值）
$c_v^-(i)$	节点 i 的负归一化相对速度风险分量（自车与周边车辆的逆向相对速度映射值）
d	挂车后轮轴到质心的距离
d_{con}	边对应的节点间距离（归一化）
d_{ego}	自车特征维度（本文为 53）
d_{lat}	道路横向离散分辨率（m）
d_{lon}	道路纵向离散分辨率（m）
d_e	边特征维度
d_v	节点特征总维度

d_v^{stat}	静态节点特征维度
d_v^{dyn}	动态节点特征维度
d_{veh}	周车特征维度（本文为 25）
e	挂车牵引销铰接点到质心的距离
e_t	时间编码向量
g	重力加速度（ 9.806 m/s^2 ）
h	STL 模型中浴盆曲面底部净高
h_i	质心到侧倾中心的距离（ $i = 1, 2$ 分别代表牵引车、挂车）
h_{ic}	牵引销到侧倾轴线的高度（ $i = 1, 2$ 分别代表牵引车、挂车）
h_{veh}	车辆航向角
I_{1xz}	簧载质量交叉耦合方向转动惯量
I_{ixx}	簧载质量侧倾方向转动惯量（ $i = 1, 2$ 分别代表牵引车、挂车）
I_{izz}	簧载质量横摆方向转动惯量（ $i = 1, 2$ 分别代表牵引车、挂车）
k	离散时间步索引
$k_{a,dec}$	STL 模型中浴盆 X 向移动加速度换算系数
$k_{ax,pow}$	STL 模型中 X 向加速度衰减系数
k_α	STL 模型中浴盆曲面范数阶数
k_{lane}	车道序号（最右侧道路中心为 0，向左依次增加）
k_σ	STL 模型中浴盆曲面方形系数
$k_{v,dec}$	STL 模型中 X 向速度衰减系数
k_x	STL 模型中浴盆曲面 X 轴范围
k_y	STL 模型中浴盆曲面 Y 轴范围
k_z	STL 模型中浴盆曲面 Z 轴范围
k_1	牵引车等效前轴侧向刚度
k_2	牵引车等效后轴侧向刚度
k_3	挂车后轴侧向刚度
k_{12}	牵引销连接部位的侧倾刚度
k_{ri}	悬架侧倾刚度（ $i = 1, 2$ 分别代表牵引车、挂车）
m	STL 模型中晃动部分质量
m_i	车辆总质量（ $i = 1, 2$ 分别代表牵引车、挂车）
m_{si}	簧载质量（ $i = 1, 2$ 分别代表牵引车、挂车）
M_{1z}^+	牵引车左侧附加横摆力矩
M_{1z}^-	牵引车右侧附加横摆力矩
M_{2z}^+	挂车左侧附加横摆力矩
M_{2z}^-	挂车右侧附加横摆力矩

M_x, M_y, M_z	液体晃动侧倾力矩、俯仰力矩、横摆力矩
n_e	边数量
n_v	节点数量
n_{veh}	周车数量（或周车节点数）
n_x, n_u, n_y	状态量/控制量/输出量个数
p_{brk}^{L1}	牵引车左侧制动压力
p_{brk}^{R1}	牵引车右侧制动压力
p_{brk}^{L2}	挂车左侧制动压力
p_{brk}^{R2}	挂车右侧制动压力
p_r	STL 模型中滑动平面曲线幂次
p_x	道路像素节点的二维位置坐标 x 分量
p_y	道路像素节点的二维位置坐标 y 分量
q_k	第 k 步状态权重标量
q_{N_p}	终端状态权重标量
r_k	第 k 步输入权重向量
r_t	强化学习回报
$r_t(\theta)$	PPO 中动作概率比
s_{dev}	STL 模型中浴盆曲面静态偏置距离
s_t	强化学习状态
t	连续时间变量（流匹配/扩散时间 $t \in [0, 1]$ ）
T	时域长度/预测步数
T_s	离散化时间步长/采样周期
T_{wi}	车辆轮距（ $i = 1, 2$ 分别代表牵引车、挂车）
bs	网格基础尺寸（base size of mesh）
rf	网格细化等级（refinement level）
vClass	SUMO 车辆类别字段（vehicle class）
vtype	SUMO 车辆类型字段（vehicle type）
v_a	强化学习动作
v_{des}	期望车速
v_{des}^a	给下层控制器的期望速度指令
v_{dev}	静态偏置加速度
v_f	流体特征速度
v_{lim}	道路限速（归一化后输入网络，单位m/s）
v_{veh}	车辆速度（归一化后输入网络，单位m/s）
v_{ix}	纵向速度（ $i = 1, 2$ 分别代表牵引车、挂车）

v_{iy}	侧向速度 ($i = 1, 2$ 分别代表牵引车、挂车)
v_t^θ	模型学习的速度向量场
x_k	第 k 步状态向量 (离散时刻 k 的状态向量)
x_t	时间 t 的样本状态
X_1, Y_1	牵引车在大地坐标系下的位置坐标
$\mathbf{x}$	系统状态向量 ($\mathbf{x} \in \mathcal{X} \subseteq \mathbb{R}^n$)
$\mathbf{x}^*$	系统平衡点
u_k	第 k 步控制输入向量 (离散时刻 k 的控制输入向量)
y_k	第 k 步输出向量 (离散时刻 k 的输出向量)
F_y	液体晃动侧向力
F_{y1}	牵引车等效前轴侧向力
F_{y2}	牵引车等效后轴侧向力
F_{y3}	挂车等效后轴侧向力
$F_{y,int}$	挂车作用于牵引车的侧向力
F_z	车轮所受垂向力
F_{ego}^0	当前时刻自车特征向量
$F_{i,stat}$	节点 i 的静态特征
$F_{i,ego}^{-T+k:k}$	节点 i 自车历史到当前的占据/动态特征序列
$F_{i,vehs}^{-T+k:k}$	节点 i 周车历史到当前的动态特征序列
$F_{vehs}^{-T:0}$	过去 T 步周车动态特征张量
$\text{Re}(\cdot)$	取实部
$\Delta v_{thrl d}$	期望车速与实际车速差值阈值
Δx_k	iLQR 迭代中的状态增量/扰动
$\Omega_f(j), \Omega_b(j)$	可对目标节点 j 产生风险贡献的源节点集合 (正/反向)
Θ	模型状态向量 (用于液体晃动/车辆-液体耦合模型)
θ	神经网络参数
θ_1, θ_2	双摆模型摆角
$\dot{\theta}_1, \dot{\theta}_2$	双摆模型摆角速度
τ	软更新系数
τ_{cloud}	云端长时域预测性轨迹规划结果
τ_{decay}	CBF 约束上限衰减时间常数
τ_{SSCL}	SSCL 概率随时间衰减系数
τ_v	车速响应时间常数
ϵ	松弛因子 (软约束)
ϵ_{SSCL}	SSCL 中保留真值 (未来时刻标签) 的概率

ϵ_{clip}	PPO 裁剪阈值
ϵ_{occ}	占据存在性阈值
$\alpha(\mathbf{x})$	状态依赖的加权系数 ($\alpha : \mathcal{X} \rightarrow [0, 1]$)
α^*	控制器切换的阈值 ($\alpha^* = \inf\{\alpha(\mathbf{x}) \mathbf{x} \in \partial\mathcal{X}_3\}$)
β_1, β_2	牵引车/挂车质心侧偏角
$\dot{\beta}_i$	质心侧偏角变化率 ($i = 1, 2$ 分别代表牵引车、挂车)
β_t	目标样本与初始样本的线性插值系数
γ	折扣因子
δ	车辆前轮转角
δ_d	期望前轮转角
δ_t	时序差分 (TD) 残差
ϕ_i	侧倾角 ($i = 1, 2$ 分别代表牵引车、挂车)
$\dot{\phi}_1, \dot{\phi}_2$	牵引车/挂车侧倾角速度
ψ_i	横摆角 ($i = 1, 2$ 分别代表牵引车、挂车)
λ_f, λ_b	风险沿道路正/反向扩散的指数衰减系数
λ_{spd}	速度风险到占据风险的量纲转换系数
$c_k^x(x_k)$	第 k 步 CBF 一阶近似的标量项
$\nabla c_k^x(x_k)$	第 k 步 CBF 一阶近似的梯度向量
π_θ	策略函数
$\odot$	哈达玛积 (逐元素乘法)
$\otimes$	克罗内克积 (Kronecker product)
$\oplus$	张量拼接 (tensor concatenation)

第1章 引言

1.1 研究背景及意义

我国危化品公路运输需求持续增长，液罐车已成为危化品运输的主要载体。统计显示，2025 年我国危化品运输总额已接近 3 万亿元，其中超过 80 % 依赖液罐车公路运输^[1]；截至 2025 年，危化品运输车辆总数已超过 36 万辆，其中液罐车接近 19 万辆，占比达 52.8 %^[2]。与此同时，液罐车运输安全问题尤为突出。2011 年至 2025 年间，我国危化品罐车重大事故已超过 1 万 5 千起，其中 78.7 % 发生于液罐车行驶过程中，62.7 % 由车辆侧翻引起^[3-7]。在货车严重伤亡事故中，液罐车侧翻事故占比超过 31 %，在液罐车单方面事故中侧翻占比接近 70 %^[8]。可见，侧翻已成为液罐车运行安全中的典型风险问题。

液罐车侧翻事故往往伴随严重次生灾害，造成重大人员伤亡和财产损失。如图 1.1 所示，2020 年浙江温岭 G15 高速液化石油气罐车侧翻爆炸事故造成 20 人死亡、175 人受伤，并导致大量房屋倒塌和损毁^[9]。近年来，四川江油、山东威海、广西百色、北京东六环、湖南邵阳等地亦相继发生液罐车因超速、避让、急转向等诱发的侧翻事故。由于液罐车所运载介质多为液化石油气、液化天然气、汽柴油、甲醇等易燃易爆危化品，相关事故常进一步引发泄漏、燃烧、爆炸及环境污染等严重后果^[1,10]。因此，如何降低液罐车运行过程中的侧翻风险，已成为危化品道路运输安全保障中的关键问题。



图 1.1 液罐车事故及其严重后果

液罐车侧翻风险的形成具有典型的多因素耦合特征，主要表现为车辆特性、单车局限与人因失误的共同作用。首先，液罐车通常需在非满载条件下运行，以避免液体膨胀和蒸汽压力升高引发泄漏或爆炸，最大允许充液量一般不得超过 95 %^[11-12]。

在中低充液率条件下，罐内液体易发生显著晃动，进而降低车辆侧倾稳定性并增大侧翻风险。其次，驾驶员或单车智能系统受限于本车视角，难以充分掌握道路结构、临时施工、周车状态及行为意图等动静态交通信息，尤其在弯坡组合路段、突发干扰场景及多车交互条件下，更难以实现对风险的提前识别与规避^[8]。再次，超速、疲劳驾驶以及紧急工况下的不当操纵等人因失误，也会进一步加剧车辆失稳并诱发侧翻事故。

上述问题使自动驾驶技术成为提升液罐车行驶安全的重要潜在途径。自动驾驶系统可避免超速、疲劳驾驶等人为违规行为，依托多传感器融合提升环境感知能力，并通过优化决策与控制算法提高车辆对动态交通环境的响应速度与操纵稳定性。近年来，商用车自动驾驶技术发展迅速，已在干线物流场景中形成初步应用基础。例如，2024年卡尔动力完成2–6车混合无人化半挂车队超820万公里无事故运输^[13]，小马智卡等企业的L4级自动驾驶卡车也正加快迈向规模化应用^[14]。这些进展表明，自动驾驶技术为降低危化品运输中的人为失误风险提供了现实可能。

然而，单车自动驾驶仍存在明显局限。一方面，其感知能力受限于本车视距，难以获取超视距及遮挡区域信息；另一方面，车端算力和实时优化能力有限，难以在复杂交通场景中持续执行高维预测与全局协同决策。对于液罐车而言，道路条件、周车行为与液体晃动之间存在强耦合关系，仅依靠单车智能仍难以充分应对复杂环境下的侧翻风险。




图 1.2 车路云一体化系统架构^[15]

在此背景下，车路云一体化系统（云控系统）为液罐车防侧翻提供了新的技术路径。如图 1.2所示，云控系统由智能网联车辆、路侧单元、云控基础设施及定

位、地图、交通管理、应急支撑等平台共同构成^[16]，本质上属于典型的信息物理系统。通过路侧与车端协同感知、云端信息融合及虚实闭环运行，云控系统能够在更大空间范围内实现交通环境理解、预测性决策与协同控制^[17]。目前，全国已有20个主要城市开展车路云一体化试点建设，表明车路云一体化已成为我国智能交通发展的重要方向^[18]。

相较于单车智能，车云协同的优势主要体现在三个方面：其一，依托路侧与云端融合感知，可为车辆提供超视距、跨路段的全局交通信息，弥补单车感知盲区；其二，利用边缘云与云平台的并行算力，可支持更长时域、更高复杂度的风险预测与决策优化；其三，借助云端统一协调能力，可突破单车局部博弈限制，为多车场景下的整体安全与效率优化提供条件。

综上，液罐车侧翻风险来源于车辆非满载车液耦合特性、单车感知与决策能力不足以及人因失误等多因素共同作用。单车自动驾驶虽可在一定程度上缓解人为失误和局部感知不足问题，但仍难以独立应对复杂交通环境下的高风险侧翻场景。车路云一体化系统凭借全局感知、强大算力与协同优化能力，为液罐车侧翻风险的提前识别、预测性规避和分层安全控制提供了新的可能。因此，研究车云协同条件下液罐车防侧翻行驶规划与控制方法，不仅对完善危化品运输车辆主动安全理论具有重要学术意义，而且对提升复杂环境下液罐车运行安全水平、减少重大事故发生具有重要工程应用价值。

1.2 国内外研究现状

围绕车云协同液罐车防侧翻问题，本文从动力学建模、防侧翻安全措施、车云协同决策规划以及体系架构构建四个方面综述相关研究。


1.2.1 车液耦合机理与液罐车动力学建模研究现状

1.2.1.1 车液耦合机理研究现状

液罐车的车-液耦合效应通常可从准静态质心迁移效应与瞬态晃动冲击效应两类机制加以理解。前者主要改变稳态侧向加速度作用下的等效质心位置和侧倾力矩，从而降低车辆静态侧翻阈值；后者则在转向、变道等非稳态激励下引入附加侧向冲击力和侧倾力矩，使车辆动态侧翻阈值进一步下降。以常见类椭圆截面罐体为例，如图1.3所示，在准静态条件下，液体自由液面随侧向加速度倾斜，液体质心在侧倾平面内发生纵向抬升和横向偏移：前者增大车-液总质量相对于侧倾中心的力矩，后者直接增大液体重力产生的侧倾力矩，因此液罐车相较于等质量固体载荷车辆通常具有更低的静态侧翻阈值^[19]。

相较于固体载荷车辆中“载荷增加导致侧翻阈值单调下降”的一般规律，液罐车在部分充液条件下通常表现出更复杂的非单调特征。现有研究普遍表明，车辆侧翻风险随充液率变化往往呈现“先降低后回升”的趋势，中等充液率常对应更不利工况，尤其在50%~70%附近更易出现显著晃动冲击。这表明，除总质量与质心高度变化外，自由液面长度、液体惯性分量及瞬态冲击效应也是决定液罐车侧倾稳定性的关键因素^[19-23]。代表性研究进一步指出，中等充液率下液体横向冲击更强、侧向力波动更显著，而在高充液率条件下，自由液面受限，晃动幅值与波动程度通常有所抑制^[20,24]。


准静态下车辆液体质心转移对车辆侧翻特性的影响



准静态下因液体质心移动影响，整车**质心纵向上升、横向偏移，静态侧翻阈值降低**

$$\frac{a_y}{g} \uparrow = \frac{T_w(\text{轮距})}{2h_g \uparrow(\text{质心高度})} + \beta(\text{路面侧倾角})$$

瞬态下液体晃动冲击对车辆侧翻特性的影响



- F_y 瞬时冲击最大值超出平均值40%~50%
- 充液率50%-70%时自由液面最大，晃动最剧烈导致侧翻阈值最小。

车液耦合特性




图 1.3 车液耦合机理说明^[19,24-26]

从影响因素看，现有研究普遍认为液体晃动强度主要受液体质心高度、自由液面长度以及外部激励特性共同影响。质心越高，液体重力引起的平均侧倾力矩

越大；自由液面越长，液体横向迁移与冲击越剧烈，系统响应中的高阶分量也越明显；而激励幅值与频率则影响主导响应模态及能量分布，从而改变晃动峰值及衰减特性^[24,27]。

因此，车-液耦合对液罐车侧向动力学的影响可概括为三个方面：一是准静态质心迁移增大等效侧倾力矩，使响应幅值上升；二是瞬态晃动冲击带来附加侧向力与侧倾力矩，使系统更易出现峰值放大和超调；三是液体系统阻尼有限，导致振荡衰减较慢、危险状态持续时间延长。上述特性共同解释了液罐车在中等充液率和强横向激励条件下更易发生侧倾失稳，也表明后续建模需要在关键模态可解释性与实时性之间进行权衡。

1.2.1.2 液体晃动建模研究现状

液体晃动建模最早主要面向飞行器燃料箱、船舶液舱和车辆油箱等场景，近年来逐步扩展到液罐车晃动与侧倾稳定性研究。现有方法大体可归纳为四类：准静态模型法、机械等效力学模型法、液体晃动动力学模型法和实验研究法^[28]，如图1.4所示。四类方法分别对应稳态规律分析、低维动态近似、高精度流动求解和模型验证等不同目标。




图 1.4 液体晃动建模方法

(1) 准静态模型法 (QS) 准静态模型基于自由液面形态、液体质心位置和静力平衡关系描述平均晃动力与侧倾力矩，形式简单、物理意义明确，适合分析充液率、截面形状等因素对稳态侧倾特性的影响^[25,32]。但该方法忽略瞬态晃动冲击和相位滞后，对变道、蛇形等非稳态工况的适用性有限。

(2) **机械等效力学模型法** 机械等效模型通过单摆、双摆、弹簧-质量-阻尼或椭圆规摆等低维结构逼近液体晃动产生的等效力和力矩^[33-37]。其优势在于计算效率高、易于嵌入规划与控制，是当前最适合在线应用的一类方法。其不足在于表达能力受等效结构限制，通常只能覆盖主导模态，对高阶晃动、水跃飞溅及横纵向耦合流动的描述仍不充分。




图 1.5 液体晃动机械等效模型发展

(3) **液体晃动动力学模型法** 液体晃动动力学模型直接基于流体动力学方程描述液体运动，典型包括线性晃动理论和 CFD 方法。该类方法能够较完整地刻画自由液面演化及强非线性流动，精度高，适合机理分析、高精度基准构建和离线标定^[19,21]。但其建模与求解代价较大，通常难以满足实时规划与控制需求。

(4) **实验研究法** 实验研究法通过实车、缩比模型或液舱台架直接观测晃动行为和车辆响应，是模型校核与控制验证的重要手段^[20,26]。但受安全性、成本和可重复性限制，尤其在危化品场景下难以大规模开展，因此更多承担验证作用，而难以替代建模本身。

总体来看，现有研究已经形成“准静态方法揭示平均规律、机械等效模型服务实时应用、流体动力学模型提供高精度基准、实验方法承担验证闭环”的基本格局。其中，机械等效模型最适合车辆规划与控制，但现有模型多集中于二维主导晃动，对横摆、俯仰以及纵向加减速诱导的横纵向流动耦合考虑不足。对于液罐车防侧翻问题，后续建模的关键不在于单纯提高复杂度，而在于在保证实时性的前提下保留对侧倾失稳最关键的液动模态。

1.2.1.3 液罐车动力学建模研究现状

在规划与控制中引入液罐车动力学约束，首先需要建立可计算的车-液耦合动力学模型。受工程实时性要求限制，现有研究通常采用“简化车辆模型 + 液体晃动模型”的建模路线，即以低自由度车辆横向/横摆模型为骨架，并与准静态模型、机械等效模型或流体动力学模型耦合，形成可用于分析、规划与控制的低阶模型^[21,26,38]。

对整体式液罐车而言，车辆部分多采用自行车模型、3DOF 平面模型或引入侧倾自由度的 4DOF 模型，以兼顾横向运动描述与侧翻风险表征^[26,38-39]。其中，3DOF 模型适合描述纵向、侧向和横摆运动，4DOF 模型则进一步增强了对侧倾响应的刻画能力；与之耦合的液体模型通常采用单摆、椭圆规摆等机械等效形式，以满足计算效率要求^[26,39]。总体上，这类模型能够较好支撑液罐车与固体载荷车辆的动力学差异分析，以及抑晃和防侧翻控制器设计^[26,39]。

对半挂液罐车而言，由于牵引车与挂车之间存在铰接耦合，系统动力学维度更高，建模时通常需要围绕研究目标进一步简化。现有研究常采用牵引车与挂车平面运动模型描述基本操纵特性，例如制动分析中常见牵引车纵向、侧向、横摆与挂车横摆组成的 4DOF 模型^[40]；在防侧翻研究中，则更多采用包含牵引车侧倾和挂车侧倾的 5DOF 模型，以增强对侧倾稳定性的表达^[41-42]。在此基础上，再与基于势流理论、单摆或椭圆规摆的液体模型耦合，可形成适用于半挂液罐车分析与控制设计的低阶车-液耦合模型^[21,29]。因此，“半挂车简化动力学模型 + 可计算液体模型”已成为半挂液罐车工程建模的主流思路^[21,41]。

除模型结构外，参数辨识也是决定模型可用性的关键环节。现有研究通常以高精度仿真或实验结果为参照，通过遗传算法、粒子群等优化方法最小化低阶模型与参考模型之间的输出误差，从而辨识液体等效参数和部分车辆参数^[26,41-43]。其中，液体部分的辨识重点在于使等效模型逼近 CFD 或实验得到的侧向力、侧倾力矩等关键输出^[26,43]；车辆部分则常需结合多工况辨识和参数插值，以适应运行状态变化^[41-42]。

总体来看，现有液罐车动力学建模已形成以低自由度车辆模型耦合可实时液体模型的基本框架：整体式液罐车多采用 3-4DOF 车辆模型，半挂液罐车多采用约 5DOF 的简化模型，并配合单摆、椭圆规摆等机械等效液体模型，在精度与实时性之间取得折中^[21,26,29,39]。但现有模型仍普遍存在横纵向耦合不足、输出模态有限，以及对复杂交通工况和强非线性液体响应适应性不足等问题，这也说明后续研究需要进一步面向预测性规划与鲁棒控制任务，提升模型对关键失稳模态的表达能力。

1.2.2 液罐车防侧翻主被动安全措施研究现状

通过液罐车自身的改进解决其侧倾稳定性差问题的思路有两大类，一类是以改进车辆自身性能的被动措施；另一类是从控制入手的主动安全措施，下面对两种思路分别介绍。

1.2.2.1 液罐车防侧翻的被动安全措施研究现状

被动防侧翻措施主要从车辆结构与罐体内部构型入手，通过减弱液体横向流动、降低质心迁移幅度或改善罐体受力状态来提升侧倾稳定性。现有研究与工程实践中的典型措施主要包括罐体截面形状优化、防浪板/防波板设计，以及通过弹性气袋等装置抑制自由液面晃动，如图 1.6所示。




图 1.6 液罐车防侧翻被动安全措施

其中，罐体形状优化主要通过改变液体质心位置及其迁移规律来改善侧倾稳定性。现有研究表明，在相同装载条件下，部分改进椭圆形或锥形截面能够降低液体质心高度，减小侧倾力矩，从而优于常规圆形或普通椭圆形截面^[27,45]；进一步结合机械等效模型和优化方法的研究也表明，合理选择椭圆率有助于减小侧向冲击力和侧倾力矩，说明截面参数优化具有明确的防侧翻潜力^[38,43,46]。

防浪板设计则是工程中更常见的被动措施，其作用机理是抑制液体大尺度横向迁移、削弱冲击载荷并改善受力分布。相关研究指出，抑制液体侧向流动可直接提升侧倾稳定性^[47]；基于 CFD 的分析进一步表明，合理布置纵向防波板能够有效改善制动和转向工况下的液体受力状态，并与现行安全规程中的设计要求相一致^[48-49]。相比之下，横向防波板由于制造复杂、成本较高且缺乏统一规范，工程应用相对较少。

除上述两类主流措施外，现有研究还探索了利用弹性气袋固定自由液面以减弱晃动^[24]、通过罐体结构改进优化受力路径^[50]，以及借助道路信息预警辅助驾驶员规避高风险路段^[51]等思路。这些方法分别从液体晃动抑制、结构安全提升和风

险提示等角度对侧翻防护进行补充。

被动安全措施已在罐体形状优化、防浪结构设计和自由液面抑制等方面形成较为系统的研究与工程基础，能够在一定程度上降低液体晃动强度并改善车辆侧倾稳定性。但这类方法主要作用于车辆和罐体本体，其效果受整车布置、制造成本、轻量化要求以及检修维护条件限制，难以持续覆盖道路几何突变、周车干扰、驾驶操作失误等外部诱因所导致的动态风险。因此，仅依赖被动措施仍难以充分应对复杂交通环境下的侧翻问题，仍需结合主动风险预测、预防性规划与控制干预，形成与被动措施互补的分层安全体系。

1.2.2.2 液罐车防侧翻主动安全措施研究现状

面向液罐车的主动防侧翻方法总体可归纳为两条互补路径：防侧翻运动规划与防侧翻控制。前者通过在决策与轨迹层提前约束侧向激励、侧倾响应及其演化过程，从源头降低车辆进入危险状态的概率，更偏向“预防”；后者则在车辆已处于高侧翻风险状态时，通过执行器施加控制作用抑制侧倾失稳，更偏向“救车”。考虑本文对象为半挂式液罐车，其防侧翻问题同时受到半挂结构、液体晃动耦合及自动驾驶执行条件的共同影响，因而有必要分别从防侧翻运动规划与防侧翻控制两方面进行综述。

(1) 防侧翻运动规划研究现状

防侧翻运动规划的核心是在轨迹生成阶段显式约束可能诱发侧翻的横向激励与姿态响应，因此首先需要合理刻画侧翻风险。现有研究常用指标大致可分为三类：一类是以 SSF、DSF 为代表的稳定性判据，适合描述车辆几何与动力学层面的稳定裕度^[52-54]；一类是以 LTR 及其变体为代表的载荷转移指标，能够较直接反映车轮接地载荷变化，是当前防侧翻规划与控制中最常用的动态风险指标^[55-57]；另一类是 TTR、ZMP 及多参数联合指标，更适用于风险预警、触发逻辑或综合安全评估^[26,58-62]。总体而言，LTR 兼具物理可解释性和动态敏感性，在防侧翻运动规划中应用最为广泛。

在此基础上，现有防侧翻规划通常是在通用轨迹规划框架中引入侧倾动力学约束或风险代价，以限制侧向加速度、横摆响应和载荷转移峰值。按方法形式划分，相关研究大体可归纳为搜索、采样、几何参数化、优化和学习五类。搜索类方法如 A*、Hybrid A*、DP 和 Lattice Planner 等^[63-66]，具有较好的可行性搜索能力，但受限于状态离散化，较难细致表达连续动力学约束和风险演化；采样类方法如 PRM、RRT 及其变体^[67-70]，适合复杂环境中的可行域探索，但结果一致性和约束稳定性相对不足；几何参数化方法基于回旋曲线、贝塞尔曲线、B 样条等直接构造

连续轨迹^[71-75]，计算效率较高，但对复杂约束和多目标权衡的表达能力有限。相比之下，优化方法能够将避障约束、轨迹平滑性与 LTR、TTR 等防侧翻指标统一纳入目标函数或约束条件，因此已成为防侧翻规划研究的主要方向^[57,65,76-78]；学习方法则多以强化学习及 Safe RL 为基础，试图在复杂交互环境中直接学习兼顾安全与效率的行为策略^[79-84]，但其性能仍高度依赖场景覆盖、奖励设计和安全约束构造。

对半挂式液罐车而言，防侧翻规划比普通车辆更为复杂。半挂结构引入牵引车-挂车铰接耦合，使规划过程除满足牵引车本体避障外，还需兼顾挂车轨迹约束、铰接角稳定性和防折叠要求^[41-42]；液体晃动进一步与横摆、侧倾和路径变化相互耦合，使规划问题由一般动力学可行性问题演化为受强安全约束主导的耦合规划问题。因此，液罐车防侧翻规划不仅要控制轨迹几何形状，还要限制由路径变化激发的侧倾风险累积。

现有半挂车规划研究为此提供了一定基础。低速场景研究多集中于自动泊车和狭小空间避障，通常基于半挂车运动学模型，将搜索、采样、优化或强化学习方法用于牵引车轨迹生成，并通过铰接角和挂车避障约束保证整体可行性^[85-87]。高速场景研究则更关注牵引车与挂车协同跟踪、高速换道与稳定性保持，常通过 LQR、ADP、优化方法或分层控制框架降低铰接角误差、挂车跟踪误差及峰值 LTR^[88-92]。但这些研究大多面向一般半挂车，重点仍在避障、泊车或高速跟踪，对液体晃动与侧翻风险的考虑相对有限。

总体来看，现有研究已经形成较丰富的防侧翻风险指标体系和通用规划方法，也为半挂车轨迹生成与协同跟踪提供了基础；但公开文献中仍缺少真正面向半挂式液罐车的防侧翻运动规划方法。具体而言，普通车辆防侧翻规划通常未显式考虑牵挂结构与液体晃动耦合，而现有半挂车规划研究又多未将液体动力学和强侧翻约束纳入统一规划框架。因此，面向自动驾驶场景构建兼顾半挂结构、液体晃动与侧翻风险约束的防侧翻运动规划方法，仍是有待突破的关键问题。

(2) 防侧翻控制研究现状

与防侧翻运动规划侧重从源头降低风险不同，防侧翻控制更强调在车辆接近危险边界或已进入危险状态时，通过执行器快速干预侧倾动态。现有车辆防侧翻控制方法主要包括主动悬架、差动制动、分布式驱动、转向控制及其组合形式^[93-94]。其中，主动悬架通过调节左右悬架支撑力直接作用于侧倾自由度，控制效果最直接，但硬件复杂度和能耗成本较高^[95]；差动制动依托左右轮制动力差产生附加横摆力矩，工程实现基础较好，但对侧倾的作用路径较为间接^[96]；分布式驱动可进一步扩大可用横摆力矩，但通常依赖特殊驱动结构，应用范围有限^[97]；转向控制

则通过改变车辆路径和横向激励主动抑制侧翻风险，在极限工况下通常具有更强的翻车避免潜力，但对执行器能力和控制设计要求更高^[98]。




图 1.7 现有车辆防侧翻控制方法

对液罐车而言，防侧翻控制仍属于相对小众的研究方向，现有工作总体上主要面向人工驾驶条件下的主动安全辅助。受车载硬件条件和工程可实施性限制，相关研究主要集中于差动制动、转向控制及其协同形式，而主动悬架和分布式驱动在液罐车领域中的研究和应用相对较少^[21,30,99]。

在建模层面，现有研究通常采用等效摆模型或势流模型描述液体晃动，并与车辆横向动力学模型耦合^[21,26,29-30]；在控制层面，则主要采用 PID 及模糊 PID、LQR、MPC、无模型自适应控制和 H_∞ 控制等方法^[56,100-103]。从研究演进看，早期工作多采用“液体机械等效模型 + 差动制动救车”的基本范式^[30-31]，随后逐步发展为将势流或等效摆液体模型与半挂车动力学耦合，并结合 MPC、LQR 等方法实现差动制动与转向控制协同^[21,26,29,104]。与此同时，高精度 CFD 仿真也开始用于液体动力学分析及控制方法验证，从而提升了液体建模和验证的可信度^[23,26]。

从控制效果看，现有研究普遍表明，差动制动工程可实施性较好，但由于其主要通过附加横摆力矩间接影响侧倾动态，控制能力存在上限^[105]；相比之下，转向控制通过直接改变车辆路径和横向激励，通常在稳定时间、超调抑制和峰值 LTR 降低等方面表现更优^[106-107]。近年来，随着自动驾驶液罐车研究的推进，部分工作开始尝试将防侧翻控制由单一临险干预扩展到路径跟踪与防侧翻协调控制，以实现“常态运行 + 临险补偿”的多模态安全控制^[99]，但切换标准及过渡手段仍需

进一步研究。

总体来看,现有液罐车防侧翻控制研究已在执行器选择、液体建模、控制方法和验证手段等方面取得一定进展,但总体上仍以紧急救车和事后抑制为主,对自动驾驶条件下更重要的预防性安全保障关注不足。现有方法普遍建立在横纵向解耦、液体模型简化和局部控制补偿基础上,对液体横纵向耦合流动、规划与控制协同以及复杂场景验证闭环的考虑仍不充分。因此,面向半挂式液罐车,有必要进一步将转向控制、差动制动等执行手段与防侧翻运动规划协同设计,形成“提前避险+临险兜底”的主动安全控制框架。

1.2.3 车云协同预测性决策与规划研究现状

云端预测性行为决策与运动规划是在单车自动驾驶决策与规划的基础上发展而来的,相对于单车方案,云端预测性的决策和规划更加考虑了云端的全局感知、并行算力与协同优化优势,对单车所触及不到的长时域规律进行解析,并给出更具指导性的建议。

1.2.3.1 单车智能行为决策及其向云端的拓展

尽管云端与车端在可用信息量、更新频率与规划颗粒度上存在差异,其决策与规划的基本范式是相通的:在不确定、多主体交互的交通环境中,生成既安全又高效且可执行的行为与轨迹。因此,较为成熟的单车智能行为决策为云端预测性决策提供了重要参考。行为决策自始至终试图解决的核心问题只有一个:如何处理自车与周围交通参与者之间的交互,如图1.8所示。

自DARPA自动驾驶挑战赛以来,感知-预测-决策-规划-控制的模块化流程被沿用多年^[108-114],但该流程隐藏了一个关键逻辑矛盾:若先对周车进行预测再据此决策,则预测结果默认与自车决策无关;而实际交通中周车行为往往会对自车动作产生反应,预测应当随自车候选决策而变化。由此,传统“先预测后决策”的串行结构在多车交互场景下容易出现保守、迟滞或不稳定等问题。为修正上述矛盾,近年来模块化路线的一个共同趋势是预测-决策一体化。

现有模块化方法大体可按交互处理方式划分为显式交互、隐式交互及综合式交互三类。显式交互以自车候选策略/意图划分场景,在每个候选行为下预测周车反应,并对不同候选行为的长期收益与风险进行比较,典型代表为多策略决策方法(Multi-Policy Decision Method, MPDM);隐式交互侧重对周车意图/不确定性构造多个可能情景,并在情景集合上评估自车应对策略,典型代表包括防御性规划(Contingency Planning)^[115]与博弈论方法;综合式交互将显式交互与隐式交互思想融合,并常与风险度量、礼貌性或协同性等机制结合。本文在附录A.1.1中对模块

化路线作进一步综述。

端到端方案则进一步通过通过学习从环境表征到行为/轨迹的可微分联合映射，在训练阶段将预测、决策与规划的耦合显式纳入优化目标，从而缓解传统“先预测后决策”带来的交互一致性问题。常见实现包括基于模仿学习的端到端轨迹生成、基于强化学习的交互策略学习，以及以扩散/生成模型为代表的多模态规划生成等。端到端方法中最早发展起来的两端式端到端融合预测-决策-规划三者，近年来涌现的一段式端到端则将感知-规划的闭环打通，其中 VLA 方案则将感知-控制全链路打通。本文在附录A.1.2中对端到端路线作进一步综述。




图 1.8 预测决策一体化思想及其向云端的拓展

对云端预测性行为决策而言，预测决策一体化的核心思想同样适用，但现有单车方案向云端长时域大空间尺度的拓展存在挑战。模块化方案的交互式决策需具备多模态周车预测能力从而据其构建自车行为树，但随云端时域与空间尺度的增加，周车行为树的规模将呈指数级增长，导致计算复杂度过高，且预测结果无法穷尽所有可能，即每次交互将忽略大量小概率时间，而这在长时域多次交互后将导致不确定性传播的严重失真；由于车云通信时延，端到端方案在云端通常采用两段式，其依赖的 BEV 感知特征或向量化感知适合描述小欧式空间内周车，在面对大时空尺度拓展时则包含大量无用非道路语义向量子空间，导致表征与计算效率低下。

综上，单车自动驾驶的行为决策普遍通过预测-决策耦合的方式高效建模自车与周车的短期交互以规避先预测后决策的逻辑谬误，云端预测决策一体化势在必行。然而，现有适用于单车的交互建模方式难以拓展到需要考虑较大时空尺度的

云端，亟需适用于云端的反映交互不确定性在长时域扩散的交互建模方法。

1.2.3.2 云控预测性决策与规划研究现状

相较于单车自动驾驶主要依赖本车局部感知、短时域预测和有限车载算力完成决策与规划，车路云一体化系统可借助路侧、边缘侧或云端的广域感知与并行计算能力，在车端实时闭环之外提供更长时域的预测性决策与规划支持，从而弥补单车在全球可观测性、预测范围和计算资源上的不足^[116]。

从功能分配方式看，现有云控预测性决策与规划研究大体可归纳为三类：车端决策辅助、车云分层控制和云端全局/集中控制^[116]。其中，车端决策辅助仍以车端为决策主体，仅利用 V2X 信息增强环境理解、行为预测和本地规划^[117-119]；该类方法实现门槛较低、易于与现有单车系统结合，但并未根本改变“决策主要在车端完成”的结构，因此对车端算力压力和全局协同能力的改善有限。云端全局/集中控制则进一步将决策重心转移至路侧、边缘侧或云端，由基础设施在交叉口、匝道或更大路网尺度统一组织多车行为^[120-125]；该类方法最能发挥广域感知和全局优化优势，但对通信可靠性、渗透率和基础设施部署条件要求较高，在现实交通环境下应用边界较强。相比之下，车云分层控制强调“云端长时域引导、车端短时域闭环”，由云端负责低频、预测性和全局性决策，车端负责高频、强安全约束下的轨迹生成与稳定控制^[126-133]。这类方法既能利用云端扩展预测时域和协同范围，又保留了车端安全闭环，因此更符合当前低渗透率、通信资源受限条件下的工程实现需求。

需要指出的是，车云协同的关键并不只是“云端是否更优”，而在于云端建议能否在通信时延、丢包和链路波动条件下被车端稳定吸收并保持安全闭环^[134-136]。因此，现有车云分层方法通常还需要结合时间触发、事件触发、局部重规划和降级执行等机制，以处理通信不确定性并维持系统鲁棒性^[127,136]。

从应用目标看，现有云控预测性决策与规划研究主要面向一般自动驾驶场景下的安全、节能和通行效率优化，典型任务包括换道辅助、速度规划、队列组织、匝道合流和路口冲突协调^[122-123,128,131-132]。这些研究为云端参与行为决策和长时域规划提供了方法基础，但其协同对象多为普通车辆，关注点也主要是交通效率、能耗或一般安全性提升。对于液罐车而言，侧翻风险不仅受道路与周车行为影响，还与液体晃动、车辆侧倾及半挂结构耦合密切相关，因此云控问题不再只是一般意义上的行为优化，而是面向强安全约束和强动力学耦合条件下的预测性风险规避问题。

目前车路云协同决策与规划已形成由“车端决策辅助—车云分层控制—云端全局/集中控制”构成的连续谱系。其中，车端决策辅助易于部署，但协同深度有

限；云端全局/集中控制优化潜力最大，但对外部条件依赖最强；车云分层控制则在协同收益与工程可行性之间取得了较好平衡，更适合作为当前阶段车云协同液罐车防侧翻问题的基本架构。尽管如此，现有研究仍主要面向普通自动驾驶任务，尚缺少针对液罐车防侧翻这一强安全约束问题的系统设计，尤其缺少对云端预测性决策、车端防侧翻运动规划与稳定控制之间协同机制的统一刻画。因此，如何在低渗透率和通信不可靠条件下明确云端与车端的功能边界、信息接口、触发机制与降级关系，进而构建可降级、可验证、可持续演进的车云协同防侧翻决策与规划框架，仍是亟待解决的关键问题。

1.2.4 车云协同体系架构构建方法研究现状

前述研究表明，液罐车防侧翻问题已在车-液耦合建模、车端防侧翻控制和车云协同预测性决策等方面形成了一定技术积累，但现有研究大多聚焦局部机理、单项算法或单一场景优化，尚缺少一种能够将需求、能力、功能、逻辑、资源与验证机制统一映射的体系架构构建方法。对于车云协同液罐车防侧翻问题，仅从规划、控制或通信等单一层面分别展开研究，难以回答云端与车端如何分工、系统边界与接口如何定义以及架构如何验证等更基础的体系问题。

在这一背景下，车路云一体化为智能车辆系统提供了新的工程组织方式，其核心在于将车辆、路侧基础设施、云端计算资源和平台服务进行系统级连接，以支撑广域感知、协同决策与闭环控制^[15,17,137-139]。在系统抽象层面，该类对象通常可归纳为智能汽车信息物理系统（Intelligent Vehicle Cyber-Physical System, IVCPS）。因此，车路云一体化更适合作为工程建设范式，而 IVCPS 则是其对应的系统形态表达；本文研究的车云协同液罐车防侧翻（Cloud-based Collaborative Tank Truck Rollover Prevention, CT2ROP）可视为 IVCPS 中一个面向安全的典型场景任务。

围绕此类复杂交通系统，国内外已形成若干代表性参考架构。例如，美国交通部发布的 CVRIA 和 ARC-IT 从企业、功能、物理、通信和服务等多个视角描述网联交通系统组成与交互关系^[140-141]；欧盟 C-Mobile 项目面向 C-ITS 系统，从上下文、功能、通信、应用和信息等视角开展架构描述，并探索了基于 SysML 的建模方法^[142-144]；国内则已形成智能汽车信息物理系统参考架构 1.0/2.0、ICV-7S 框架以及车路云一体化系统云控基础平台功能场景参考架构等成果^[145-148]。这些参考架构为车路云复杂系统提供了多视角描述框架，有助于明确系统组成、交互关系与功能边界，但其主要作用仍在于“描述系统”和“规范系统”，对于特定任务场景下如何将需求逐步落实为能力、功能、逻辑和资源配置，并形成可分析、可验证、可迭代的架构方案，支持仍然有限。

为增强复杂系统架构设计的可实施性，基于模型的系统工程（Model-Based

Systems Engineering, MBSE) 逐渐被引入智能网联汽车领域。MBSE 以模型替代传统文本作为设计载体, 强调需求、功能、逻辑与物理模型之间的一致性和可追踪性, 因此在复杂系统需求分解、功能分配和接口分析方面具有明显优势。面向 IVCPS 相关任务, 已有研究开始探索基于 MBSE 的场景架构设计, 例如围绕云控预测性巡航控制 (Cloud-based Predictive Cruise Control, CPCC) 系统的建模工作, 体现了面向具体任务开展体系建模的工程化路线^[147]。但 MBSE 仍主要面向边界相对明确的单一系统设计, 对于多场景并行、跨场景耦合和持续演进条件下的体系问题支撑有限。

对于 IVCPS 这类由车辆、基础设施、平台服务及多类场景任务共同构成的开放复杂系统, 仅依赖静态参考架构或单次 MBSE 建模仍难以覆盖其开放性、演进性和涌现性特征。从这一意义上, IVCPS 更接近信息物理体系 (Cyber-Physical System of Systems, CPSoS)。因此, 相关研究进一步从 MBSE 扩展到体系工程 (System of Systems Engineering, SoSE) 及其与仿真结合的方法, 通过波浪模型、螺旋模型以及建模与仿真闭环等方式描述复杂体系的持续演进和验证过程^[149-159]。

面向 IVCPS 这类开放演进的 CPSoS, 戚笑景等^[160]进一步提出分场景的基于模型与仿真的体系工程 (Scenario-oriented Model and Simulation Based SoS Engineering, So-MBSOSE) 方法。该方法以场景任务为基本构建单元, 通过场景迭代不断完善整体架构、识别跨场景交互, 并将建模、仿真与验证纳入统一闭环。相较于一次性、自上而下的静态架构描述, 这种方法更适合处理 IVCPS 中场景持续扩展、多主体协同以及安全闭环需反复验证的特点, 也更契合 CT2ROP 这类需要同时统筹车端、云端、通信链路与安全约束的复杂任务。

综上, 现有研究已为车路云复杂系统提供了从参考架构到模型化设计再到开放体系构建的基本方法链: 参考架构解决了多视角描述问题, MBSE 提升了任务场景设计的一致性与可追踪性, SoSE 及其与仿真结合的方法则进一步面向开放演进体系提供了构建与验证思路。然而, 针对液罐车防侧翻这一强安全约束场景, 仍缺少一种能够围绕车云协同任务特点, 将需求、能力、功能、逻辑、资源与验证机制统一起来的场景任务体系架构构建方法。特别是在低渗透率、通信受限和场景持续扩展的现实条件下, 如何基于 IVCPS 框架采用适合的 SoSE 方法构建可实现、可验证、可演进的 CT2ROP 场景任务架构, 仍是有待深入研究的关键问题。

1.3 本文研究内容

1.3.1 本文研究对象

本文以低渗透率高等级公路云控系统下的车云协同液罐车防侧翻子系统为研究对象，研究对象如图 1.9所示，主要包括接受云控预测性规划服务的自动驾驶半挂车液罐车、与其交互的人工驾驶车辆以及提供感知、计算与决策支持的云平台。

研究场景面向高等级公路典型运行环境，重点考虑液罐车侧翻风险较高的高速公路全路段及部分路口/匝道场景，包括一般路段、上/下匝道、大曲率弯道、施工区域、车道数变化等典型工况，并考虑目标液罐车与周车之间的动态交互。

本文聚焦自动驾驶半挂车液罐车，是因为半挂车液罐车在危化品运输中占比高、载重大、质心高、操纵与稳定控制更为复杂，具有更突出的防侧翻研究意义。本文假设目标车辆具备基本的环境感知、决策规划与闭环控制能力。

本文的研究目标是充分发挥云控系统广域感知与并行计算优势，将云端预测性风险规避与车端实时安全保障相结合，在兼顾通行效率与运行经济性的前提下，提高液罐车行驶过程中的侧翻稳定性并降低进入危险状态的概率。




图 1.9 研究对象示意图

1.3.2 研究现状总结及存在的问题

综上，现有研究已在车路云协同、自动驾驶决策规划、液罐车动力学建模以及防侧翻控制等方面形成一定基础，但面向车云协同条件下液罐车防侧翻这一问题，仍缺乏从体系架构到云端决策、再到车端控制的整体性研究。结合本文研究目标，

现阶段主要存在以下五方面问题。

(1) 车云协同防侧翻的体系架构尚不清晰。现有研究多面向通用协同感知、协同通行或一般自动驾驶任务,缺少针对液罐车防侧翻这一强安全约束场景的专门架构设计,尤其在云端与车端功能分配、通信失效下的降级关系以及安全闭环构建方面仍不明确。

(2) 现有云端决策方法对复杂交通交互的长时域预测支撑不足。云端虽具备全局感知与并行计算优势,但现有方法对周车交互行为不确定性的建模仍不充分,难以稳定支撑更大空间尺度和更长时域下的预测性风险规避。

(3) 现有规划方法对液罐车特性的考虑不足。现有自动驾驶规划方法大多面向普通车辆,较少同时考虑液体晃动、牵挂结构及车液耦合特性,难以满足半挂式液罐车防侧翻规划需求。

(4) 现有车端防侧翻控制对关键动态特征刻画不足。现有液罐车防侧翻控制多建立在简化模型基础上,对液体晃动与车辆横纵侧向耦合动态的系统考虑不足,限制了控制器对危险工况的适应能力和安全边界拓展能力。

(5) 模型与实验验证之间缺乏统一支撑。现有研究虽已开展一定的仿真或试验验证,但模型尺度、实验尺度以及缩比系统与实车系统之间的对应关系仍不够清晰,尚未形成完整的一致性验证闭环。

因此,有必要围绕液罐车防侧翻任务,构建兼顾通信约束、云端预测、车端规划控制与实验验证的一体化研究框架,形成“云端预防风险、车端保障安全、验证闭环支撑”的系统解决方案。

1.3.3 总体研究方案

针对上述问题,本文围绕“云端预测性规避风险、车端实时性保障安全”的总体思路,构建车云协同液罐车防侧翻行驶规划与控制总体方案。整体上,本文按照“体系架构设计—云端预测性决策规划—车端防侧翻控制—验证评估”的主线展开研究,目标是在发挥云端全局感知与计算优势的同时,保留车端快速闭环与安全兜底能力,实现液罐车侧翻风险的分层防控。

首先,从体系架构层面明确车端、云端与通信链路在防侧翻任务中的功能边界、协同关系与安全保证机制,形成面向液罐车防侧翻的车云协同总体架构。

其次,从云端决策规划层面,利用广域感知与并行计算优势开展长时域风险预判与预测性规避,为车辆提供面向防侧翻任务的先验决策引导与参考轨迹支持。

再次,从车端执行层面,面向局部实时约束与临险工况,构建具有防侧翻能力的规划控制方法,使车辆在跟踪上层参考的同时保持侧倾稳定性,并在云端建议失效或场景突变时提供安全兜底。

最后，从验证评估层面，建立面向防侧翻任务的仿真与实验验证体系，对所提出的架构、云端方法和车端方法进行系统评估，形成从理论设计到验证闭环的完整支撑。

由此，本文形成“架构层明确分工、云端层提前避险、车端层实时兜底、验证层闭环评估”的总体研究方案，为车云协同条件下液罐车防侧翻行驶规划与控制提供系统化支撑。




图 1.10 本文研究框架

第2章 总结与展望

2.1 全文总结

本文以车路云一体化系统为背景，针对液罐车侧翻事故频发、单车智能难以应对复杂交互与液体晃动耦合风险的问题，系统开展了车云协同液罐车防侧翻行驶规划与控制研究。论文首先从体系工程视角出发，构建了车云协同危化品运输场景任务架构，明确了云端长时域预测性决策与车端短时域高频控制的协同机制。在此基础上，分别突破云端非确定性交互预测与决策、车端横纵向耦合液体晃动建模与防侧翻控制、以及联合仿真与缩比模型试验验证等关键技术，形成了从体系设计到算法实现再到实证检验的完整闭环。主要工作与结论如下：

(1) 针对 IVCPS 开放演进与多场景并行的特点，提出了分场景基于模型与仿真的体系工程方法，完成了 CT2ROP 场景任务体系的战略、运行、服务、资源四阶段架构设计，通过蒙特卡洛仿真验证了关键指标（如应急响应时间 $\leq 100\text{ ms}$ ），为算法开发提供了系统边界与需求约束。

(2) 在云端决策层，构建了图扩散交互式预测模型，以道路像素级有向交通图表征交通场景，通过自回归流匹配学习周车长时域（20s）非确定性演化规律，并基于该世界模型训练强化学习决策器，实现了考虑交互不确定性的速度与换道行为决策。同时，提出了以最小化侧翻风险为目标的六阶多项式轨迹优化方法，生成了可跟踪的平滑换道轨迹。仿真结果表明，所提方法在复杂高速场景中安全性能显著优于单车方案，且通行效率与舒适性基本保持。

(3) 在车端控制层，建立了横纵向耦合液体晃动的滑动伸缩天平（STL）快速模型，首次同时捕捉了横摆力矩波动、舱室液体转移引起的稳态变化等关键模态，计算速度达亚毫秒级；针对 STL 非解析难以在线优化的问题，引入残差强化学习重线性化机制，实时补偿线性双摆模型（LDP）的参数与状态，使线性模型在预测时域内精度逼近 STL。基于此，构建了横纵向耦合半挂液罐车 8 自由度动力学模型，设计了多约束模型预测控制策略，将等效载荷转移率（ LTR_{eq1} ）作为软约束，实现了轨迹跟踪、抑晃与防侧翻的协同优化。为弥补规划与控制脱节，进一步提出了车端高频防侧翻避障应急轨迹规划方法，建立了运动-动力学耦合的半挂车简化模型与三阶 LTR 动态模型，通过约束迭代 LQR 生成双场景分叉轨迹，保障突发场景下的稳定与安全。

(4) 搭建了车液耦合联合仿真平台与 1:14 缩比例模型车实验平台，基于双重相似性准则设计了双移线等极限工况，开展了仿真与实车验证。结果表明，所提方

法能将 LTR 有效控制在软约束范围内，证明了方法的有效性与工程可行性。

2.2 主要创新点

1. 提出了面向 IVCPS 演化特征的 So-MBS_oSE 体系工程方法，构建了车云协同液罐车防侧翻场景任务架构，通过“战略—运行—服务—资源”四阶段闭环与蒙特卡洛仿真验证，为算法落地提供了系统级需求边界与演进路径。
2. 构建了图扩散交互式预测模型与强化学习决策器，实现了云端长时域（20s）非确定性交通交互预测与预测性行为决策，显著提升了复杂动态场景下的行车安全性。
3. 提出了滑动伸缩天平非线性快速建模方法及残差强化学习重线性化机制，攻克了横纵向耦合液体晃动的高精度实时预测难题；在此基础上设计了多约束 MPC 防侧翻轨迹跟踪控制器与约束迭代 LQR 应急规划器，形成了车端双模态安全保障体系，并通过缩比模型试验验证了算法的实时性与有效性。

2.3 研究展望

尽管本文取得了上述成果，但仍存在若干问题值得进一步探索：

(1) 更复杂的交互场景与周车不确定性建模。当前图扩散预测主要针对高速公路，未来需拓展至城市交叉口等复杂拓扑环境；同时可引入更丰富的驾驶风格表征与在线贝叶斯推断，提高预测精度。

(2) 车云通信与信息安全层面的深化。算法层面对通信时延、丢包的处理尚显简化，后续应开发通信异常下的决策平滑切换与轻量级加密认证机制，增强系统鲁棒性。

(3) 面向实际工程落地的软硬件集成与测试。缩比模型试验已验证算法可行性，下一步应开展真实液罐车道路试验，积累数据并迭代算法，同时探索与大语言模型、世界模型等新兴技术的融合，进一步提升决策的语义理解能力。

总之，车云协同为液罐车防侧翻提供了超越单车智能的解决路径，本文工作为这一方向奠定了理论方法与技术基础，后续研究将继续向高阶智能化与工程化迈进。

参考文献

- [1] 钱钰延,周亚洪,覃泽森,等. 危化品公路运输罐车事故特征分析及应急处理[J]. 中国矿业大学学报, 2023, 39(10): 79-85.
- [2] 中国物流与采购联合会危化品物流分会. 常压液体危险货物运输市场将迎来利好[EB/OL]. 2022[2022-08-03]. <http://whpwlh.chinawuliu.com.cn/gzdt/202208/03/583992.shtml>.
- [3] 刘惠平. 危化品罐车道路运输常见事故类型及原因浅谈[J]. 上海职业安全, 2023, 1(44): 44-45.
- [4] 程硕, 阳富强. 2011~2020 年我国危险化学品事故统计及灰色关联分析[J]. 应用化工, 2023, 52(1): 1-5.
- [5] 李健, 白晓昀, 任正中, 等. 2011~2013 年我国危险化学品事故统计分析对策研究[J]. 中国安全生产科学技术, 2014, 10(6): 142-147.
- [6] 陈晓勇, 施式亮, 任竞舟, 等. 2013~2014 年我国道路危险化学品运输事故统计分析对策[J]. 湖南科技大学学报 (自然科学版), 2017, 32(3): 91-95.
- [7] 王阳, 施式亮, 钟利达, 等. 2013 年—2017 年危化品罐式车辆公路运输事故时空分布[J]. 湖南科技大学学报 (自然科学版), 2022, 37(2): 1-5.
- [8] 公安部道路交通安全研究中心. 罐式车辆侧翻隐患及防范对策建议[EB/OL]. (2022-03-01)[2023-09-28]. <https://baijiahao.baidu.com/s?id=1730605931942550470&wfr=spider&for=pc>.
- [9] Lyu S, Zhang S H, Huang X M, et al. Investigation and modeling of the lpg tank truck accident in wenling, china[J]. Process Safety and Environmental Protection, 2022, 1(157): 493-508.
- [10] 白金花, 刘勇, 叶黎明, 等. 我国危化品道路运输事故特征分析[J]. 安全, 2023, 44(5): 61-66.
- [11] 中华人民共和国国家质量监督检验检疫总局. GB18564.1-2006 道路运输液体危险货物罐式车辆第一部分: 金属常压罐体技术要求[S]. 北京: 中国标准出版社, 2006.
- [12] 国家市场监督管理总局. TSG R0005-2011 移动式压力容器安全技术监察规程[S]. 北京: 中国标准出版社, 2011.
- [13] 卡尔动力 (KargoBot.ai). KargoBot 混合无人解决方案及物流服务[EB/OL]. 2024[2024-09-29]. <https://kargobot.ai/>.
- [14] 小马智行 (Pony.ai). 自动驾驶技术及移动出行服务[EB/OL]. 2024[2024-09-29]. <https://pony.ai/>.
- [15] 中国智能网联汽车产业创新联盟. 车路云一体化系统白皮书[R]. 北京: 中国智能网联汽车产业创新联盟, 2023.
- [16] 崔明阳, 黄荷叶, 许庆, 等. 智能网联汽车架构, 功能与应用关键技术[J/OL]. 清华大学学报: 自然科学版, 2022, 62(3): 16. DOI: 10.16511/j.cnki.qhdxxb.2021.26.026.
- [17] 李克强, 常雪阳, 李家文, 等. 智能网联汽车云控系统及其实现[J]. 汽车工程, 2020, 42(12): 1595-1605.

- [18] 工业和信息化部, 公安部, 自然资源部, 等. 五部门关于公布智能网联汽车“车路云一体化”应用试点城市名单的通知: 工信部联通装函〔2024〕181号[EB/OL]. (2024-07-01) [2026-01-25]. <https://jingji.cctv.com/2024/07/03/ARTI24eZYhw1aPFkR1hmAhHT240703.shtml>.
- [19] 茅海剑, 李波, 贝绍轶, 等. 基于流固耦合的液罐车侧倾稳定性研究[J]. 江苏理工学院学报, 2021, 27(4): 12.
- [20] 王小润, 陈清华, 王建业. 侧向加速度对非满载液罐车横向稳定性的影响分析[J]. 安徽工程大学学报, 2022(4): 37.
- [21] 于志新, 程新新, 李杰, 等. 基于 MPC 的重型液罐车侧向稳定性控制仿真[J]. 长春工业大学学报, 2018.
- [22] 徐晓美, 朱铨伟, 蔡浩浩. 基于仿真平台的半挂液罐车变道行驶稳定性研究[Z]. 2020.
- [23] 李杰, 于志新, 程新新, 等. 车-液耦合响应下液罐车稳定性控制仿真[J]. 油气储运, 2020, 39(2): 8.
- [24] 王琼瑶. 部分充液罐车罐体内液体晃动的动力学特性研究[D]. 广州: 华南理工大学, 2017.
- [25] 黄洋, 邓贵德, 张兴芳. 非满载充液罐车转弯过程瞬时液体冲击影响分析[J]. 化工机械, 2017.
- [26] 万滢. 液罐车辆车-液耦合动力学特性与防侧翻控制方法研究[D]. 长春: 吉林大学, 2020.
- [27] 陈益苞, Rakheja S, 上官文斌. 罐体横截面形状对液罐车侧倾稳定性影响分析[J]. 振动与冲击, 2016, 35(6): 6.
- [28] 贾心红, 张竹林, 蒋德飞. 半挂式液罐车罐内液体晃动及其对整车侧翻稳定性影响研究现状[J]. 汽车实用技术, 2022, 47(1): 193-196.
- [29] 于志新, 李杰, 程新新, 等. 液罐车稳定性最优控制仿真[J]. 油气储运, 2019, 38(8): 8.
- [30] 赵伟强, 封冉, 宗长富. 基于等效晃动模型的液罐车防侧翻控制策略[J]. 吉林大学学报: 工学版, 2018, 48(1): 1-6.
- [31] 赵伟强, 凌锦鹏, 宗长富. 半挂式液罐车防侧翻控制策略开发[J]. 汽车工程, 2019, 41(1): 1-7.
- [32] 何烈云, 刘强. 非满载液罐车侧倾稳定性的准静态等效力学模型[J]. 力学与实践, 2020, 42(3): 6.
- [33] Salem M I. Rollover stability of partially filled heavy-duty elliptical tankers using trammel pendulums to simulate fluid sloshing[D]. Morgantown: West Virginia University, 2000.
- [34] 杨秀建, 邢云祥, 吴相稷, 等. 液罐车液体侧向晃动多质量椭圆规摆模型[J]. 交通运输工程学报, 2018, 18(5): 12.
- [35] 吴相稷, 杨秀建, 宋均涛. 液罐车液体侧向晃动模型研究[J]. 农业装备与车辆工程, 2018, 56(2): 6.
- [36] Qi X, Gao B, Zhang Y. Observing liquid sloshing based on a multi-degree-of-freedom pendulum model and free surface fluctuation sensor[J/OL]. Sensors, 2023, 23(21): 8831. DOI: 10.3390/s23218831.
- [37] Qi X, Luo Y, Gao B, et al. Anti-rollover path tracking control for an autonomous semi-trailer tank truck[J]. IEEE Transactions on Intelligent Transportation Systems, 2025, 26(7): 9932-9947.

- [38] Yu D, Chu J, et al. Study on roll-stability model optimization for partially filled tanker trucks[J]. *Advances in Mechanical Engineering*, 2019, 11(4): 1-8.
- [39] 任园园, 李显生, 郑雪莲, 等. 液罐车精确动力学建模及其侧倾稳定性[J]. *上海交通大学学报*, 2020, 54(3): 10.
- [40] 何仁, 申小敏. 半挂汽车列车联合制动系统性能仿真分析[J]. *重庆交通大学学报: 自然科学版*, 2016, 35(5): 9.
- [41] 宗长富, 聂枝根, 张振. 厢式半挂车简化模型参数辨识研究[J]. *中国公路学报*, 2014, 27(4): 9.
- [42] 聂枝根, 宗长富. 重型半挂车简化模型参数辨识研究[J]. *汽车工程*, 2015, 37(6): 10.
- [43] 于迪, 李显生, 刘宏飞, 等. 非满载液罐车侧倾稳定性模型研究[J]. *湖南大学学报: 自然科学版*, 2016, 43(8): 5.
- [44] 韩友彬. 基于 VOF 的铁路液罐车防波板设计与仿真[D]. 西安: 西安理工大学, 2019.
- [45] 瞿绘军, 房坤, 蔡彦伦. 液罐车侧倾稳定性的计算研究[J]. *公路交通科技*, 2017(S2): 5.
- [46] 李显生, 于迪, 张景海. 基于遗传算法的液罐车侧倾稳定性模型[J]. *中国公路学报*, 2015, 28(7): 6.
- [47] Moreno Contreras G, Flórez Serrano E, Bladimir R, et al. Stability of tanker trucks using the davies method[J]. *Istrazivanja i projektovanja za privredu*, 2022, 20(2): 602-609.
- [48] 刘奎, 康宁. 罐车制动时液体晃动的仿真分析[J]. *北京航空航天大学学报*, 2009(7): 5.
- [49] 刘奎, 康宁. 罐车转向时液体晃动的仿真分析[J]. *北京航空航天大学学报*, 2009(11): 5.
- [50] 房亮. 基于有限元的液罐车罐体结构分析[J]. *机械工程与自动化*, 2022(1): 0.
- [51] 张卫华, 魏田宇, 徐迟, 等. 基于 GIS-T 的液罐车侧翻预警方法[J]. *中国安全科学学报*, 2019(2): 6.
- [52] Huston R, Kelly F. Another look at the static stability factor (ssf) in predicting vehicle rollover[J]. *International Journal of Crashworthiness*, 2014, 19(6): 567-575.
- [53] Jin Z, Weng J, Hu H. Rollover stability of a vehicle during critical driving manoeuvres[J]. *Proceedings of the Institution of Mechanical Engineers Part D: Journal of Automobile Engineering*, 2007, 221(9): 1041-1049.
- [54] 何元超, 李亮, 宋健, 等. 极限工况下汽车动态稳定性因数模型与分析[J]. *汽车安全与节能学报*, 2010, 1(4): 7.
- [55] Zhang Y, Khajepour A, Xie X. Rollover prevention for sport utility vehicles using a pulsed active rear-steering strategy[J]. *Proceedings of the Institution of Mechanical Engineers Part D: Journal of Automobile Engineering*, 2016, 230(9): 1239-1253.
- [56] Zhao W, Ji L, Wang C. H ∞ control of integrated rollover prevention system based on improved lateral load transfer rate[J]. *Transactions of the Institute of Measurement and Control*, 2019, 41(3): 859-874.
- [57] Jin Z, Li J, Wang H, et al. Rollover prevention and motion planning for an intelligent heavy truck[J]. *Chinese Journal of Mechanical Engineering*, 2021, 34(1): 1-15.
- [58] Zeng X, Li G, Song D, et al. Rollover warning algorithm based on genetic algorithm-optimized BP neural network[J]. *Journal of South China University of Technology*, 2017, 45(2): 30-38.

- [59] 靳立强, 石冠男, 孔德隽, 等. 基于零力矩点指标和侧翻时间算法的车辆侧翻预警[J]. 汽车工程, 2017, 39(3): 281-287,316.
- [60] Jin Z, Zhang L, Zhang J, et al. Stability and optimised H_{∞} control of tripped and untripped vehicle rollover[J]. *Vehicle System Dynamics*, 2016, 54(10): 1405-1427.
- [61] Jin Z, Li J, Huang Y, et al. Study on rollover index and stability for a triaxle bus[J]. *Chinese Journal of Mechanical Engineering*, 2019, 32: 64.
- [62] Imine H, Djemaï M. Switched control for reducing impact of vertical forces on road and heavy-vehicle rollover avoidance[J]. *IEEE Transactions on Vehicular Technology*, 2015, 65(6): 4044-4052.
- [63] Likhachev M, Ferguson D. Planning long dynamically feasible maneuvers for autonomous vehicles[J]. *The International Journal of Robotics Research*, 2009, 28(8): 933-945.
- [64] Kurzer K. Path planning in unstructured environments: A real-time hybrid A* implementation for fast and deterministic path generation for the KTH research concept vehicle[D/OL]. Stockholm: KTH Royal Institute of Technology, 2016. DOI: 10.13140/RG.2.2.10091.49444.
- [65] Dong H, Wang Q, Zhuang W, et al. Flexible eco-cruising strategy for connected and automated vehicles with efficient driving lane planning and speed optimization[J/OL]. *IEEE Transactions on Transportation Electrification*, 2023. DOI: 10.1109/TTE.2023.3289980.
- [66] Werling M, Ziegler J, Kammel S, et al. Optimal trajectory generation for dynamic street scenarios in a frenet frame[C/OL]//*Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*. Anchorage, AK, USA: IEEE, 2010: 987-993. DOI: 10.1109/ROBOT.2010.5509799.
- [67] Kuwata Y, Teo J, Fiore G, et al. Real-time motion planning with applications to autonomous urban driving[J]. *IEEE Transactions on Control Systems Technology*, 2009, 17(5): 1105-1118.
- [68] Karaman S, Frazzoli E. Sampling-based algorithms for optimal motion planning[J]. *The International Journal of Robotics Research*, 2011, 30(7): 846-894.
- [69] Klemm S, Oberländer J, Hermann A, et al. RRT*-connect: Faster, asymptotically optimal motion planning[C/OL]//*Proceedings of the IEEE International Conference on Robotics and Biomimetics (ROBIO 2015)*. Zhuhai, China: IEEE, 2015: 1670-1677. DOI: 10.1109/ROBIO.2015.7419012.
- [70] Fan H, Huang J, Huang X, et al. BI-RRT*: An improved path planning algorithm for secure and trustworthy mobile robots systems[J/OL]. *Heliyon*, 2024, 10(5): e26403. DOI: 10.1016/j.heliyon.2024.e26403.
- [71] Brezak M, Petrovic I. Real-time approximation of clothoids with bounded error for path planning applications[J]. *IEEE Transactions on Robotics*, 2014, 30(2): 507-515.
- [72] Rastelli J, Lattarulo R. Dynamic trajectory generation using continuous-curvature algorithms for door to door assistance vehicles[C]//*Proceedings of the IEEE Intelligent Vehicles Symposium (IV)*. IEEE, 2014: 510-515.
- [73] Phan-Huu T, Nguyen V H, Konigorski U. A time-optimal trajectory generation approach with non-uniform B-splines[J/OL]. *International Journal of Control, Automation and Systems*, 2021, 19(12): 3947-3955. DOI: 10.1007/s12555-020-0497-3.

- [74] Gotte C, Keller M, Nattermann T, et al. Spline-based motion planning for automated driving [C]//Proceedings of the IFAC World Congress. 2018.
- [75] Hegedüs F, Bécsi T, Aradi S, et al. Real-time optimal motion planning for automated road vehicles[J/OL]. IFAC-PapersOnLine, 2020, 53(2): 15647-15652. DOI: 10.1016/j.ifacol.2020.12.2501.
- [76] Rasekhipour Y, Khajepour A, Chen S, et al. A potential field-based model predictive path-planning controller for autonomous road vehicles[J]. IEEE Transactions on Intelligent Transportation Systems, 2017, 18(5): 1255-1267.
- [77] Cheng S, Li L, Member S. Longitudinal collision avoidance and lateral stability adaptive control system based on mpc of autonomous vehicles[J/OL]. IEEE Transactions on Intelligent Transportation Systems, 2019, 99(3): 1-10. DOI: 10.1109/TITS.2019.2927058.
- [78] Li X, Tang B, Ball J, et al. Rollover-free path planning for off-road autonomous driving[J/OL]. Electronics, 2019, 8(6): 614-636. DOI: 10.3390/electronics8060614.
- [79] Wu J, Huang C, Huang H, et al. Recent advances in reinforcement learning-based autonomous driving behavior planning: A survey[J/OL]. Transportation Research Part C, 2024, 164: 104654. DOI: 10.1016/j.trc.2024.104654.
- [80] Zhang E T, Zhang R X, Masoud N. Predictive trajectory planning for autonomous vehicles at intersections using reinforcement learning[J/OL]. Transportation Research Part C, 2023, 149: 104063. DOI: 10.1016/j.trc.2023.104063.
- [81] Irshayyid A, Chen J, Xiong G J. A review on reinforcement learning-based highway autonomous vehicle control[J/OL]. Green Energy and Intelligent Transportation, 2024, 3(4): 100156. DOI: 10.1016/j.geits.2024.100156.
- [82] Zhang Z, Liu Q, Li Y, et al. Safe reinforcement learning in autonomous driving with epistemic uncertainty estimation[J/OL]. IEEE Transactions on Intelligent Transportation Systems, 2024. DOI: 10.1109/TITS.2024.3397700.
- [83] Gu S, Yang L, Du Y, et al. A review of safe reinforcement learning: Methods, theories and applications[J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024. DOI: 10.1109/TPAMI.2024.3457538.
- [84] García J, Fernández F. A comprehensive survey on safe reinforcement learning[J]. Journal of Machine Learning Research, 2015, 16(42): 1437-1480.
- [85] 王元民, 王亚飞, 秦文刚, 等. 基于 SMPA 的半挂车自动泊车运动规划方法研究[J]. 汽车工程, 2024, 46(4): 693-702.
- [86] 陈朝. 半挂车辆垂直泊车系统路径规划与跟踪控制研究[D]. 秦皇岛: 燕山大学车辆与能源学院, 2023.
- [87] 贾生超. 半挂牵引车自动泊车路径规划与运动控制方法研究[D]. 秦皇岛: 燕山大学车辆与能源学院, 2023.
- [88] 李斯旭, 徐彪, 胡满江, 等. 基于动力学模型预测控制的铰接车辆多点预瞄路径跟踪方法[J]. 汽车工程, 2021, 43(8): 1479-1486.
- [89] 曹莉凌, 刘威, 代堃鹏, 等. 采用转角补偿 LQR 的自动驾驶集卡路径跟踪控制[J]. 汽车安全与节能学报, 2024, 15(3): 413-423.

- [90] 张发旺, 陈良发, 段京良, 等. 多轴轮式铰接车辆双策略轨迹跟踪控制[J]. 兵工学报, 2025.
- [91] 宋广昊. 铰接式车辆紧急变道避障控制策略研究[D]. 长春: 吉林大学, 2023.
- [92] 王洪昌. 自动驾驶半挂牵引车换道转向实时运动规划方法研究[D]. 青岛: 青岛大学, 2023.
- [93] Xu Y Y, Wang J S, Jin Z L, et al. Rollover prevention control based on active-steering and differential-braking[J/OL]. Computer Simulation, 2011. DOI: 10.1080/17415993.2010.547197.
- [94] Liang J H, Lu Y B, Pi D W, et al. A decentralized cooperative control framework for active steering and active suspension: Multi-agent approach[J/OL]. IEEE Transactions on Transportation Electrification, 2022, 8(1): 1414-1429. DOI: 10.1109/TTE.2021.3096992.
- [95] Xiao L, Wang M, Zhang B, et al. Vehicle roll stability control with active roll-resistant electro-hydraulic suspension[J/OL]. Frontiers of Mechanical Engineering, 2020, 15(1): 43-54. DOI: 10.1007/s11465-019-0547-9.
- [96] Carlson N W, Taylor A J, Jones K M, et al. Two-step polarization-labeling spectroscopy of excited states of Na₂[J]. Phys Rev A, 1981, 24: 822-834.
- [97] Zilin X, Wenwei W, Sheng L. Path following and lateral-yaw-roll stability integrated control method for autonomous distributed drive electric buses[J/OL]. International Journal of Automotive Technology, 2023. DOI: 10.1007/s12239-023-0091-9.
- [98] Shao W, Liang X, Fang T, et al. Active steering stability control of steer-by-wire vehicles based on variable horizon-robust model predictive control[J/OL]. Journal of the Brazilian Society of Mechanical Sciences and Engineering, 2023, 45(8): 410. DOI: 10.1007/s40430-023-04316-5.
- [99] 韩硕. 半挂式液罐车防侧翻集成与路径跟踪协调控制研究[D]. 安徽: 安徽理工大学, 2023.
- [100] 胡云, 江发潮, 陈锐, 等. 分布式电驱车辆驱动系统 MFAC 主动容错控制[J/OL]. 汽车工程, 2019, 41(9). DOI: CNKI:SUN:QCGC.0.2019-09-001.
- [101] 罗禹贡, 陈锐, 胡云. 分布式电驱车辆线控转向系统 MFAC 主动容错控制[J/OL]. 机械工程学报, 2019, 55(22): 1-9. DOI: 10.3901/JME.2019.22.131.
- [102] 唐泽月, 刘海鸥, 薛明轩, 等. 基于 MPC-MFAC 的双侧独立电驱动无人履带车辆轨迹跟踪控制[J/OL]. 兵工学报, 2023, 44(1): 129-139. DOI: 10.12382/bgxb.2022.0886.
- [103] 冯增喜, 张聪, 李丙辉. 基于改进粒子群优化算法的 MFAC 参数寻优[J/OL]. 控制工程, 2021, 28(4): 1-8. DOI: 10.14107/j.cnki.kzgc.20200303.
- [104] Sun W, Liu Y, Li S, et al. Rollover prevention control of the tank semi-trailer considering sloshing of the liquid[J]. International Journal of Heavy Vehicle Systems, 2021, 28: 752-752.
- [105] 刘台凤. 基于多智能体理论的危化品液罐车底盘集成控制研究[D]. 江苏: 淮阴工学院, 2021.
- [106] Li X S, Ren Y Y, Zheng X L. Model-free adaptive control for tank truck rollover stabilization [J/OL]. Mathematical Problems in Engineering, 2021, 2021: 8417071. DOI: 10.1155/2021/8417071.
- [107] 郑雪莲, 任园园, 李显生, 等. 基于 MFAC 算法的液罐车侧倾稳定性控制方法、系统: 中国, CN110395263A[P]. 2019-11-01.
- [108] Ferguson D, Howard T M, Likhachev M. Motion planning in urban environments[J]. Journal of Field Robotics, 2008, 25(11-12): 939-960.

-
- [109] Urmson C, Anhalt J, Bagnell D, et al. Autonomous driving in urban environments: Boss and the urban challenge[J]. *Journal of Field Robotics*, 2008, 25(8): 425-466.
 - [110] Leonard J, How J, Teller S, et al. A perception-driven autonomous urban vehicle[J]. *Journal of Field Robotics*, 2008, 25(10): 727-774.
 - [111] Kammel S, Ziegler J, Pitzer B, et al. Team annieway's autonomous system for the 2007 DARPA urban challenge[J]. *Journal of Field Robotics*, 2008, 25(9): 615-639.
 - [112] von Hundelshausen F, Himmelsbach M, Hecker F, et al. Driving with tentacles: Integral structures for sensing and motion[J/OL]. *Journal of Field Robotics*, 2008, 25(9): 640-673. DOI: 10.1002/rob.20256.
 - [113] Montemerlo M, Becker J, Bhat S, et al. Junior: The stanford entry in the urban challenge[J/OL]. *Journal of Field Robotics*, 2008, 25(9): 569-597. DOI: 10.1002/rob.20255.
 - [114] Thrun S, Montemerlo M, Dahlkamp H, et al. Stanley: The robot that won the DARPA grand challenge[J/OL]. *Journal of Field Robotics*, 2006, 23(9): 661-692. DOI: 10.1007/978-3-540-73429-1_1.
 - [115] Salvado J, Custodio L M M, Heß D. Contingency planning for automated vehicles in urban traffic[C/OL]//2016 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2016. DOI: 10.1109/IROS.2016.7759442.
 - [116] Huang T, Liu J, Zhou X, et al. Vehicle-to-everything cooperative perception for autonomous driving[J/OL]. *Proceedings of the IEEE*, 2025. DOI: 10.1109/JPROC.2025.3600903.
 - [117] Yu H, Yang W, Zhong J, et al. End-to-end autonomous driving through v2x cooperation[A/OL]. 2024. arXiv: 2404.00717. <https://arxiv.org/abs/2404.00717>.
 - [118] Song Z, Xia C, Wang C, et al. Unimm-v2x: Moe-enhanced multi-level fusion for end-to-end cooperative autonomous driving[A/OL]. 2025. arXiv: 2511.09013. <https://arxiv.org/abs/2511.09013>.
 - [119] You J, Shi H, Jiang Z, et al. V2x-vlm: End-to-end v2x cooperative autonomous driving through large vision-language models[A/OL]. 2025. arXiv: 2408.09251. <https://arxiv.org/abs/2408.09251>.
 - [120] Kherroubi Z e a, Boukhalfa F, Lestable T, et al. Autodraitec: An infrastructure-based autonomous driving system using artificial intelligence and telecommunication technologies [C]//Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence (IJCAI-24) Demonstrations Track. IJCAI Organization, 2024: 8704-8707.
 - [121] Lu Z, Wu T, Su J, et al. Toward edge-computing-enabled collision-free scheduling management for autonomous vehicles at unsignalized intersections[J/OL]. *Digital Communications and Networks*, 2024, 10: 1600-1610. DOI: 10.1016/j.dcan.2024.03.001.
 - [122] Typaldos P, Malikopoulos A A. Combining cooperative re-routing with intersection coordination for connected and automated vehicles in urban networks[A]. 2025. arXiv: 2503.10004v1.
 - [123] Yang H, Li W, Zhang C, et al. Cloud-based cooperative merging control with communication delay compensation for connected and automated vehicles[J/OL]. *Sustainability*, 2025, 17(17): 7952. DOI: 10.3390/su17177952.

- [124] Wang Y, Xiang J, Pan J, et al. Cooperative control of cavs in the merging area of multi-lane mainline and dual-lane ramps on freeways[J/OL]. *Transportation Safety and Environment*, 2025, 7. DOI: 10.1093/tse/tdaf030.
- [125] 石佳. 基于高速公路匝道云控系统的异质车辆组协同控制方法[D]. 北京: 清华大学, 2024.
- [126] Gao Z, Liu D, Zheng C. Vehicle-to-everything decision optimization and cloud control based on deep reinforcement learning[J/OL]. *Scientific Reports*, 2025, 15: 29160. DOI: 10.1038/s41598-025-12772-3.
- [127] 韩硕. 基于车路云一体化的智能网联汽车决策规划方法[D]. 北京: 清华大学, 2024.
- [128] Gao B, Chen Q, Liu Y, et al. Predictive cruise control under cloud control system for urban bus considering queue dissipation time[J]. *IEEE Transactions on Intelligent Vehicles*, 2023, 8(4): 2639-2649.
- [129] Li S, Wan K, Gao B, et al. Predictive cruise control for heavy trucks based on slope information under cloud control system[J]. *Journal of Systems Engineering and Electronics*, 2022, 33(4): 812-826.
- [130] Gao B, Wang L, et al. Cloud-based predictive adaptive cruise control for heavy trucks considering preceding vehicle and slope information[J]. *IEEE Transactions on Vehicular Technologies*, 2024: 1-15.
- [131] 王宙, 褚端峰, 高博麟, 等. 云支持的分层式车辆队列预测性巡航控制[J]. *汽车安全与节能学报*, 2023, 14(5): 591-599.
- [132] 梅润, 褚端峰, 高博麟, 等. 基于云控系统的队列预测性巡航与换道决策[J]. *汽车工程*, 2023, 45(8): 1299-1308.
- [133] 江宇. 基于云控的智能网联汽车预测性换道方法研究[D]. 北京: 中国农业大学, 2023.
- [134] Ji Y, Zhou Z, Yang Z, et al. Toward autonomous vehicles: A survey on cooperative vehicle-infrastructure system[J/OL]. *iScience*, 2024, 27: 109751. DOI: 10.1016/j.isci.2024.109751.
- [135] 许庆, 潘济安, 李克强, 等. 不可靠通信的云控场景下网联车辆控制器的设计[J]. *汽车工程*, 2021, 43(4): 527-536.
- [136] Wang P, Deng H, Zhang J, et al. Model predictive control for connected vehicle platoon under switching communication topology[J/OL]. *IEEE Transactions on Intelligent Transportation Systems*, 2021: 1-14. DOI: 10.1109/TITS.2021.3073012.
- [137] 李克强, 李家文, 常雪阳, 等. 智能网联汽车云控系统原理及其典型应用[J]. *汽车安全与节能学报*, 2020, 11(3): 261-275.
- [138] Ran B, Zheng Y, Luo K, et al. Architecture design of a vehicle-road-cloud collaborative automated driving system[J]. *Urban Lifeline*, 2023, 1: 9.
- [139] Guo Z, Yu K, Kostromitin K, et al. Deep collaborative intelligence-driven traffic forecasting in green internet of vehicles[J]. *IEEE Transactions on Green Communications and Networking*, 2023, 7(2): 1023-1035.
- [140] Hejazi H, Bokor L. A survey on the use-cases and deployment efforts toward converged internet of things (iot) and vehicle-to-everything (v2x) environments[J]. *Acta Technica Jaurinensis*, 2022, 15(2): 58-73.

- [141] US Department of Transportation. ARC-IT version 9.3: The national ITS reference architecture [EB/OL]. (2024-07-17)[2026-01-25]. <https://www.arc-it.net/html/architecture/architecture.html>.
- [142] C-MobILE Consortium. C-mobile: Advanced cooperative mobility for urban transportation [EB/OL]. 2024[2026-01-25]. <https://c-mobile-project.eu>.
- [143] Lu M, Turetken O, Adali O E, et al. C-ITS (cooperative intelligent transport systems) deployment in europe: challenges and key findings[C]//25th ITS World Congress. Copenhagen, Denmark: ITS World Congress, 2018: 17-21.
- [144] Ferrandez R, Dajsuren Y, Karkhanis P, et al. Modelling the C-ITS architectures: C-MobILE case study[C]//25th ITS World Congress. Copenhagen, Denmark: ITS World Congress, 2018: 17-21.
- [145] 国家智能网联汽车创新中心. 智能网联汽车信息物理系统参考架构 1.0[R/OL]. 北京: 国家智能网联汽车创新中心, 2019[2026-01-25]. https://13115299.s21i.faiusr.com/61/1/ABUIABA9GAAGwODrjQYojv_5wQc.pdf.
- [146] 国家智能网联汽车创新中心. 智能网联汽车信息物理系统参考架构 2.0[R/OL]. 北京: 国家智能网联汽车创新中心, 2021[2026-01-25]. <https://13115299.s21i.faiusr.com/61/1/ABUIABA9GAAGweDrjQYoweitMw.pdf>.
- [147] Xu T, Liang H, Zhao J, et al. Modeling method for intelligent vehicle cyber-physical system based on MBSE[J]. Automotive Digest, 2023, 10(1): 1-16.
- [148] 中国汽车工程学会. 车路云一体化系统云控基础平台功能场景参考架构 1.0[EB/OL]. (2024-06-19)[2026-01-25]. <https://zhishi.sae-china.org/ppt.html?id=4891>.
- [149] 王维平, 朱一凡, 王涛, 等. 体系视野下的 MBSE[J/OL]. 科技导报, 2019, 37(7): 12-21. <https://www.kjdb.org/CN/10.3981/j.issn.1000-7857.2019.07.002>.
- [150] 冯益民, 刘玉生, 邵艳利, 等. 基于建模与仿真的体系工程框架[C]//国防科技大学系统工程学院. 第六届体系工程学术会议论文集—体系工程与高质量发展. 长沙: 国防科技大学系统工程学院, 2024: 11.
- [151] 李明华. 新时期航天体系工程模型研究[J]. 工程研究-跨学科视野中的工程, 2021, 13(6): 552-562.
- [152] 张霖, 王昆玉, 赖李媛君, 等. 基于建模仿真的体系工程[J]. 系统仿真学报, 2022, 34(2): 179-190.
- [153] 刘兴华, 曹云峰, 王彪, 等. 基于 SysML 与 Simulink 的飞控系统概念样机设计[J]. 电子科技大学学报, 2011, 40(6): 887-891+910.
- [154] 刘同磊, 曹云峰, 庄丽葵, 等. 基于 SysML 的三余度飞控计算机系统建模方法研究[J]. 云南民族大学学报(自然科学版), 2015, 24(5): 412-417.
- [155] 张绍杰, 李正强, 海晓航, 等. 基于 MBSE 的民用飞机安全关键系统设计[J]. 中国科学: 技术科学, 2018, 48(3): 299-311.
- [156] 韦彩色, 王新尧, 陈纪磊, 等. 基于 SysML 与 Simulink 的机载传感器建模方法[J]. 计算机仿真, 2021, 38(10): 94-100.
- [157] 郭玉亮, 朱东伟, 张丽, 等. 基于 MBSE 的车门系统设计研究[J]. 铁道车辆, 2023, 61(5): 81-87.

- [158] 秦昌茂, 孟苏, 莫锦鹤. 基于 SysML 的远程专家保障装备体系建模及结构评估[J]. 宇航总体技术, 2021, 5(6): 12-19.
- [159] 刘洋, 郝威巍, 李乐晓, 等. 体系工程理论新发展及展望[C]//国防科技大学系统工程学院. 第六届体系工程学术会议论文集—体系工程与高质量发展. 长沙: 国防科技大学系统工程学院, 2024: 8.
- [160] 戚笑景, 肖雅月, 钟薇, 等. 智能网联汽车信息物理系统分场景 MBSOSE 建模方法[J/OL]. 机械工程学报, 2026, 62(7): 1-25. DOI: 10.3901/JME.260143.

附录 A 补充内容

A.1 综述补充

A.1.1 模块化自动驾驶

近年来模块化路线的一个共同趋势是预测-决策一体化：将自车决策作为条件变量，显式或隐式地建模“自车动作 → 他车响应”的耦合关系，并在候选决策之间做综合评估。现有研究大体可按交互处理方式划分为显式交互、隐式交互及综合式交互三类。

显式交互以自车候选策略/意图划分场景，在每个候选行为下预测周车反应，并对不同候选行为的长期收益与风险进行比较，典型代表为多策略决策方法（Multi-Policy Decision Method, MPDM）。Cunningham 等^[A.1-A.2]提出 MPDM 思想，将交互不确定性建模为部分可观测马尔可夫决策过程（Partially Observable Markov Decision Problem, POMDP），并用一组闭环策略/意图近似描述自车与周车的决策空间，从而显著压缩搜索规模。Ding 等提出的 EPSILON^[A.3]继承并改进该思想，提出领域特定闭环策略树（Domain-Specific-Policy Tree, DCP-Tree）与条件集中分支（Conditional Focused Branching, CFB）机制^[A.4]，通过限制自车策略展开深度并聚焦意图不确定性高的周车，提升了在线规划的效率；并进一步结合时空语义走廊规划器^[A.5]用于运动规划。Bae 等^[A.6]结合 MPC 与生成对抗网络（Generative Adversarial Network, GAN）生成平滑换道轨迹，并引入自适应安全边界与卡尔曼滤波以提升密集交通中的鲁棒性与可用性。

隐式交互侧重对周车意图/不确定性构造多个可能情景，并在情景集合上评估自车应对策略，典型代表包括防御性规划（Contingency Planning）^[A.7]与博弈论方法。Huang 等^[A.8]提出基于风险预算的递归控制算法，通过动态分配风险预算在满足安全约束的同时减少过度保守。Da 等^[A.9]提出综合反应式安全（Comprehensive Reactive Safety, CRS）框架，强调规划不必在所有未来情形下“绝对无碰撞”，而应能对环境变化做出反应并保证安全，并在此基础上提出反应式迭代线性二次规划（iterative Linear Quadratic Regulator, iLQR）算法。博弈论思路方面，Le Cleach 等^[A.10]提出基于无迹卡尔曼滤波的逆动力学博弈用于在线估计其他智能体目标函数，并将其整合到滚动时域博弈规划器中；进一步在^[A.11]提出增广拉格朗日快速求解器 ALGAMES 以求解含非线性约束的多玩家动态博弈问题。Li 等^[A.12]提出面向无信号交叉口的多车博弈框架，并在^[A.13]提出基于 Level-K 博弈论的长时域、多

步交互决策模型，体现了“交互可解释、决策可推演”的特点。

综合式交互将显式交互与隐式交互思想融合，并常与风险度量、礼貌性或协同性等机制结合。Tong Li 等^[A.14]提出风险敏感多策略防御性规划（Multipolicy and Risk-Aware Contingency Planning, MARC）框架，集成 MPDM 与风险感知的防御性规划，并通过场景级动态分支点与 LP-iLQR 双层迭代优化显著提升复杂交互环境下的决策效率与自然性。此外，Sun 等^[A.15]在目标函数中引入“对他车成本影响”的度量以形成更礼貌的驾驶行为；Sheng 等^[A.16]利用时空图卷积网络构建交互式轨迹预测模型，用于评估他车对自车决策的反应，从而增强协同意识。

A.1.2 端到端自动驾驶

自 2022 年大语言模型（Large Language Model, LLM）快速兴起以来^[A.17]，大规模数据驱动的统一表征与跨模态知识融合显著加速了自动驾驶从“模块化流水线”向“可微统一优化”的范式迁移。端到端（End-to-end, E2E）自动驾驶因此成为热点：其核心目标是缓解模块化方案中感知误差难以被后续模块正确吸收、感知—规控接口造成的信息裁剪与不确定性丢失等问题。围绕可微边界的不同，现有端到端路线通常划分为两段式端到端（以结构化感知结果为输入）与一段式端到端（从原始或近原始感知表征直接到规划/控制输出），并进一步发展到“感知直接到控制”的视觉语言动作模型（Vision Language Action Model, VLA）形态。

两段式端到端通常以结构化感知结果作为输入，是早期端到端方案的主流工程选择，其方法谱系主要包括模仿学习与强化学习，并常组合使用：通过行为克隆、逆最优控制、知识蒸馏等模仿学习^[A.18]注入先验以快速初始化，再衔接强化学习提升长时域闭环性能。规划挑战体系中，PlanTF^[A.19]奠定了两段式端到端规划的 Transformer 化范式；PLUTO^[A.20]作为其后续代表，将自车、周车、静态障碍物、静态地图与动态交通信息分路编码，并设计可微辅助任务与横纵向交叉因式分解注意力解码机制，配合规则后处理在综合指标上显著提升表现，首次击败了规则方案：2023 年 nuPlan 挑战赛冠军 PDM-Close。CarPlanner^[A.21]在此基础上引入动作模式一致性的自回归世界模型以增强长时域一致性。与此同时，“将驾驶行为离散化为 token 并借鉴语言建模训练范式”的路线也被用于两段式体系增强：Wayformer^[A.22]与 Trajenglish^[A.23]体现将自车动作/轨迹离散成“词”的建模思路，Plan-R1^[A.24]进一步将强化学习与 PLUTO 式框架衔接以提升闭环决策质量。总体而言，两段式端到端的优势是输入结构化、跨平台迁移友好、较少面临原始感知域的 Sim2Real 适配；但其不可避免受限于感知到规控的信息接口，感知不确定性难以在端到端训练中被充分吸收并转化为更优决策，这构成其相对于一段式路线的主要性能上限来源。

一段式端到端的关键差异在于：规划/决策损失的梯度可以回传到上游感知表征，从而实现感知—预测—决策—规划的整体协同优化。向 Transformer 迁移的统计基座表征、多模态融合与 BEV 化输入是端到端方案发展的重要基石。Transformer^[A.17]奠定了序列建模与注意力机制的通用范式，并促成视觉领域从 CNN 主导向 Transformer 主导的快速迁移：ViT^[A.25]提供视觉 Transformer 的基础表征框架，DETR^[A.26]将检测任务显式序列化并实现端到端集合预测，Deformable DETR^[A.27]进一步通过可变形注意力提升稀疏采样效率与收敛质量；相较之下，Faster R-CNN^[A.28]、Mask R-CNN^[A.29]与早期 YOLO^[A.30]代表传统两阶段/实例分割/单阶段检测范式，在统一序列接口与全局注意力建模方面存在结构性差异。多模态端到端方面，Transfuser^[A.31]代表性地推进了相机/激光雷达等多源原始数据的融合机制，使“在统一表征上直接学习规划”更具工程可行性。纯视觉端到端则普遍以鸟瞰图（Bird-Eye View, BEV）作为统一几何坐标系：Lift-Splat-Shoot^[A.32]提供从图像到 BEV 的显式几何投影范式，PanopticSegFormer^[A.33]推进了 BEV 语义与全景理解能力，BEVFormer^[A.34]进一步通过时序注意力与多相机对齐强化动态场景表征（BEV 发展脉络可由^[A.32-A.34]串联）。在 BEV 之上，结构化输出同样快速演进：MapTR^[A.35]体现 BEV 到矢量化地图/车道拓扑要素的生成路径，SurroundOcc^[A.36]代表占用/可通行空间的体素化建模方向，CASPFormer^[A.37]则延续以统一 Transformer 骨干推动多任务场景级理解的一体化趋势。UniAD^[A.38]与 VAD^[A.39]是早期代表：其将检测、跟踪、建图/占用等感知子任务与规划模块网络化并联合训练，使规划学习能够直接利用可学习的中间表征。UAD^[A.40]进一步强调将多模块融合为更统一的综合式架构，并引入无监督预训练以降低对标注的依赖。SparseDrive^[A.41]体现以更稀疏/关键要素的表示与更高效的推理路径支撑端到端规划，而 VADv2^[A.42]则作为 VAD 体系的重要迭代，强调在训练机制与闭环表现上的增强。在“开环规划/评测”语境下，BEV-Planner^[A.43]具有代表性：其系统性分析开环端到端评测中的关键细节，并突出自车状态（ego status）在规划学习中的作用，通过面向自车信息的设计改善收敛与鲁棒性，从而为后续端到端规划的输入建模与指标解读提供了可复用的基线框架。在数据来源与目标形式上，HydraMDP^[A.44]采用多模态、多目标的训练范式，将交互逻辑不仅从人类驾驶数据学习，也通过仿真数据补充多样性与长尾覆盖，从而提升端到端规划在稀有工况下的鲁棒性。强化学习与世界模型亦被用于增强闭环能力，例如 SEM2^[A.45]通过语义掩码构建世界模型并配合多源采样提高长尾工况比例，体现“以可控数据分布塑形闭环策略”的路线。

随着端到端从“输出单一最优轨迹”转向“建模可行多模态轨迹分布”，生

成式规划成为重要方向。扩散模型体系由去噪扩散概率模型（Denoising Diffusion Probabilistic Model, DDPM）^[A.46]奠基，扩散去噪隐式模型（Denoising Diffusion Implicit Model, DDIM）^[A.47]提供更快的隐式采样路径大大加速了采样耗时的 DDPM，Score-based 扩散^[A.48]进一步提供了基于分数函数的训练视角；在数值加速方面，清华大学提出的 DPM-Solver 系列^[A.49-A.51]对高质量加速提供了更好的方案；在更加高维的向量空间表征上，潜空间扩散模型（Latent Diffusion Model, LDM）^[A.52]将向量量化生成对抗式网络（Vector Quantised-GAN, VQ-GAN）^[A.53]与 DDPM 结合从而“在潜空间进行扩散”以显著降低生成成本。面向自动驾驶闭环规划，DiffusionPlanner^[A.54]代表将扩散用于闭环规划并支持预测—规划联合建模的路线，通过生成多模态行为分布提升交互一致性与轨迹质量（并强调减少规则后处理依赖）。相比于传统扩散方式，Flow Matching^[A.55]这一条技术路线则提供另一条直接建模概率扩散的方式，建立线性插值的最短路径：“整合流（Rectified Flow）”用于以更少步数实现高效生成。扩散模型跨模态条件生成的范式如 DALLE2 中 CLIP^[A.56]与扩散模型结合^[A.57]所体现的“条件对齐表征 + 生成模型”框架，并被更新的自动驾驶规划工作用于将地图/交通体/导航意图等条件注入生成过程。在更近期的结果汇总中，DiffusionDrive-v2^[A.58]引入强化学习约束的截断扩散生成策略，并在其公开报告中给出了在 NAVSIM 基准上的更高分数，从而在同类生成式规划对比中形成新的强参考点；该结果在文中被表述为当时的基准最优，并体现出对以 GoalFlow^[A.59]为代表的先前强方法的进一步提升。

A.1.3 半侧翻模态及其可控性

如图 A.1 所示，车辆侧翻有全部车轮着地模态（未侧翻模态）和一侧车轮离地（半侧翻模态，Semi-Rollover）两种状态^[A.60]，而半侧翻模态在很多研究中已经被定义为侧翻。但实际车辆行驶过程中由于操作不慎、绊倒性侧翻等原因在达到半侧翻态时仍旧有将车辆救回的余地。

但由于目前研究只关注未侧翻模态，而忽略了半侧翻模态，国内外缺乏对于半侧翻模态可控性、动力学特性与控制方法的探究，故对吉尼斯记录、网络公开可访问的交通录像资料与影视素材进行了搜索，对该模态的说法一般为侧两轮行驶（Driving on Two Wheels），或单边行驶。首先关注半侧翻模态的发生条件。如图 A.2 所示，半侧翻状态在小型车辆行驶时一般不容易被动发生，通常是驾驶员认为主动在高速情况下通过 ABA 式（ABA 表示向某向打方向，再向反向，再回来的方式）快速打方向或 AB 式快速打方向产生的，通常属于特技动作，可用于超车或紧急避险。其他主动发生方法包括一侧车轮行驶过带坡度的单边桥等。对于大型车辆，半侧翻模态由于车辆质心更高更易发生，其发生通常是被动的，如中速在大




图 A.1 车辆侧翻的两种模式

曲率弯道下发生，或高速在小曲率弯道发生等。



(a) 高速 ABA 式快速转向主动发生 (b) 高速 AB 式快速转向主动发生

(c) 中速大曲率弯道被动发生 (d) 高速小曲率弯道被动发生

图 A.2 半侧翻态发生的情况

其次关注半侧翻模态的可控性，如图 A.3(a)所示，2016 年 11 月 3 日中国车手韩岳驾驶一台 MINI 完成侧两轮行驶纽伯格林北环全程 20.83 km 并打破圈速记录；如图 A.3(b)所示，2022 年 12 月，车手田林文驾驶长安览拓者挑战“汽车侧两轮往返绕桩用时最短”吉尼斯世界记录成功，绕 5 桩用时 38.41 s；如图 A.3(c)工程师对模型玩具车进行改装，通过小型 IMU 和主动转向控制实现模型车侧两轮行驶；图 A.3(d)是某影视作品中驾驶员进行液罐车半侧翻态行驶的快照截取。通过上述实例总结来说，半侧翻模态在高速和低速都存在可控的状态子空间，半挂液罐车而言同样存在可控的状态子空间，且存在仅通过前轮转向即可控制的区域。在此

区域内，通过控制器可以得到与驾驶员控制相同的可控性结论。



图 A.3 半侧翻模态可控性调研

A.1.4 强化学习与近端策略优化

强化学习（Reinforcement Learning, RL）研究智能体（agent）在环境（environment）中通过交互学习策略（policy）的过程。典型形式化可用马尔可夫决策过程（Markov Decision Process, MDP）表示：\$(S, \mathcal{A}, P, r, \gamma)\$，其中 \$S\$ 为状态空间，\$\mathcal{A}\$ 为动作空间，\$P(s'|s, a)\$ 为转移概率，\$r(s, a)\$ 为即时奖励，\$\gamma \in (0, 1)\$ 为折扣因子。智能体的目标是最大化期望折扣回报

$$J(\pi) = \mathbb{E}_{\tau \sim \pi} \left[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) \right], \quad (\text{A.1})$$

其中轨迹 \$\tau = (s_0, a_0, s_1, a_1, \dots)\$ 由策略 \$\pi(a|s)\$ 诱导。强化学习算法大体可按值函数学习、策略梯度、Actor-Critic 与分布式/改进型分类，也可以根据是否只用最新策略采集的数据进行训练分为在轨策略（On-Policy）和离轨策略（Off-Policy），其他还有根据策略的随机性与否进行划分的方法等。下文将简述主要 RL 方法，并简要介绍第??章用到的近端策略优化（Proximal Policy Optimization, PPO）。

(1) 基于价值的深度强化学习

在离散动作空间中，经典路径是学习动作价值函数 $Q^\pi(s, a)$ ，并通过贪婪策略 $a = \arg \max_a Q(s, a)$ 做决策。深度 Q 网络（Deep Q-Network, DQN）将 $Q(s, a)$ 用深度网络近似，并引入经验回放与目标网络稳定训练，是深度强化学习的里程碑工作之一^[A.61]。DQN 及后续改进使得在高维观测（如 Atari 像素）上实现端到端学习成为可能。

除“期望回报”的标量 Q ，分布式强化学习（Distributional RL）直接建模回报随机变量 $Z(s, a)$ 的分布，并通过分布距离（如 Wasserstein/quantile 回归）学习更丰富的信息。Bellemare 等提出从分布角度刻画强化学习目标，推动了分位数回归 DQN 等方法的发展^[A.62]。这类思想也可与连续控制的 critic 建模结合，用于缓解偏差与提升稳定性（如本节的 TQC 方法）。

(2) 策略梯度与 Actor–Critic 架构

当动作空间连续或离散动作规模很大时，直接优化策略 $\pi_\theta(a|s)$ 往往更自然。策略梯度方法通过

$$\nabla_\theta J(\theta) = \mathbb{E}_{\pi_\theta} [\nabla_\theta \log \pi_\theta(a_t|s_t) \hat{A}_t] \quad (\text{A.2})$$

更新参数，其中 $\hat{A}_t$ 为优势函数估计，用于降低方差。异步方法（Asynchronous Methods，通常被称为 A3C/A2C 范式）通过多线程/多进程并行采样与更新，提高样本效率与训练吞吐^[A.63]。A2C 可视为 A3C 的同步版本，常与广义优势估计（Generalized Advantage Estimation, GAE）等技巧搭配，在中等规模任务中表现相对稳健。

然而，朴素策略梯度可能因步长过大导致策略崩溃。TRPO 通过信赖域约束控制新旧策略分布差异（常用 KL 散度约束），以保证单步更新的“单调改进”倾向^[A.64]。TRPO 理论上优雅，但实现涉及二阶信息与共轭梯度，工程复杂度较高。PPO 则用更易实现的“裁剪目标”在一阶优化框架下近似 TRPO 的保守更新思想^[A.65]，因其鲁棒性与实现简洁成为当前最常用的 on-policy 基线之一。下一小节将对 PPO 展开介绍。

(3) 连续控制的 Off–Policy Actor–Critic 架构

在连续动作控制中，off-policy Actor–Critic 通常更具样本效率。DDPG 将确定性策略梯度与 Q 学习结合，以 actor 输出连续动作、critic 评估 $Q(s, a)$ ，并使用经验回放与目标网络稳定训练^[A.66]。但 DDPG 易受函数逼近误差与过估计偏差影响。

TD3 针对 DDPG 常见问题提出三项关键改进：双 Q 网络取最小值减少过估计、

延迟策略更新降低不稳定、目标策略平滑抑制尖峰^[A.67]。SAC 则基于最大熵强化学习框架，在优化期望回报的同时最大化策略熵，从而鼓励探索并提升鲁棒性；其随机策略与温度参数机制使得训练更稳定、性能更强劲^[A.68]。在分布式/分位数视角下，TQC 通过截断多个分位数 critic 的尾部来控制过估计偏差，是对连续控制分布式 critic 的一类有效工程化方案^[A.69]。

(4) 其他优化与稳定方法

稀疏奖励场景（如机器人到达目标）中，成功轨迹极少导致学习效率低。HER 提出“事后经验回放”：将失败轨迹中的达到状态重解释为“目标”，从而为同一条轨迹生成额外的有效监督信号，显著提升样本利用率^[A.70]。围绕多目标/通用技能学习，Plappert 等进一步构建更具挑战的机器人多目标基准与研究议程，推动了多目标强化学习的系统化发展^[A.71]。从工程角度，HER 常与 DDPG/TD3/SAC 等 off-policy 方法结合，构成解决稀疏奖励连续控制的经典组合。

除深度 Actor-Critic 外，参数空间搜索与黑箱优化也能在某些连续控制任务上取得有竞争力的表现。ARS 用简单随机方向搜索与归一化技巧，展示了“简单随机搜索”在一些基准上的惊人效果，且实现与调参成本较低^[A.72]。

近年来，一些工作从正则化/随机性或结构性简化角度提升样本效率与可扩展性：DroQ 通过对 Q 函数施加 dropout 并进行多次采样估计，有助于获得更“保守/稳健”的价值估计并提高样本效率^[A.73]；CrossQ 讨论了在深度强化学习中引入（批）归一化以获得更好的样本效率与更简洁的训练配方^[A.74]；SimBa 则从“simplicity bias”角度讨论参数规模扩展（scaling up）时的训练行为与规律，为大参数 RL 的可扩展训练提供经验性指引^[A.75]。这些方向共同反映了一个趋势：在既定算法骨架（如 Actor-Critic）上，通过更简单、更稳定的训练配方来获得更强的实际效果。

(5) PPO 方法核心思想与目标函数

PPO 属于 on-policy Actor-Critic 方法，核心目标是在保持实现简单的一阶优化框架下，限制策略更新幅度，避免性能骤降^[A.65]。其关键在于使用重要性采样比率

$$r_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)}, \quad (\text{A.3})$$

并用优势函数 $\hat{A}_t$ 构建 surrogate 目标。最常用的 PPO-Clip 形式为

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon_{\text{clip}}, 1 + \epsilon_{\text{clip}}) \hat{A}_t \right) \right], \quad (\text{A.4})$$

其中 ϵ_{clip} 为裁剪阈值（如 0.1 或 0.2）。直观解释如下：

- 当 $r_t(\theta)$ 偏离 1（新旧策略差异过大）且会过度提高目标时，裁剪项会限制增益，强制更新更保守。
- 通过 $\min(\cdot)$ 结构，PPO 在经验上倾向于避免“看似提升但可能导致崩溃”的过大更新。

PPO 还通常加入价值函数损失与熵正则项构成整体目标：

$$L(\theta) = L^{\text{CLIP}}(\theta) - c_v \mathbb{E}_t [(V_\theta(s_t) - \hat{V}_t)^2] + c_e \mathbb{E}_t [\mathcal{H}(\pi_\theta(\cdot|s_t))], \quad (\text{A.5})$$

其中 V_θ 为 critic， $\hat{V}_t$ 为回报/TD 目标， $\mathcal{H}$ 为策略熵， c_v, c_e 为权重。熵项鼓励探索、降低过早收敛风险；价值损失为 actor 提供低方差优势估计支撑。PPO 的工程实现通常采用“采样一批 on-policy 轨迹 $\rightarrow$ 多个 epoch、小批量 SGD 更新”的训练范式。

(6) 优势函数估计与训练流程

PPO 性能高度依赖优势函数 $\hat{A}_t$ 的估计质量。常见做法是采用 GAE 思想构造指数加权的 TD 残差累积（这里给出常用形式，便于在实现中对齐）：

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t), \quad (\text{A.6})$$

$$\hat{A}_t = \sum_{l=0}^{T-t-1} (\gamma\lambda)^l \delta_{t+l}, \quad (\text{A.7})$$

其中 $\lambda \in [0, 1]$ 控制偏差-方差权衡。实践中通常对优势做标准化（减均值除标准差），以提升数值稳定性。PPO 典型训练步骤可概括为：

1. 使用当前策略 $\pi_{\theta_{\text{old}}}$ 在环境中采样 N 步或若干条轨迹，得到 $\{(s_t, a_t, r_t, s_{t+1})\}$ ；
2. 用 critic 计算 $V(s_t)$ 并构造 $\hat{A}_t$ 与价值目标 $\hat{V}_t$ ；
3. 固定旧策略 $\pi_{\theta_{\text{old}}}$ ，以小批量方式对目标 $L(\theta)$ 进行 K 个 epoch 的梯度更新；
4. 更新 $\theta_{\text{old}} \leftarrow \theta$ ，进入下一轮采样。

与 off-policy 方法（DDPG/TD3/SAC）相比，PPO 的采样数据必须较新（on-policy），因此样本效率略逊，但其训练稳定性、对超参数的鲁棒性以及复杂策略网络（如 CNN/Transformer）上的泛化表现，使其在很多工程场景依然是首选基线^[A.65]。

A.2 理论补充

A.2.1 图扩散流匹配理论证明

我们希望学习得到的是动态特征速度的边缘向量场： v_t^θ ，其不依赖于未来真值 $\mathcal{V}_{k+1}$ ，那么我们使用条件向量场计算出来的速度向量 $v_t^{\text{target}}(F_{\text{dyn}}^t | \mathcal{V}_{k+1})$ 是否可以拿来当做训练的标签，即是否可以将无条件损失式（A.8）替换为有条件损失式

(A.9)。

$$\mathcal{L}_{FM}(\theta) = \mathbb{E}_{\mathbf{t} \sim \mathcal{U}, \mathbf{x} \sim p_{\mathbf{t}}} \left[\|v_{\mathbf{t}}^{\theta}(F_{dyn}^{\mathbf{t}}) - v_{\mathbf{t}}^{target}(F_{dyn}^{\mathbf{t}})\|^2 \right] \quad (\text{A.8})$$

$$\mathcal{L}_{CFM}(\theta) = \mathbb{E}_{\mathbf{t} \sim \mathcal{U}, \mathbf{x} \sim p_{\mathbf{t}}(\cdot|z), z \sim p_1} \left[\|v_{\mathbf{t}}^{\theta}(F_{dyn}^{\mathbf{t}}) - v_{\mathbf{t}}^{target}(F_{dyn}^{\mathbf{t}}|\mathcal{V}_{k+1})\|^2 \right] \quad (\text{A.9})$$

其实是可以的，下面来进行证明：

为了简化证明过程，不妨令真值 $z = \mathcal{V}_{k+1}$ ，动态特征场 $x = F_{dyn}^{\mathbf{t}}$ 。我们有了条件向量场，现在需要求出边缘向量场，也就是不依赖于 z 的向量场。边缘概率路径是对条件概率路径乘以条件 z 的概率然后对所有可能的 z 积分，即

$$p_{\mathbf{t}}(x) = \int_z p_{\mathbf{t}}(x|z)p_1(z)dz \quad (\text{A.10})$$

本质上应用了全概率公式，按照各种条件对 z 进行汇总，然后对所有可能的 z 积分。那么是否可以通过对所有条件向量场乘以 $p(z)$ ，然后对所有可能的 z 积分，得到边缘向量场？即

$$v_{\mathbf{t}}^{target}(x) = \int_z v_{\mathbf{t}}^{target}(x|z)p_1(z)dz \quad (\text{A.11})$$

答案是不行的，因为这里的 $v_{\mathbf{t}}^{target}$ 是个向量场，不是概率值，不能应用全概率公式。实际上的公式是这样的

$$v_{\mathbf{t}}^{target}(x) = \int_z v_{\mathbf{t}}^{target}(x|z)p_{\mathbf{t}}(z|x)dz \quad (\text{A.12})$$

我们可以利用贝叶斯公式 $p_{\mathbf{t}}(z|x) = \frac{p_{\mathbf{t}}(x|z)p(z)}{p_{\mathbf{t}}(x)}$ 转化一下上述边缘向量场公式，得到

$$v_{\mathbf{t}}^{target}(x) = \int_z v_{\mathbf{t}}^{target}(x|z) \frac{p_{\mathbf{t}}(x|z)p_1(z)}{p_{\mathbf{t}}(x)} dz \quad (\text{A.13})$$

这个表达式在后面证明时会用到。

接下来就来证明为什么边缘向量场的公式是那样的。我们需要验证的是这个边缘向量场公式符合连续性方程：

$$\frac{\partial p_{\mathbf{t}}(x)}{\partial t} + \nabla \cdot (p_{\mathbf{t}}(x)v_{\mathbf{t}}^{target}(x)) = 0 \quad (\text{A.14})$$

证明

定理 A.1 (连续性方程)： 设存在流，其质量场为 ρ ，速度场为 $\mathbf{v}$ ，时间变量为 t ，则

流场满足：

$$\frac{\partial \rho}{\partial t} + \nabla \cdot (\rho \mathbf{v}) = 0 \quad (\text{A.15})$$

连续性方程第一项，概率密度对时间求导，代入边缘概率的公式

$$\frac{\partial p_t(x)}{\partial t} = \frac{\partial}{\partial t} \int_z p_t(x|z) p_1(z) dz \quad (\text{A.16})$$

然后将求导符号移入积分符号，其中 $p(z)$ 可以看做常数项

$$= \int_z \frac{\partial p_t(x|z)}{\partial t} p_1(z) dz \quad (\text{A.17})$$

偏导部分满足连续方程，可代入

$$= \int_z -\nabla \left(p_t(x|z) v_t^{\text{target}}(x|z) \right) p_1(z) dz \quad (\text{A.18})$$

因为散度计算是对 x 进行的，而这里的积分是对 z 进行的，所以可以将散度符号移到积分号外边

$$= -\nabla \left(\int_z p_t(x|z) v_t^{\text{target}}(x|z) p_1(z) dz \right) \quad (\text{A.19})$$

下一步在积分号外乘 $p_t(x)$ ，在积分号内除 $p_t(x)$ ，得到

$$= -\nabla \left(p_t(x) \int_z v_t^{\text{target}}(x|z) \frac{p_t(x|z) p_1(z)}{p_t(x)} dz \right) \quad (\text{A.20})$$

可以发现这里的积分项就是我们之前定义的边缘向量场公式，故上式为

$$= -\nabla \left(p_t(x) v_t^{\text{target}}(x) \right) \quad (\text{A.21})$$

证明完毕。 ■

故上述流匹配过程在未来预测上应满足连续性方程，从而保证了通过条件流匹配学习得到的边缘向量场的正确性。同时，可以保证自车和周车存在概率在宏观扩散过程中保持一致，即使原本集中的概率扩散到更宽阔的道路空间中以更低的概率存在。

A.2.2 Trailer-MEI 指标推导计算

目前一维替代安全指标（Surrogate Safty Index, SSI）如碰撞时间（Time to Collision, TTC）、车头时距（Time Head Way, THW）等仅在跟车情况下有效，不考虑车辆真实宽度与几何形状，对二维空间中的碰撞无法有效监测；而二维碰撞指标如 RTTC 虽考虑二维几何形状，对斜碰等问题可以探测，但计算过于乐观且不考虑不同撞击重叠面积风险的不同。Cheng 等震碎上述问题在 2024 年提出紧急因子（Emergency Index, EI）^[A.76] 安全评价指标，并在 2025 年进一步提出修正紧急因子（Modified Emergency Index, MEI）^[A.77]。

MEI 通过计算侵入距离 (InDepth) 来评估车辆最大的安全损失, 计算紧急操作时间 (Time for Emergency Manoeuvour, TEM) 即可用于规避风险的操作时间来衡量风险的紧急程度, 其定义为:

$$\text{MEI} = \frac{\text{InDepth}}{\text{TEM}} \quad (\text{A.22})$$

其中 InDepth 如图 A.4 所示, 定义为自车和周车都匀速直线运动的前提假设下, 将周车在未来无限时域内的空间位置投影在自车坐标系下以后, 自车轮廓与周车投影相交的最大距离。当沿着匀速直线运动可能发生碰撞时, InDepth 大于 0, 否则 InDepth 小于 0。TEM 定义为自车和周车都匀速直线运动的前提假设下, 两车轮廓




图 A.4 InDepth 概念描述

最早发生重叠的时间, 若不发生重叠则 $\text{TEM} = \infty$ 。

MEI 经过对比测试, 相比于现有二维 SSI 能够有效反映车辆实际风险, 且计算速度很快, 经过 C++ 编译后单次计算时间大约在 $6\mu\text{s} \sim 10\mu\text{s}$ 。但 MEI 仍存在问题, 如其匀速直线运动假设过强, 且针对如环岛等匀速恒定前轮转角的情况适用性较差, 以及针对本文而言, 其无法计算车辆中其一或全部为半挂车时的风险, 即只能针对两辆单车计算风险。为对包含挂车的车辆对 (Vehicle Pair) 计算 MEI 指标, 本文提出 Trailer-MEI 方法。

假设半挂车的牵引车部分匀速直线运动, 挂车后轴轨迹为曳物线 (tractix), 如图 A.5 所示, 设铰接角为 γ_g , 牵引车车速为 v_{1x} , 其解析形式可描述为式 (A.23) 到式 (A.25)。其中铰接角随时间变化为 $\gamma_g(t)$ 如式 (A.23) 所示, 则牵引车轨迹直线为式 (A.24), 挂车曳物线为式 (A.25)。

$$\gamma_g(t) = \pi - 2 \arctan \left(\tan \frac{\pi - \gamma_g}{2} e^{\frac{v_{1x} t}{L_g}} \right) \quad (\text{A.23})$$

$$x_{\text{tractor}}(t) = v_{1x} t + L_g \cos \gamma_g, \quad y_{\text{tractor}}(t) = L_g \sin \gamma_g \quad (\text{A.24})$$




图 A.5 挂车曳物线轨迹

$$x_{\text{trailer}}(t) = -L_g \left(\ln \left(\tan \frac{\gamma_g(t)}{2} + \cos \gamma_g(t) \right) \right) + L_g \left(\ln \left(\tan \frac{\gamma_g}{2} + \cos \gamma_g \right) \right) \quad (\text{A.25})$$

$$y_{\text{trailer}}(t) = -L_g (\sin \gamma_g(t) - \sin \gamma_g)$$

由于将曳物线根据相对自车车速投影到坐标系后并没有和直线相交的解析解存在, 故需采用数值方法进行近似。为计算在曳物线上距离均匀划分的采样点, 如图 A.6(a)所示, 采用对时间 t 进行均匀划分的方法, 得到 N_{pred} 个时间点 $t_1, t_2, \dots, t_{N_{\text{pred}}}$ 对应的角度 $\gamma_g(t)$, 从而可以计算出 N_{pred} 个挂车轮廓位置 $B_g^k, k \in \{1, 2, \dots, N_{\text{pred}}\}$ 。可包含半挂车的车辆对共有三种情况: 全无挂车、其一有挂车、两者都有挂车。对于第一种情况可以直接采用 MEI 进行计算; 对第二种情形, 假设 A 车为半挂车 B 车为单车, 需要计算 A 车牵引车与 B 车的 MEI, 以及利用离散的时间分别将平移后的 A 车挂车轮廓 $B_g^{k'}$ 与 B 车车头轮廓 B_{veh} 进行 N_{pred} 次碰撞检测与 InDepth 计算, InDepth 解析计算方法见^[A.77], 假设 t_k 时刻挂车发生碰撞, 则挂车与自车计算的等效 MEI 指标为 $\tilde{\text{MEI}} = \frac{\text{InDepth}}{t_k}$, 最终取 $\text{Trailer-MEI} = \max(\tilde{\text{MEI}}, \text{MEI})$; 对于第三种情况, 需要验证 A 车与 B 车车头的 MEI, 以及 A 车车头与 B 车挂车、B 车车头与 A 车挂车在第二种情况的 $\tilde{\text{MEI}}_1$ 和 $\tilde{\text{MEI}}_2$, 并分别对两车挂车在 N_{pred} 个时刻的绝对轮廓进行 InDepth 计算, 计算过程不再赘述, 最终取 4 者中最大者为此情况的 Trailer-MEI。

在最坏情况, 即需计算 SSI 的车辆都为半挂车时, Trailer-MEI 指标的计算时间仅为 MEI 的 6 倍, C++ 编译后单次计算时间大约在 $30 \mu\text{s} \sim 50 \mu\text{s}$, 在实现半挂车计算的同时计算时间依然可以忽略。本文为平衡精度与计算速度, 计算 Trailer-MEI 指标采用的离散步长 $\Delta t = 0.2 \text{ s}$, 预测时域为 5 s。

A.2.3 无模型自适应滑模残差补偿

第??小节构建的多约束模型预测控制基础控制器的基本要求在于预测模型的准确性, 而这一点在实际行驶过程中由于载荷变化、零部件老化、标定测量误差等原因通常难以绝对保障, 对基础模型进行补偿是模型预测方法跨入真正实用的




图 A.6 包含挂车的计算示意

重要部分^[A.78]。本小节在基础控制器上进一步建立基于广义跟踪误差控制车轮转角和/或各车轮驱/制动力的补偿控制器。广义跟踪误差为牵引车实际轨迹与最优控制下的预测轨迹之间的误差；补偿控制器为无模型自适应滑模控制器，以广义跟踪误差为输入量 $\mathbf{y}$ ，并采用全格式动态线性化。下面进行详细说明。




图 A.7 无模型自适应滑模残差补偿控制器结构

定义 MIMO 非线性系统如下

$$\mathbf{y}(k+1) = \mathbf{f}(\mathbf{y}(k), \dots, \mathbf{y}(k-n_y), \mathbf{u}(k), \dots, \mathbf{u}(k-n_u)) \quad (\text{A.26})$$

式中 $\mathbf{f}(\cdot)$ 为未知的非线性函数， n_y 和 n_u 分别为系统控制和输入的真实阶数， $\mathbf{y}(k) \in \mathbb{R}^{N_y}$ ， $\mathbf{u}(k) \in \mathbb{R}^{N_u}$ 分别为 k 时刻的系统输出和输入， $N_u \geq N_y$ 。由于系统的实际阶数可能很高，为简化模型设置两个固定的伪阶数 L_y 和 L_u ($1 \leq L_y \leq n_y$, $1 \leq L_u \leq n_u$)

来代表实际阶数，维护一个固定窗口内的信息向量：

$$\mathbf{H}_{L_y, L_u}(k) = \begin{bmatrix} \mathbf{y}(k) \\ \vdots \\ \mathbf{y}(k - L_y + 1) \\ \mathbf{u}(k) \\ \vdots \\ \mathbf{u}(k - L_u + 1) \end{bmatrix} \in \mathbb{R}^{N_y L_y + N_u L_u} \quad (\text{A.27})$$

对于 MIMO 系统，首先需要定义两个前提条件：①除有限时刻点外， $\mathbf{f}(\cdot)$ 对于控制变量的偏导数连续；（一般非线性控制的典型约束条件）②广义 Lipschitz 条件：对任意 $k_1 \neq k_2$, $k_1, k_2 \geq 0$ ，以及 $\mathbf{H}_{L_y, L_u}(k_1) \neq \mathbf{H}_{L_y, L_u}(k_2)$ ，有

$$\|\mathbf{y}(k_1 + 1) - \mathbf{y}(k_2 + 1)\| \leq b \left\| \mathbf{H}_{L_y, L_u}(k_1) - \mathbf{H}_{L_y, L_u}(k_2) \right\| \quad (\text{A.28})$$

其中 $b > 0$ 为常数。（信息向量的有限变化不能引起系统输出的无限增长）^[A.79]。

第一个条件是控制系统设计中一般非线性控制的典型约束，第二个条件是对系统输出变化率上界的一种限制，上述两个条件一般的非线性系统都可以满足。

给定正整数伪阶数 L_y 和 L_u ，当 $\mathbf{H}_{L_y, L_u}(k) \neq 0$ 时，一定存在一个时变的分块伪 Jacobian 矩阵（PPJM）或者叫作伪梯度 $\Phi_{f, L_y, L_u}(k)$ ，使得被控系统能够转化为如下三种数据模型之一（动态线性化模型，Dynamic Linearization, DL）：

全格式（Full Form DL, FFDL）：包含所有历史信息和高阶动态，建模精度高但伪梯度维度高导致计算量较大，对实时性要求较高的系统可能存在延迟风险，适用于复杂慢时变系统。

$$\Delta \mathbf{y}(k + 1) = \Phi_{f, L_y, L_u}(k) \Delta \mathbf{H}_{L_y, L_u}(k) \quad (\text{A.29})$$

偏格式（Partial Form DL, PFDL）：包含部分历史信息和动态，考虑了系统的记忆特性（如惯性和滞后），计算复杂度适中，可以建模适于中等复杂度系统。

$$\mathbf{y}(k + 1) = \mathbf{y}(k) + \Phi_{p, L_u}(k) \Delta \mathbf{H}_{L_u}(k) \quad (\text{A.30})$$

紧格式（Compact Form DL, CFDL）：不包含历史信息，仅将系统输出变化直接与当前输入变化想光，忽略中间状态变量，形式最为简洁，适用于简单系统。

$$\Delta \mathbf{y}(k + 1) = \phi(k) \Delta \mathbf{u}(k) \quad (\text{A.31})$$

表 A.1 三种动态线性化方法对比

形式	伪梯度维度	历史数据依赖	精度	复杂度	适用场景
紧格式 (CF)	低维向量/标量	无/极少	低	低	简单系统实时性要求高
偏格式 (PF)	中维向量	部分历史数据	中	中	中等动态复杂系统
全格式 (FF)	高维向量	全部历史数据	高	高	复杂慢时变系统

其中

$$\Delta \mathbf{H}_{L_y, L_u}(k) = \mathbf{H}_{L_y, L_u}(k) - \mathbf{H}_{L_y, L_u}(k-1) = \begin{bmatrix} \Delta \mathbf{y}(k) \\ \vdots \\ \Delta \mathbf{y}(k - L_y + 1) \\ \Delta \mathbf{u}(k) \\ \vdots \\ \Delta \mathbf{u}(k - L_u + 1) \end{bmatrix} \quad (\text{A.32})$$

$$\Phi_{f, L_y, L_u}(k)_{N_y \times (N_y L_y + N_u L_u)} = [\phi_1(k) \cdots \phi_{L_y}(k) \phi_{L_y+1}(k) \cdots \phi_{L_y+L_u}(k)] \quad (\text{A.33})$$

其中

$$\phi_i(k) = \begin{bmatrix} \varphi_{i,11}(k) & \varphi_{i,12}(k) & \cdots & \varphi_{i,1N_y}(k) \\ \varphi_{i,21}(k) & \varphi_{i,22}(k) & \cdots & \varphi_{i,2N_y}(k) \\ \vdots & \vdots & \ddots & \vdots \\ \varphi_{i,N_y1}(k) & \varphi_{i,N_y2}(k) & \cdots & \varphi_{i,N_yN_y}(k) \end{bmatrix} \in \mathbb{R}^{N_y \times N_y}, i = 1, \dots, L_y \quad (\text{A.34})$$

$$\phi_j(k) = \begin{bmatrix} \varphi_{j,11}(k) & \varphi_{j,12}(k) & \cdots & \varphi_{j,1N_u}(k) \\ \varphi_{j,21}(k) & \varphi_{j,22}(k) & \cdots & \varphi_{j,2N_u}(k) \\ \vdots & \vdots & \ddots & \vdots \\ \varphi_{j,N_y1}(k) & \varphi_{j,N_y2}(k) & \cdots & \varphi_{j,N_yN_u}(k) \end{bmatrix} \in \mathbb{R}^{N_y \times N_u}, j = L_y + 1, \dots, L_y + L_u \quad (\text{A.35})$$

MFAC 基础算法与相关符号说明见附录A.2.4小节，本小节在此基础上进一步设计 MFASMC 控制算法，将 MFAC 与滑模控制结合，前者无需第一性原理模型，后者响应速度快、抗扰动性能强。

定义输出误差：

$$\mathbf{e}(k) = \mathbf{y}^*(k) - \mathbf{y}(k) \quad (\text{A.36})$$

设计一个线性滑模面：

$$\mathbf{s}(k) = \Lambda \mathbf{e}(k) \quad (\text{A.37})$$

其中 $\mathbf{A}$ 是正定矩阵，一般是正定对角阵用于加权各个滑模面。

$$\begin{aligned} \mathbf{s}(k+1) &= \mathbf{A}\mathbf{e}(k+1) = \mathbf{A} \left(\mathbf{y}^*(k+1) - \mathbf{y}(k) - \boldsymbol{\Phi}_{f,L_y,L_u}(k) \Delta \mathbf{H}_{L_y,L_u}(k) \right) \\ &= \mathbf{A} \left(\mathbf{y}^*(k+1) - \mathbf{y}(k) - \sum_{i=1}^{L_y} \boldsymbol{\phi}_i(k) \Delta \mathbf{y}(k-i+1) - \sum_{i=2}^{L_u} \boldsymbol{\phi}_{i+L_y}(k) \Delta \mathbf{u}(k-i+1) \right) - \mathbf{A} \boldsymbol{\phi}_{L_y+1}(k) \Delta \mathbf{u}(k) \end{aligned} \quad (\text{A.38})$$

设计或选择一个趋近律，比如等速趋近律：（其中 $\mathbf{E} \in \mathbb{S}^{++}$ ）

$$\dot{\mathbf{s}} = -\mathbf{E} \text{sgn}(\mathbf{s}) \quad (\text{A.39})$$

$$\mathbf{s}(k+1) = \mathbf{s}(k) - T \mathbf{E} \text{sgn}(\mathbf{s}(k)) \quad (\text{A.40})$$

指数趋近律：（其中 $\mathbf{E} \in \mathbb{S}^{++}, \mathbf{K} \in \mathbb{S}^{++}$ ）

$$\dot{\mathbf{s}} = -\mathbf{E} \text{sgn}(\mathbf{s}) - \mathbf{K} \mathbf{s} \quad (\text{A.41})$$

$$\mathbf{s}(k+1) = (\mathbf{I} - T \mathbf{K}) \mathbf{s}(k) - T \mathbf{E} \text{sgn}(\mathbf{s}(k)) \quad (\text{A.42})$$

幂次趋近律：（其中 $\mathbf{E} \in \mathbb{S}^{++}, \mathbf{K} \in \mathbb{S}^{++}, \alpha > 0$ ）

$$\dot{\mathbf{s}} = -(\mathbf{E} + \mathbf{K} \text{diag}(|\mathbf{s}|^\alpha)) \text{sgn}(\mathbf{s}) \quad (\text{A.43})$$

$$\mathbf{s}(k+1) = \mathbf{s}(k) - T (\mathbf{E} + \mathbf{K} \text{diag}(|\mathbf{s}(k)|^\alpha)) \text{sgn}(\mathbf{s}(k)) \quad (\text{A.44})$$

这里选取指数趋近律（A.42）与（A.38）联立可以求解出滑模控制意义下的控制量增量

$$\Delta \mathbf{u}(k) = \boldsymbol{\phi}_{L_y+1}^\dagger(k) \begin{pmatrix} \mathbf{y}^*(k+1) - \mathbf{y}(k) - \sum_{i=1}^{L_y} \boldsymbol{\phi}_i(k) \Delta \mathbf{y}(k-i+1) - \sum_{i=2}^{L_u} \boldsymbol{\phi}_{i+L_y}(k) \Delta \mathbf{u}(k-i+1) \\ -\mathbf{A}^{-1}(\mathbf{I} - T \mathbf{K}) \mathbf{s}(k) + T \mathbf{A}^{-1} \mathbf{E} \text{sgn}(\mathbf{s}(k)) \end{pmatrix} \quad (\text{A.45})$$

其中

$$\boldsymbol{\phi}_{L_y+1}^\dagger(k) = \left(\boldsymbol{\phi}_{L_y+1}^T(k) \boldsymbol{\phi}_{L_y+1}(k) \right)^{-1} \boldsymbol{\phi}_{L_y+1}^T(k) \quad (\text{A.46})$$

设计一个一阶的线性滑模面

$$\mathbf{s}(k) = \mathbf{A}\mathbf{e}(k) + \dot{\mathbf{e}}(k) = \left(\frac{1}{T} \mathbf{I} + \mathbf{A} \right) \mathbf{e}(k) - \frac{1}{T} \mathbf{e}(k-1) = \mathbf{A}\mathbf{e}(k) - \frac{1}{T} \mathbf{e}(k-1) \quad (\text{A.47})$$

这里用欧拉前向离散化展开误差随时间的导数。

$$\begin{aligned}
 s(k+1) &= \left(\frac{1}{T} \mathbf{I} + \mathbf{A} \right) \mathbf{e}(k+1) - \frac{1}{T} \mathbf{e}(k) \\
 &= \mathbf{A} \left(\mathbf{y}^*(k+1) - \mathbf{y}(k) - \boldsymbol{\Phi}_{f,L_y,L_u}(k) \Delta \mathbf{H}_{L_y,L_u}(k) \right) \\
 &\quad - \frac{1}{T} \left(\mathbf{y}^*(k) - \mathbf{y}(k-1) - \boldsymbol{\Phi}_{f,L_y,L_u}(k-1) \Delta \mathbf{H}_{L_y,L_u}(k-1) \right) \\
 &= \mathbf{A} \left(\mathbf{y}^*(k+1) - \mathbf{y}(k) - \sum_{i=1}^{L_y} \boldsymbol{\phi}_i(k) \Delta \mathbf{y}(k-i+1) - \sum_{i=2}^{L_u} \boldsymbol{\phi}_{i+L_y}(k) \Delta \mathbf{u}(k-i+1) \right) \\
 &\quad - \frac{1}{T} \left(\mathbf{y}^*(k) - \mathbf{y}(k-1) - \sum_{i=1}^{L_y} \boldsymbol{\phi}_i(k-1) \Delta \mathbf{y}(k-i) - \sum_{i=2}^{L_u} \boldsymbol{\phi}_{i+L_y}(k-1) \Delta \mathbf{u}(k-i) \right) \\
 &\quad - \mathbf{A} \boldsymbol{\phi}_{L_y+1}(k) \Delta \mathbf{u}(k) + \frac{1}{T} \boldsymbol{\phi}_{L_y+1}(k-1) \Delta \mathbf{u}(k-1)
 \end{aligned} \tag{A.48}$$

令向量函数

$$\mathbf{f}(k) = \mathbf{y}^*(k+1) - \mathbf{y}(k) - \sum_{i=1}^{L_y} \boldsymbol{\phi}_i(k) \Delta \mathbf{y}(k-i+1) - \sum_{i=2}^{L_u} \boldsymbol{\phi}_{i+L_y}(k) \Delta \mathbf{u}(k-i+1) \tag{A.49}$$

$$\mathbf{h}(k) = \boldsymbol{\phi}_{L_y+1}(k) \Delta \mathbf{u}(k) \tag{A.50}$$

则式 (A.48) 可以进一步化简并利用动态规划的思想进行计算, 利用上一控制周期已经算过并存储的 $\mathbf{f}(k-1)$ 和 $\mathbf{h}(k-1)$ 来加快计算

$$\mathbf{s}(k+1) = \mathbf{A} \mathbf{f}(k) - \frac{1}{T} \mathbf{f}(k-1) - \mathbf{A} \boldsymbol{\phi}_{L_y+1}(k) \Delta \mathbf{u}(k) + \frac{1}{T} \boldsymbol{\phi}_{L_y+1}(k-1) \Delta \mathbf{u}(k-1) \tag{A.51}$$

同样选取指数趋近律 (A.42) 与 (A.51) 联立可以求解出滑模控制意义下的控制量增量

$$\Delta \mathbf{u}(k) = \boldsymbol{\phi}_{L_y+1}^\dagger(k) \mathbf{A}^{-1} \left(\mathbf{A} \mathbf{f}(k) - \frac{1}{T} \mathbf{f}(k-1) + \frac{1}{T} \mathbf{h}(k-1) - (\mathbf{I} - T \mathbf{K}) \mathbf{s}(k) + T \mathbf{E} \text{sgn}(\mathbf{s}(k)) \right) \tag{A.52}$$

A.2.4 MFAC 基础算法推导与符号说明

本节介绍 MFAC 算法的推导过程及相关符号说明, 以便读者更好理解正文中 MAFSMC 算法的推导。MFAC 算法定义了如下目标函数:

$$J(\mathbf{u}(k)) = \|\mathbf{y}^*(k+1) - \mathbf{y}(k+1)\|^2 + \lambda \|\mathbf{u}(k) - \mathbf{u}(k-1)\|^2 \tag{A.53}$$

式中 $\mathbf{y}^*(k+1)$ 为 $k+1$ 时刻的期望输出, $\mathbf{y}(k+1)$ 为 $k+1$ 时刻的实际输出, $\lambda > 0$ 为权重因子。

算法 A.1 MFAC-FFDL-SMC 全格式动态线性化无模型自适应滑模控制

输入: 系统期望输出序列 $\{y^*(k)\}$, 系统实际输出序列 $\{y(k)\}$, 伪阶数 L_y, L_u , 超参数 $\rho_1, \dots, \rho_{L_y+L_u}, \mu, \lambda, \eta$, 正定矩阵 $\mathbf{A}, \mathbf{E}, \mathbf{K}$, 采样时间 T

输出: 系统控制量序列 $\{u(k)\}$

初始化参数: $\Delta \mathbf{H}_{L_y, L_u}(0), \Phi_{f, L_y, L_u}(0), \mathbf{f}(0), \mathbf{h}(0)$

初始化超参数: $\rho_1, \dots, \rho_{L_y+L_u}, \mu, \lambda, \eta, \mathbf{A}, \mathbf{E}, \mathbf{K}, T$

while 系统运行 **do**

 估计伪梯度

$$\Delta \mathbf{H}_{L_y, L_u}(k-1) = \mathbf{H}_{L_y, L_u}(k-1) - \mathbf{H}_{L_y, L_u}(k-2)$$

$$\Phi_{f, L_y, L_u}(k) = \left(1 - \eta \frac{\|\Delta \mathbf{H}_{L_y, L_u}(k-1)\|^2}{\mu + \|\Delta \mathbf{H}_{L_y, L_u}(k-1)\|^2} \right) \Phi_{f, L_y, L_u}(k-1) + \eta \frac{(\mathbf{y}(k) - \mathbf{y}(k-1)) \Delta \mathbf{H}_{L_y, L_u}(k-1)^T}{\mu + \|\Delta \mathbf{H}_{L_y, L_u}(k-1)\|^2}$$

$$\Phi_{f, L_y, L_u}(k) = \text{selectiveReset}(\Phi_{f, L_y, L_u}(k)) \text{ \{按需重置伪梯度矩阵元素\}}$$

 计算控制量

$$\mathbf{e}(k) = \mathbf{y}^*(k) - \mathbf{y}(k) \text{ \{输出误差\}}$$

$$\mathbf{s}(k) = \mathbf{A}\mathbf{e}(k) - \frac{1}{T}\mathbf{e}(k-1) \text{ \{一阶线性滑模面\}}$$

$$\mathbf{s}(k+1) = (\mathbf{I} - T\mathbf{K})\mathbf{s}(k) - T\mathbf{E}\text{sgn}(\mathbf{s}(k)) \text{ \{指数趋近律\}}$$

$$\mathbf{f}(k) = \mathbf{y}^*(k+1) - \mathbf{y}(k) - \sum_{i=1}^{L_y} \phi_i(k) \Delta \mathbf{y}(k-i+1) - \sum_{i=2}^{L_u} \phi_{i+L_y}(k) \Delta \mathbf{u}(k-i+1) \text{ \{预计算向量函数\}}$$

$$\phi_{L_y+1}^\dagger(k) = \left(\phi_{L_y+1}(k)^T \phi_{L_y+1}(k) \right)^{-1} \phi_{L_y+1}(k)^T \text{ \{伪逆矩阵\}}$$

$$\Delta \mathbf{u}(k) = \phi_{L_y+1}^\dagger(k) \left(\mathbf{f}(k) - \mathbf{A}^{-1} \left(\frac{1}{T} \mathbf{f}(k-1) - \frac{1}{T} \mathbf{h}(k-1) + \mathbf{s}(k+1) \right) \right) \text{ \{控制增量\}}$$

$$\mathbf{u}(k) = \mathbf{u}(k-1) + \Delta \mathbf{u}(k) \text{ \{更新控制量\}}$$

$$\mathbf{h}(k) = \phi_{L_y+1}(k) \Delta \mathbf{u}(k) \text{ \{存储中间量用于下一周期\}}$$

end while

将全格式的式 (A.29) 带入式 (A.53) 中

$$J(\mathbf{u}(k)) = \left\| \mathbf{y}^*(k+1) - \mathbf{y}(k) - \Phi_{f, L_y, L_u}(k) \Delta \mathbf{H}_{L_y, L_u}(k) \right\|^2 + \lambda \|\mathbf{u}(k) - \mathbf{u}(k-1)\|^2 \quad (\text{A.54})$$

由于

$$\begin{aligned} \Phi_{f, L_y, L_u}(k) \Delta \mathbf{H}_{L_y, L_u}(k) &= \begin{bmatrix} \phi_1(k) & \cdots & \phi_{L_y}(k) & \phi_{L_y+1}(k) & \cdots & \phi_{L_y+L_u}(k) \end{bmatrix} \begin{bmatrix} \Delta \mathbf{y}(k) \\ \vdots \\ \Delta \mathbf{y}(k-L_y+1) \\ \Delta \mathbf{u}(k) \\ \vdots \\ \Delta \mathbf{u}(k-L_u+1) \end{bmatrix} \\ &= \phi_1(k) \Delta \mathbf{y}(k) + \cdots + \phi_{L_y}(k) \Delta \mathbf{y}(k-L_y+1) \\ &\quad + \phi_{L_y+1}(k) \Delta \mathbf{u}(k) + \phi_{L_y+L_u}(k) \Delta \mathbf{u}(k-L_u+1) \\ &= \sum_{i=1}^{L_y} \phi_i(k) \Delta \mathbf{y}(k-i+1) + \sum_{i=1}^{L_u} \phi_{i+L_y}(k) \Delta \mathbf{u}(k-i+1) \end{aligned} \quad (\text{A.55})$$

将式 (A.54) 对 $\mathbf{u}(k)$ 求偏导数, 并令其等于 0,

$$\frac{\partial J(\mathbf{u}(k))}{\partial \mathbf{u}(k)} = 2\boldsymbol{\phi}_{L_y+1}^T(k) \left(\mathbf{y}^*(k+1) - \mathbf{y}(k) - \boldsymbol{\Phi}_{f,L_y,L_u}(k) \Delta \mathbf{H}_{L_y,L_u}(k) \right) - 2\lambda(\mathbf{u}(k) - \mathbf{u}(k-1)) = 0 \quad (\text{A.56})$$

$$\begin{aligned} & \boldsymbol{\phi}_{L_y+1}^T(k) \left(\mathbf{y}^*(k+1) - \mathbf{y}(k) - \sum_{i=1}^{L_y} \boldsymbol{\phi}_i(k) \Delta \mathbf{y}(k-i+1) - \sum_{i=2}^{L_u} \boldsymbol{\phi}_{i+L_y}(k) \Delta \mathbf{u}(k-i+1) \right) \\ & - \boldsymbol{\phi}_{L_y+1}^T(k) \boldsymbol{\phi}_{L_y+1}(k) \Delta \mathbf{u}(k) - \lambda \Delta \mathbf{u}(k) = 0 \end{aligned} \quad (\text{A.57})$$

定义 $\mathbf{e}(k+1) = \mathbf{y}^*(k+1) - \mathbf{y}(k)$, 则

$$\Delta \mathbf{u}(k) = \frac{\boldsymbol{\phi}_{L_y+1}^T(k) \left(\mathbf{e}(k+1) - \sum_{i=1}^{L_y} \boldsymbol{\phi}_i(k) \Delta \mathbf{y}(k-i+1) - \sum_{i=2}^{L_u} \boldsymbol{\phi}_{i+L_y}(k) \Delta \mathbf{u}(k-i+1) \right)}{\boldsymbol{\phi}_{L_y+1}^T(k) \boldsymbol{\phi}_{L_y+1}(k) + \lambda} \quad (\text{A.58})$$

其中分母之一的 $\boldsymbol{\phi}_{L_y+1}^T(k) \boldsymbol{\phi}_{L_y+1}(k) \in \mathbb{R}^{N_u \times N_u}$, 为了提供更高的设计自由度, 引入权重参数 $\rho_i \in (0, 1], i = 1, \dots, L_y, L_y+1, \dots, L_y+L_u$, 得到最终控制量更新形式 (控制律):

$$\begin{aligned} \mathbf{u}(k) = \mathbf{u}(k-1) & + \frac{\rho_{L_y+1} \boldsymbol{\phi}_{L_y+1}^T(k) (\mathbf{y}^*(k+1) - \mathbf{y}(k))}{\boldsymbol{\phi}_{L_y+1}^T(k) \boldsymbol{\phi}_{L_y+1}(k) + \lambda} \\ & - \frac{\boldsymbol{\phi}_{L_y+1}^T(k) \left(\sum_{i=1}^{L_y} \rho_i \boldsymbol{\phi}_i(k) \Delta \mathbf{y}(k-i+1) + \sum_{i=2}^{L_u} \rho_{i+L_y} \boldsymbol{\phi}_{i+L_y}(k) \Delta \mathbf{u}(k-i+1) \right)}{\boldsymbol{\phi}_{L_y+1}^T(k) \boldsymbol{\phi}_{L_y+1}(k) + \lambda} \end{aligned} \quad (\text{A.59})$$

为实现控制算法, 需要知道伪梯度的值, 我们需要根据系统的输入输出对其进行估计。考虑如下伪梯度估计的准则函数:

$$\begin{aligned} J(\boldsymbol{\Phi}_{f,L_y,L_u}(k)) & = \left\| \mathbf{y}(k) - \mathbf{y}(k-1) - \boldsymbol{\Phi}_{f,L_y,L_u}(k) \Delta \mathbf{H}_{L_y,L_u}(k-1) \right\|^2 \\ & + \mu \left\| \boldsymbol{\Phi}_{f,L_y,L_u}(k) - \boldsymbol{\Phi}_{f,L_y,L_u}(k-1) \right\|^2 \end{aligned} \quad (\text{A.60})$$

其中 $\mu > 0$ 是权重因子。对上式关于 $\boldsymbol{\Phi}_{f,L_y,L_u}(k)$ 求导数并令其为零可得到 $\boldsymbol{\Phi}_{f,L_y,L_u}(k)$ 的估计算法为

$$\begin{aligned} \frac{\partial J(\boldsymbol{\Phi}_{f,L_y,L_u}(k))}{\partial \boldsymbol{\Phi}_{f,L_y,L_u}(k)} & = -2 \left(\mathbf{y}(k) - \mathbf{y}(k-1) - \boldsymbol{\Phi}_{f,L_y,L_u}(k) \Delta \mathbf{H}_{L_y,L_u}(k-1) \right) \Delta \mathbf{H}_{L_y,L_u}^T(k-1) \\ & + 2\mu \left(2\boldsymbol{\Phi}_{f,L_y,L_u}(k) - \boldsymbol{\Phi}_{f,L_y,L_u}(k-1) \right) = 0 \end{aligned} \quad (\text{A.61})$$

$$\begin{aligned} \mu \Phi_{f,L_y,L_u}(k) - \mu \Phi_{f,L_y,L_u}(k-1) &= (\mathbf{y}(k) - \mathbf{y}(k-1)) \Delta \mathbf{H}_{L_y,L_u}^T(k-1) \\ &\quad - \Phi_{f,L_y,L_u}(k) \Delta \mathbf{H}_{L_y,L_u}(k-1) \Delta \mathbf{H}_{L_y,L_u}^T(k-1) \end{aligned} \quad (\text{A.62})$$

$$\left(\mu + \left\| \Delta \mathbf{H}_{L_y,L_u}(k-1) \right\|^2 \right) \Phi_{f,L_y,L_u}(k) = (\mathbf{y}(k) - \mathbf{y}(k-1)) \Delta \mathbf{H}_{L_y,L_u}^T(k-1) + \mu \Phi_{f,L_y,L_u}(k-1) \quad (\text{A.63})$$

进一步化简得到

$$\begin{aligned} \Phi_{f,L_y,L_u}(k) &= \frac{(\mathbf{y}(k) - \mathbf{y}(k-1)) \Delta \mathbf{H}_{L_y,L_u}^T(k-1) + \mu \Phi_{f,L_y,L_u}(k-1)}{\mu + \left\| \Delta \mathbf{H}_{L_y,L_u}(k-1) \right\|^2} \\ &= \Phi_{f,L_y,L_u}(k-1) + \frac{(\mathbf{y}(k) - \mathbf{y}(k-1)) \Delta \mathbf{H}_{L_y,L_u}^T(k-1)}{\mu + \left\| \Delta \mathbf{H}_{L_y,L_u}(k-1) \right\|^2} - \frac{\left\| \Delta \mathbf{H}_{L_y,L_u}(k-1) \right\|^2 \Phi_{f,L_y,L_u}(k-1)}{\mu + \left\| \Delta \mathbf{H}_{L_y,L_u}(k-1) \right\|^2} \\ &\approx \left(1 - \frac{\eta \left\| \Delta \mathbf{H}_{L_y,L_u}(k-1) \right\|^2}{\mu + \left\| \Delta \mathbf{H}_{L_y,L_u}(k-1) \right\|^2} \right) \Phi_{f,L_y,L_u}(k-1) + \eta \frac{(\mathbf{y}(k) - \mathbf{y}(k-1)) \Delta \mathbf{H}_{L_y,L_u}^T(k-1)}{\mu + \left\| \Delta \mathbf{H}_{L_y,L_u}(k-1) \right\|^2} \end{aligned} \quad (\text{A.64})$$

加入了步长因子 $\eta \in (0, 2]$ 是为了使算法具有更高的灵活性。

为了使得具有更加优秀的对时变参数的跟踪能力，引入了对 Φ_{L_y+1} 系数的重置。我们通过式 (A.34) 的分析可知， Φ_{L_y+1} 是一个 $N_y \times N_u$ 的伪梯度块矩阵。对于其对角线元素 $\varphi_{L_y+1,pp}$ (其中 $p = 1, \dots, \min(N_y, N_u)$)，太小或者过大或变号都需要被重置：

$$\varphi_{L_y+1,pp}(k) = \varphi_{L_y+1,pp}(0) \quad (\text{A.65})$$

$$\text{if } \left| \varphi_{L_y+1,pp}(k) \right| < \epsilon \text{ or } \left| \varphi_{L_y+1,pp}(k) \right| > b_1 \text{ or } \text{sgn} \left(\varphi_{L_y+1,pp}(k) \right) \neq \text{sgn} \left(\varphi_{L_y+1,pp}(0) \right) \quad (\text{A.66})$$

对于其非对角线元素 $\varphi_{L_y+1,pq}$ (其中 $p = 1, \dots, N_y, q = 1, \dots, N_u, p \neq q$)，过大或变号都需要被重置：

$$\varphi_{L_y+1,pq}(k) = \varphi_{L_y+1,pq}(0) \quad (\text{A.67})$$

$$\text{if } \left| \varphi_{L_y+1,pq}(k) \right| > b_2 \text{ or } \text{sgn} \left(\varphi_{L_y+1,pq}(k) \right) \neq \text{sgn} \left(\varphi_{L_y+1,pq}(0) \right) \quad (\text{A.68})$$

A.2.5 控制器嵌套方法

本研究提出的控制器嵌套 (Controller Nesting, CN) 是一种将算法用于辅助驾驶的控制框架, 其应用需要满足两个前提条件: 1) 存在至少一个控制器 $C_1: \mathcal{X} \rightarrow \mathcal{U}$, 使得闭环系统 $\dot{\mathbf{x}} = f(\mathbf{x}, C_1(\mathbf{x}))$ 在状态空间 $\mathcal{X} \subseteq \mathbb{R}^n$ 内满足李雅普诺夫稳定; 2) 嵌套控制器 $C_2: \mathcal{X} \rightarrow \mathcal{U}$ 与基础控制器 C_1 的输出空间 $\mathcal{U} \subseteq \mathbb{R}^m$ 及约束集 $\mathcal{U}_{\text{con}} \subseteq \mathcal{U}$ 完全一致。

在满足上述前提的基础上, 控制器嵌套的核心思想是: 对基础控制器 C_1 的迭代可行域 $\mathcal{X}_1 \subseteq \mathcal{X}$, 引入稳定性余量 $\mathcal{M}_2 \subseteq \mathcal{X} \setminus \mathcal{X}_1$ 以保障系统全局稳定; 剩余状态空间 $\mathcal{X}_3 = \mathcal{X} \setminus (\mathcal{X}_1 \cup \mathcal{M}_2)$ 用于嵌套控制器 C_2 , 此时嵌套控制器的输出为 $C_{\text{CN}}(\mathbf{x}) = \alpha(\mathbf{x})C_1(\mathbf{x}) + (1 - \alpha(\mathbf{x}))C_2(\mathbf{x})$, 其中 $\alpha: \mathcal{X} \rightarrow [0, 1]$ 为状态依赖的加权系数, 满足 $\alpha(\mathbf{x}) = 1, \forall \mathbf{x} \in \mathcal{X}_1 \cup \mathcal{M}_2$, $\alpha(\mathbf{x}) \in (0, 1), \forall \mathbf{x} \in \mathcal{X}_3$ 。

如图 A.8 所示, 状态空间 $\mathcal{X}$ 被划分为三类子区域: - $\mathcal{X}_1$: 标称可行且稳定的核心区域; - $\mathcal{X}_2 = \mathcal{X}_1 \cup \mathcal{M}_1 \cup \mathcal{M}_2$: 实际可行且稳定的扩展区域, 其中 $\mathcal{M}_1 \subseteq \mathcal{X}$ 为模型误差补偿余量; - $\mathcal{X}_3$: C_1 与 C_2 输出线性组合的过渡区域。




图 A.8 控制器嵌套方法的状态空间划分

定理 A.2 (控制器嵌套的稳定性): 设车辆闭环系统为 $\dot{\mathbf{x}} = f(\mathbf{x}, u)$, 其中 $\mathbf{x} \in \mathcal{X} \subseteq \mathbb{R}^n$ 为系统状态, $u \in \mathcal{U} \subseteq \mathbb{R}^m$ 为控制输入, $f: \mathcal{X} \times \mathcal{U} \rightarrow \mathbb{R}^n$ 满足局部利普希茨连续。若: 1) 基础控制器 C_1 使得闭环系统 $\dot{\mathbf{x}} = f(\mathbf{x}, C_1(\mathbf{x}))$ 在 $\mathcal{X}_2$ 内李雅普诺夫稳定, 即存在李雅普诺夫函数 $V: \mathcal{X}_2 \rightarrow \mathbb{R}_{\geq 0}$, 满足 $\dot{V}(\mathbf{x}) = \nabla V(\mathbf{x})^T f(\mathbf{x}, C_1(\mathbf{x})) \leq 0, \forall \mathbf{x} \in \mathcal{X}_2$; 2) 加权系数 $\alpha(\mathbf{x})$ 在 $\mathcal{X}$ 上连续, 且 $\alpha(\mathbf{x}) = 1, \forall \mathbf{x} \in \mathcal{X}_2$; 则: a) 嵌套控制器 C_{CN} 下的闭环系统 $\dot{\mathbf{x}} = f(\mathbf{x}, C_{\text{CN}}(\mathbf{x}))$ 在 $\mathcal{X}$ 内李雅普诺夫稳定; b) 当且仅当 C_2 使得 $\dot{V}(\mathbf{x}) = \nabla V(\mathbf{x})^T f(\mathbf{x}, C_2(\mathbf{x})) < 0, \forall \mathbf{x} \in \mathcal{X}_3 \setminus \{\mathbf{x}^*\}$ ($\mathbf{x}^*$ 为系统平衡点) 时, C_{CN} 下的系统在 $\mathcal{X}$ 内渐进稳定。

证明 步骤 1: 证明李雅普诺夫稳定性 (结论 a) 由前提条件, C_1 对应的闭环系统

在 $\mathcal{X}_2$ 内存在李雅普诺夫函数 $V(\mathbf{x})$ ，满足：

$$\dot{V}(\mathbf{x}) = \nabla V(\mathbf{x})^T f(\mathbf{x}, C_1(\mathbf{x})) \leq 0, \forall \mathbf{x} \in \mathcal{X}_2.$$

对于 $\mathcal{X}_3$ 区域，嵌套控制器输出为 $C_{\text{CN}}(\mathbf{x}) = \alpha C_1 + (1 - \alpha)C_2$ ，其中 $\alpha \in (0, 1)$ 。由于 $f(\mathbf{x}, u)$ 满足局部利普希茨连续，且 C_1, C_2 的输出均属于约束集 $\mathcal{U}_{\text{con}}$ ，则 $f(\mathbf{x}, C_{\text{CN}}(\mathbf{x}))$ 可表示为：

$$f(\mathbf{x}, C_{\text{CN}}(\mathbf{x})) = \alpha f(\mathbf{x}, C_1) + (1 - \alpha)f(\mathbf{x}, C_2).$$

因此，李雅普诺夫函数的导数为：

$$\dot{V}(\mathbf{x}) = \alpha \nabla V^T f(\mathbf{x}, C_1) + (1 - \alpha) \nabla V^T f(\mathbf{x}, C_2).$$

结合 $\alpha \in (0, 1)$ 且 $\nabla V^T f(\mathbf{x}, C_1) \leq 0$ ，同时 $\mathcal{M}_1$ 补偿了模型误差，使得 $\nabla V^T f(\mathbf{x}, C_2)$ 在 $\mathcal{X}_3$ 内有界且非正（ $\nabla V^T f(\mathbf{x}, C_2) \leq K, K < +\infty$ ），故 $\dot{V}(\mathbf{x}) \leq 0, \forall \mathbf{x} \in \mathcal{X}$ 。根据李雅普诺夫稳定性判定定理，嵌套控制器下的系统在 $\mathcal{X}$ 内李雅普诺夫稳定，且状态 $\mathbf{x}(t)$ 无法脱离 $\mathcal{X}_2$ （最坏情况下在 $\mathcal{M}_2$ 内震荡）。

步骤 2：证明渐进稳定性的充要条件（结论 b）必要性：若 C_{CN} 下的系统渐进稳定，则 $\dot{V}(\mathbf{x}) < 0, \forall \mathbf{x} \in \mathcal{X} \setminus \{\mathbf{x}^*\}$ 。对于 $\mathcal{X}_2$ 区域， $\alpha = 1$ ，故 $\dot{V}(\mathbf{x}) = \nabla V^T f(\mathbf{x}, C_1) \leq 0$ ；对于 $\mathcal{X}_3$ 区域，需满足 $\dot{V}(\mathbf{x}) < 0$ ，即：

$$\alpha \nabla V^T f(\mathbf{x}, C_1) + (1 - \alpha) \nabla V^T f(\mathbf{x}, C_2) < 0.$$

由于 $\alpha \in (0, 1)$ 且 $\nabla V^T f(\mathbf{x}, C_1) \leq 0$ ，则必须有 $\nabla V^T f(\mathbf{x}, C_2) < 0, \forall \mathbf{x} \in \mathcal{X}_3 \setminus \{\mathbf{x}^*\}$ 。

充分性：若 $\nabla V^T f(\mathbf{x}, C_2) < 0, \forall \mathbf{x} \in \mathcal{X}_3 \setminus \{\mathbf{x}^*\}$ ，则：

$$\dot{V}(\mathbf{x}) = \alpha \nabla V^T f(\mathbf{x}, C_1) + (1 - \alpha) \nabla V^T f(\mathbf{x}, C_2) < 0, \forall \mathbf{x} \in \mathcal{X} \setminus \{\mathbf{x}^*\}.$$

根据渐进稳定的李雅普诺夫判定准则，系统在 $\mathcal{X}$ 内渐进稳定。

综上，定理的两个结论均得证。 ■

当内部嵌套的控制器 C_2 为人类驾驶员（记为 C_{human} ）时，控制器嵌套方法退化为辅助驾驶的稳域包裹（Stable Domain Wrapper, SD Wrapper）技术，其核心挑战可量化为：1) 状态空间的维度选择：需确定 $\mathcal{X} = [x_1, x_2, \dots, x_n]^T$ 中 n 的取值及各状态变量 x_i 的物理意义（如侧倾角、横摆角速度等）；2) 边界的数学表征：需通过优化方法求解 $\mathcal{X}_2$ 的边界函数 $\partial \mathcal{X}_2 : g(\mathbf{x}) = 0$ ，及控制器切换的阈值 $\alpha^* = \inf\{\alpha(\mathbf{x}) | \mathbf{x} \in \partial \mathcal{X}_3\}$ 。这两部分内容将作为后续研究推广过程的重点方向之一。

A.3 插图

A.4 表格




图 A.9 车云协同危化品运输场景下 IVCPs 架构设计流程


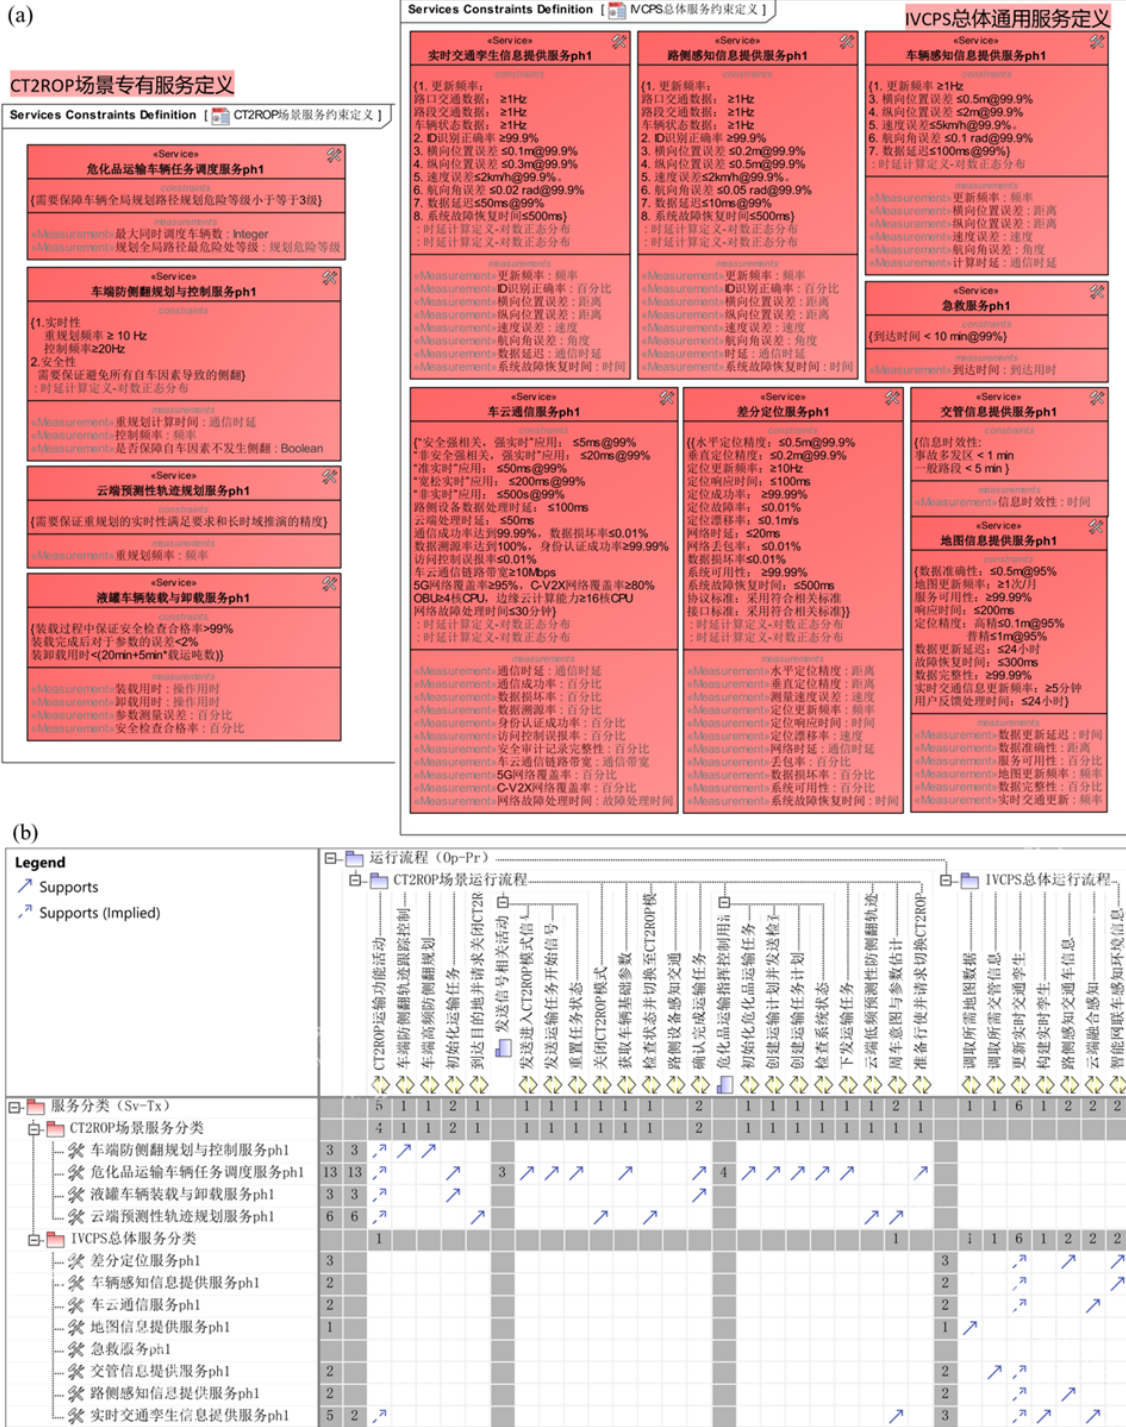


图 A.10 CT2ROP 运行功能与逻辑行为及其仿真



(a) 服务约束视图下定义的 CT2ROP 专服务及 IVCPs 通用服务 (b) 所有服务与运行活动间的追溯关系

图 A.11 CT2ROP 服务定义及其与运行活动追溯

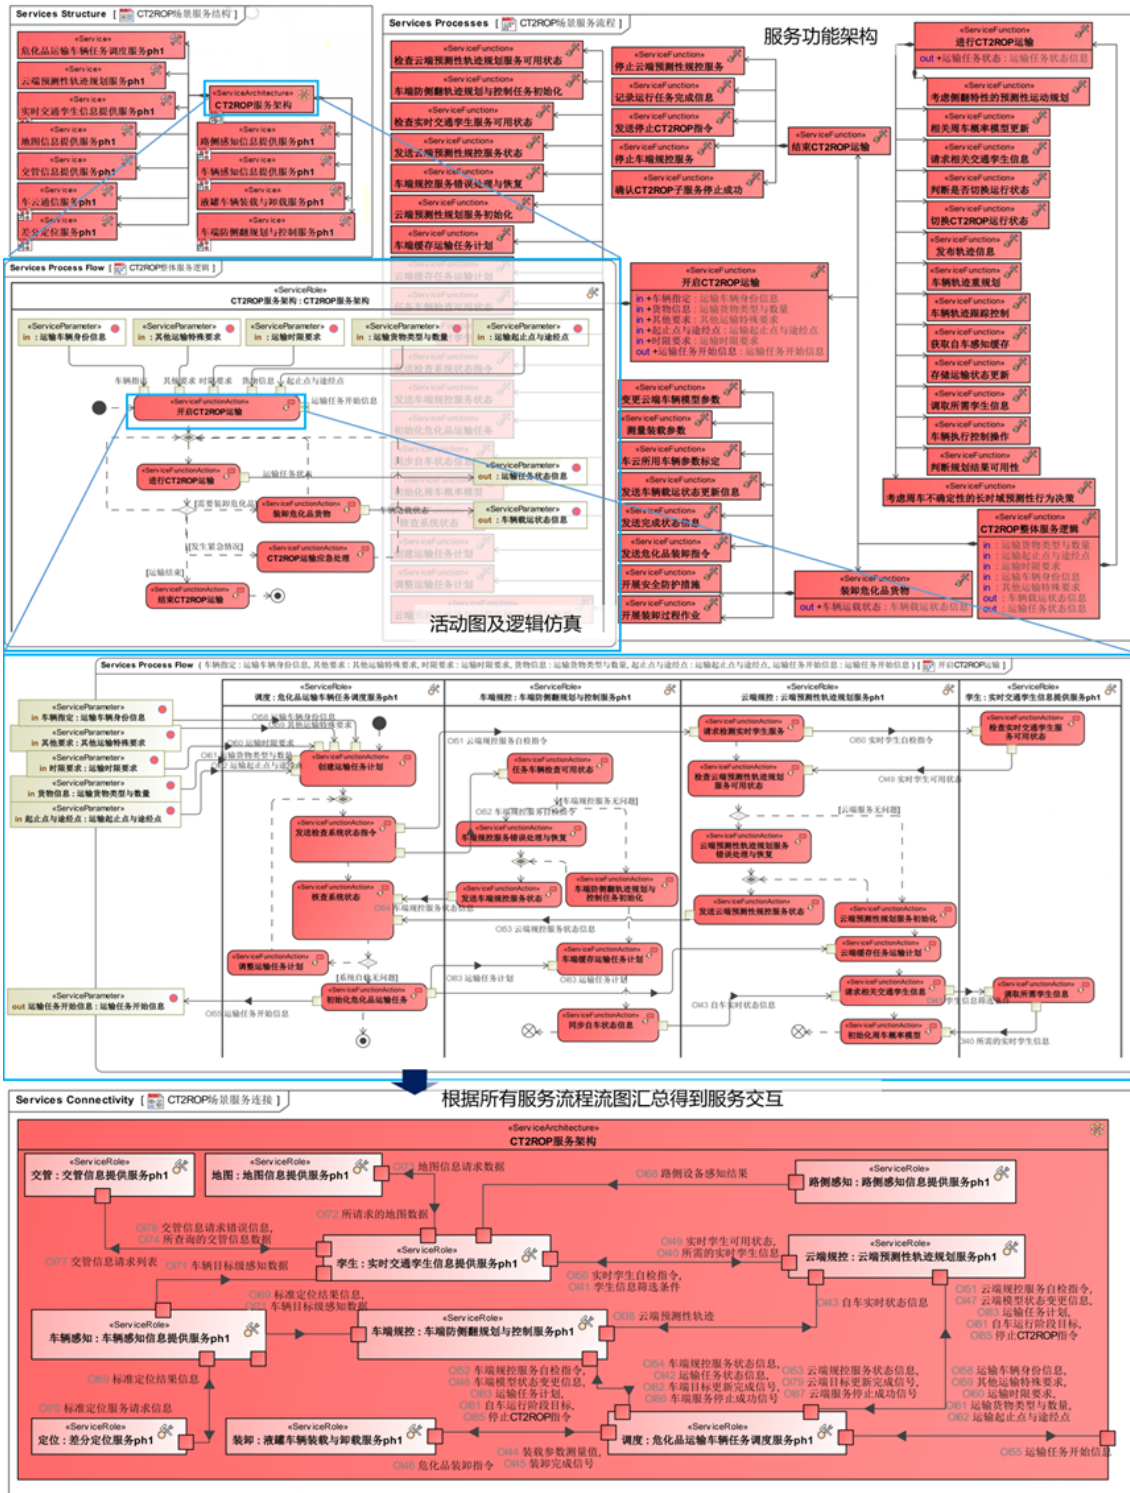


图 A.12 CT2ROP 服务功能与逻辑及其仿真

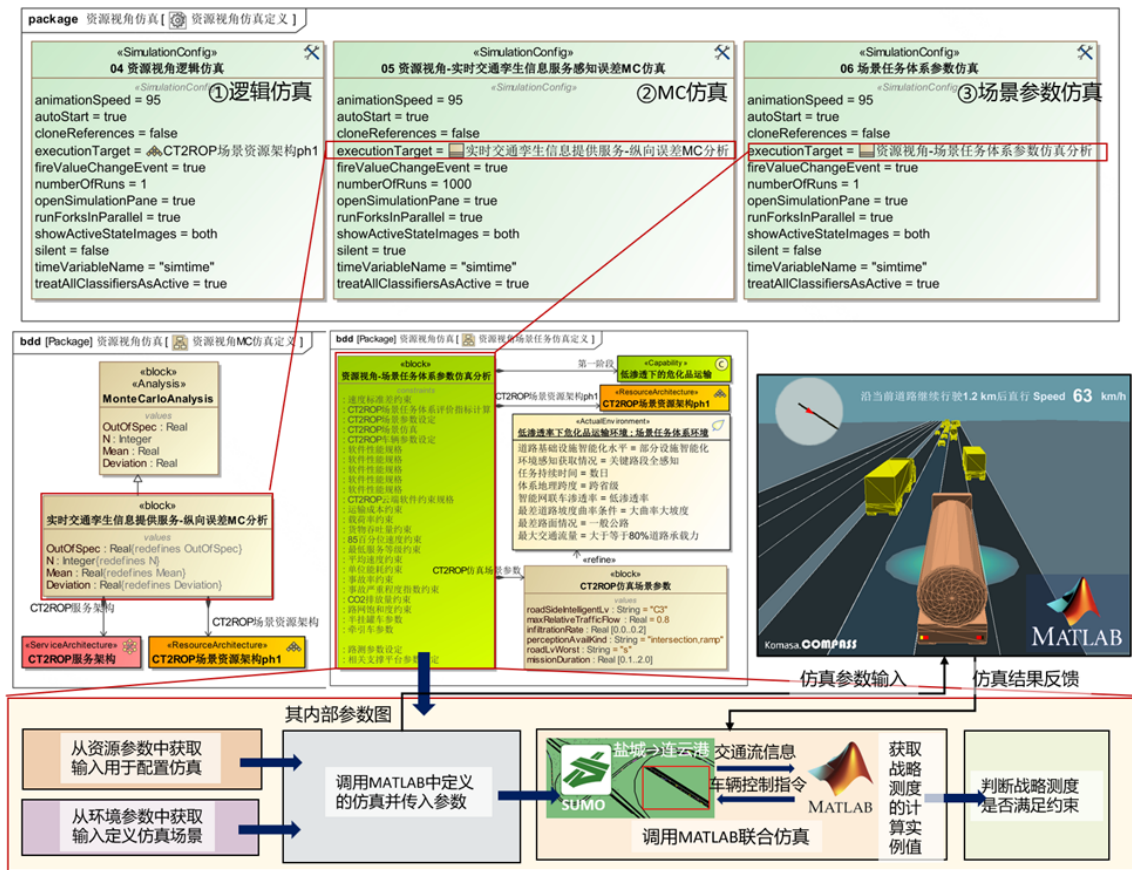


图 A.13 CT2ROP 场景资源仿真分析

表 A.2 仿真训练与验证场景设置

路口	序号	名称	t_{depr}	t_{start}	终止点	q_{main}	q_{merge}	q_{exit}	q_{avg}	用途
No.1	1	pass_1	280	287	(3377, 125023)	2250	1125	1125	4500	验证
	2	merge_1	120	230	(3377, 125023)	2250	1125	1125	4500	验证
	3	exit_1	120	140	(1353, 127222)	2250	1125	1125	4500	验证
	4	cruise_1	120	210	(6628, 122202)	2250	1125	1125	4500	验证
No.2	5	pass_2	50	150	(8827, 121224)	2000	1000	1000	4000	验证
	6	merge_2	120	125	(8827, 121224)	2000	1000	1000	4500	验证
	7	exit_2	120	190	(7084, 121972)	2000	1000	1000	4500	验证
	8	cruise_2	120	225	(13358, 119455)	2000	1000	1000	4500	验证
No.3	9	pass_3	100	145	(15097, 118843)	1750	875	875	3500	验证
	10	merge_3	100	160	(15097, 118843)	1750	875	875	3500	验证
	11	exit_3	100	120	(13647, 119360)	1750	875	875	3500	验证
	12	cruise_3	100	450	(26200, 113761)	1750	875	875	3500	验证
No.4	13	pass_4	150	160	(35853, 108391)	1500	750	750	3000	验证
	14	merge_4	150	185	(35853, 108391)	1500	750	750	3000	验证
	15	exit_4	150	190	(34593, 108938)	1500	750	750	3000	验证
	16	cruise_4	150	250	(42564, 102705)	1500	750	750	3000	验证

续表 A.2 仿真训练与验证场景设置

路口	序号	名称	t_{depr}	t_{start}	终止点	q_{main}	q_{merge}	q_{exit}	q_{avg}	用途
No.5	17	pass_5	150	165	(44006, 101780)	1250	625	625	2500	验证
	18	merge_5	150	230	(44004, 101780)	1250	625	625	2500	验证
	19	exit_5	150	160	(43231, 02663)	1250	625	625	2500	验证
	20	cruise_5	150	240	(49888, 07671)	1250	625	625	2500	验证
No.6	21	pass_6	150	190	(51242, 95154)	1000	500	500	2000	验证
	22	merge_6	150	155	(51242, 95154)	1000	500	500	2000	验证
	23	exit_6	150	160	(50189, 96489)	1000	500	500	2000	验证
	24	cruise_6	150	220	(58738, 87984)	1000	500	500	2000	验证
No.7	25	pass_7	150	170	(60200, 86293)	750	375	375	1500	验证
	26	merge_7	150	160	(60200, 86293)	750	375	375	1500	验证
	27	exit_7	150	310	(59676, 78847)	750	375	375	1500	验证
	28	cruise_7	150	310	(69330, 89515)	750	375	375	1500	验证
No.8	29	pass_8	100	130	(70907, 78147)	1250	1125	1125	4500	训练
	30	merge_8	100	130	(70907, 78147)	1250	1125	1125	4500	训练
	31	exit_8	100	130	(69498, 79025)	1250	1125	1125	4500	训练
	32	cruise_8	100	130	(74891, 72481)	1250	1125	1125	4500	训练
No.9	33	pass_9	120	150	(75573, 70800)	2000	1000	1000	4000	训练
	34	merge_9	120	150	(75573, 70800)	2000	1000	1000	4000	训练
	35	exit_9	120	150	(74896, 71940)	2000	1000	1000	4000	训练
	36	cruise_9	120	150	(85038, 58160)	2000	1000	1000	4000	训练
No.10	37	pass_10	100	130	(92050, 46785)	1750	875	875	3500	训练
	38	merge_10	100	130	(92050, 46785)	1750	875	875	3500	训练
	39	exit_10	100	130	(92054, 48293)	1750	875	875	3500	训练
	40	cruise_10	100	130	(96740, 37970)	1750	875	875	3500	训练
No.11	41	pass_11	150	180	(98075, 37971)	1500	750	750	3000	训练
	42	merge_11	150	180	(98075, 37971)	1500	750	750	3000	训练
	43	exit_11	150	180	(97180, 30472)	1500	750	750	3000	训练
	44	cruise_11	150	180	(34068, 110111)	1500	750	750	3000	训练
No.12	45	pass_12	150	180	(99643, 35167)	1250	625	625	2500	训练
	46	merge_12	150	180	(99643, 35167)	1250	625	625	2500	训练
	47	exit_12	150	180	(98931, 36237)	1250	625	625	2500	训练
	48	cruise_12	150	180	(104324, 24317)	1250	625	625	2500	训练
No.13	49	pass_13	150	180	(104781, 21843)	1000	500	500	2000	训练
	50	merge_13	150	180	(104781, 21843)	1000	500	500	2000	训练
	51	exit_13	150	180	(104332, 22626)	1000	500	500	2000	训练
	52	cruise_13	150	180	(107112, 14877)	1000	500	500	2000	训练
No.14	53	pass_14	150	180	(107705, 13226)	750	375	375	1500	训练
	54	merge_14	150	180	(107705, 13226)	750	375	375	1500	训练
	55	exit_14	150	180	(107203, 14112)	750	375	375	1500	训练

续表 A.2 仿真训练与验证场景设置

路口	序号	名称	t_{depr}	t_{start}	终止点	q_{main}	q_{merge}	q_{exit}	q_{avg}	用途
	56	cruise_14	150	180	(111286,6653)	750	375	375	1500	训练
No.15	57	pass_15	150	180	(112301,4704)	500	250	250	1000	训练
	58	merge_15	150	180	(112301,4704)	500	250	250	1000	训练
	59	exit_15	150	180	(111604,5761)	500	250	250	1000	训练
	60	cruise_15	150	180	(108764,3804)	500	250	250	1000	训练

表 A.3 交通流仿真分任务得分情况 (mean $\pm$ SEM)

Task	Reward term	IDM+MOBIL	TreeSearch	Graphflow
Task 1	Safe-1/TTC	-4.04 $\pm$ 0.42	-3.84 $\pm$ 0.27	-3.59$\pm$0.23
	Safe-MEI	-16.14 $\pm$ 9.55	-2.17 $\pm$ 0.52	-1.69$\pm$0.37
	Safe-RTTC	-0.93 $\pm$ 0.14	-0.91 $\pm$ 0.12	-0.68$\pm$0.11
	Safe-1/HW	-82.65 $\pm$ 8.03	-62.00 $\pm$ 4.84	-54.74$\pm$3.93
	Safe Reward	-103.76 $\pm$ 12.56	-68.92 $\pm$ 5.12	-60.70$\pm$4.27
	Effi Reward	183.15 $\pm$ 5.03	198.16 $\pm$ 5.58	198.75$\pm$5.39
	Navi-Lane	22.53$\pm$1.00	21.67 $\pm$ 0.78	21.86 $\pm$ 0.75
	Navi-Mission	2.86 $\pm$ 2.01	88.57 $\pm$ 3.83	95.71$\pm$2.44
	Navi Reward	25.39 $\pm$ 2.36	110.24 $\pm$ 3.84	117.57$\pm$2.58
	Comf Reward	-19.39 $\pm$ 0.94	-18.34 $\pm$ 0.68	-18.27$\pm$0.68
	Total Reward	85.38 $\pm$ 13.46	221.13 $\pm$ 7.27	237.35$\pm$6.02
Task 2	Safe-1/TTC	-1.43$\pm$0.12	-1.58 $\pm$ 0.12	-1.87 $\pm$ 0.13
	Safe-MEI	-26.79 $\pm$ 11.12	-1.51$\pm$0.25	-2.99 $\pm$ 0.84
	Safe-RTTC	-0.99 $\pm$ 0.09	-0.73$\pm$0.07	-0.82 $\pm$ 0.08
	Safe-1/HW	-35.22 $\pm$ 3.25	-18.90 $\pm$ 2.28	-17.45$\pm$2.44
	Safe Reward	-64.44 $\pm$ 11.14	-22.71$\pm$2.41	-23.14 $\pm$ 2.74
	Effi Reward	110.80 $\pm$ 6.37	114.58 $\pm$ 5.97	116.03$\pm$6.08
	Navi-Lane	14.46 $\pm$ 0.69	15.48 $\pm$ 0.71	16.77$\pm$0.73
	Navi-Mission	97.14 $\pm$ 2.01	100.00$\pm$0.00	100.00$\pm$0.00
	Navi Reward	111.60 $\pm$ 2.36	115.48 $\pm$ 0.71	116.77$\pm$0.73
	Rule Reward	25.15 $\pm$ 2.30	26.19 $\pm$ 2.19	26.31$\pm$2.39
	Comf Reward	-11.42 $\pm$ 0.58	-11.11$\pm$0.56	-11.18 $\pm$ 0.54
	Total Reward	171.70 $\pm$ 14.83	222.42 $\pm$ 6.43	224.80$\pm$7.27
Task 3	Safe-1/TTC	-3.10 $\pm$ 0.17	-2.82$\pm$0.14	-3.16 $\pm$ 0.18
	Safe-MEI	-12.42 $\pm$ 5.45	-0.90$\pm$0.14	-1.37 $\pm$ 0.29
	Safe-RTTC	-0.61 $\pm$ 0.08	-0.26$\pm$0.04	-0.39 $\pm$ 0.06
	Safe-1/HW	-41.23 $\pm$ 3.13	-24.28$\pm$2.14	-27.34 $\pm$ 2.35
	Safe Reward	-57.36 $\pm$ 6.29	-28.26$\pm$2.19	-32.25 $\pm$ 2.44
	Effi Reward	105.90 $\pm$ 6.11	114.89 $\pm$ 5.68	115.86$\pm$5.58
	Navi-Lane	15.77$\pm$0.66	14.74 $\pm$ 0.58	15.59 $\pm$ 0.65
	Navi-Mission	98.57 $\pm$ 1.43	100.00$\pm$0.00	100.00$\pm$0.00
	Navi Reward	114.34 $\pm$ 1.69	114.74 $\pm$ 0.58	115.59$\pm$0.65

续表 A.3 交通流仿真分任务得分情况 (mean $\pm$ SEM)

Task	Reward term	IDM+MOBIL	TreeSearch	Graphflow
Task 4	Rule Reward	31.29$\pm$1.90	26.81 $\pm$ 1.63	26.75 $\pm$ 1.85
	Comf Reward	-12.85 $\pm$ 0.46	-11.35$\pm$0.40	-11.72 $\pm$ 0.40
	Total Reward	181.33$\pm$10.31	216.83 $\pm$ 6.63	214.22 $\pm$ 6.21
	Safe-1/TTC	-4.70 $\pm$ 0.34	-4.10$\pm$0.26	-4.38 $\pm$ 0.29
	Safe-MEI	-3.00 $\pm$ 0.73	-1.55 $\pm$ 0.24	-1.38$\pm$0.17
	Safe-RTTC	-0.70 $\pm$ 0.13	-0.62 $\pm$ 0.07	-0.57$\pm$0.06
	Safe-1/HW	-176.83 $\pm$ 9.12	-135.01$\pm$7.39	-141.76 $\pm$ 7.12
	Safe Reward	-185.23 $\pm$ 9.47	-141.28$\pm$7.59	-148.09 $\pm$ 7.25
	Effi Reward	547.09 $\pm$ 17.74	559.02$\pm$17.30	554.70 $\pm$ 18.17
	Navi-Lane	46.24$\pm$1.54	45.86 $\pm$ 1.49	46.09 $\pm$ 1.60
	Navi-Mission	1.43 $\pm$ 1.43	72.86 $\pm$ 5.35	84.29$\pm$4.38
	Navi Reward	47.67 $\pm$ 2.16	118.72 $\pm$ 4.68	130.37$\pm$3.63
	Rule Reward	151.05 $\pm$ 7.44	168.74$\pm$5.89	157.62 $\pm$ 7.21
	Comf Reward	-46.06 $\pm$ 1.47	-45.62$\pm$1.39	-45.68 $\pm$ 1.47
	Total Reward	514.52 $\pm$ 23.24	659.59$\pm$19.52	648.93 $\pm$ 21.99

表 A.4 交通流仿真分流量得分情况 (mean $\pm$ SEM)

Flow (veh/h)	Reward term	IDM+MOBIL	TreeSearch	Graphflow
4500	Safe-1/TTC	-4.47 $\pm$ 0.71	-3.57 $\pm$ 0.44	-3.39$\pm$0.35
	Safe-MEI	-2.75 $\pm$ 0.80	-1.76$\pm$0.30	-2.65 $\pm$ 0.61
	Safe-RTTC	-1.17 $\pm$ 0.15	-0.92$\pm$0.12	-1.00 $\pm$ 0.13
	Safe-1/HW	-121.10 $\pm$ 12.19	-79.61 $\pm$ 9.10	-74.66$\pm$8.29
	Safe Reward	-129.48 $\pm$ 13.10	-85.86 $\pm$ 9.27	-81.70$\pm$8.49
	Effi Reward	224.15 $\pm$ 20.62	257.37$\pm$21.30	248.41 $\pm$ 19.29
	Navi-Lane	27.23$\pm$1.73	27.01 $\pm$ 1.61	26.74 $\pm$ 1.52
	Navi-Mission	52.50 $\pm$ 8.00	90.00 $\pm$ 4.80	97.50$\pm$2.50
	Navi Reward	79.73 $\pm$ 6.65	117.01 $\pm$ 4.75	124.24$\pm$2.91
	Rule Reward	49.18 $\pm$ 7.87	58.28$\pm$9.30	51.02 $\pm$ 7.97
	Comf Reward	-25.60 $\pm$ 1.77	-24.38 $\pm$ 1.69	-23.76$\pm$1.58
	Total Reward	197.98 $\pm$ 28.37	322.41$\pm$26.71	318.21 $\pm$ 22.10
4000	Safe-1/TTC	-3.13 $\pm$ 0.30	-2.92 $\pm$ 0.28	-2.82$\pm$0.24
	Safe-MEI	-19.19 $\pm$ 8.29	-2.74 $\pm$ 0.83	-2.56$\pm$0.77
	Safe-RTTC	-1.09 $\pm$ 0.23	-0.74$\pm$0.10	-0.80 $\pm$ 0.11
	Safe-1/HW	-92.12 $\pm$ 8.08	-61.43$\pm$6.29	-62.63 $\pm$ 6.49
	Safe Reward	-115.53 $\pm$ 10.11	-67.82$\pm$6.50	-68.81 $\pm$ 6.54
	Effi Reward	183.22 $\pm$ 15.37	198.06$\pm$15.70	193.86 $\pm$ 14.40
	Navi-Lane	23.72$\pm$0.79	21.56 $\pm$ 1.00	21.65 $\pm$ 0.82
	Navi-Mission	50.00 $\pm$ 8.01	95.00 $\pm$ 3.49	100.00$\pm$0.00
	Navi Reward	73.72 $\pm$ 7.40	116.56 $\pm$ 3.42	121.65$\pm$0.82
	Rule Reward	37.20 $\pm$ 4.82	41.14$\pm$6.07	35.77 $\pm$ 5.02
	Comf Reward	-20.37 $\pm$ 0.86	-18.86$\pm$1.06	-19.14 $\pm$ 0.91

续表 A.4 交通流仿真分流量得分情况 (mean $\pm$ SEM)

Flow (veh/h)	Reward term	IDM+MOBIL	TreeSearch	Graphflow
	Total Reward	158.24 $\pm$ 12.92	269.08$\pm$17.18	263.32 $\pm$ 13.17
3500	Safe-1/TTC	-2.90 $\pm$ 0.26	-2.83$\pm$0.26	-3.30 $\pm$ 0.28
	Safe-MEI	-63.06 $\pm$ 24.50	-2.76$\pm$0.42	-4.77 $\pm$ 1.25
	Safe-RTTC	-1.48 $\pm$ 0.14	-1.17 $\pm$ 0.16	-1.11$\pm$0.14
	Safe-1/HW	-84.28 $\pm$ 13.73	-64.15$\pm$13.19	-66.83 $\pm$ 12.05
	Safe Reward	-151.72 $\pm$ 25.27	-70.91$\pm$13.51	-76.02 $\pm$ 11.94
	Effi Reward	217.74 $\pm$ 35.59	227.23 $\pm$ 34.80	229.37$\pm$34.92
	Navi-Lane	23.45 $\pm$ 2.59	23.81 $\pm$ 2.36	24.17$\pm$2.41
	Navi-Mission	45.00 $\pm$ 7.97	95.00$\pm$3.49	95.00$\pm$3.49
	Navi Reward	68.45 $\pm$ 7.19	118.81 $\pm$ 3.48	119.17$\pm$4.44
	Rule Reward	55.01$\pm$12.00	53.43 $\pm$ 11.61	53.35 $\pm$ 12.12
	Comf Reward	-21.25 $\pm$ 2.78	-20.82$\pm$2.63	-20.82$\pm$2.73
	Total Reward	168.22 $\pm$ 45.89	307.75$\pm$35.36	305.06 $\pm$ 36.91
3000	Safe-1/TTC	-3.24 $\pm$ 0.31	-2.96$\pm$0.28	-3.27 $\pm$ 0.28
	Safe-MEI	-1.50 $\pm$ 0.42	-1.08 $\pm$ 0.29	-0.44$\pm$0.13
	Safe-RTTC	-0.61 $\pm$ 0.15	-0.53 $\pm$ 0.11	-0.35$\pm$0.07
	Safe-1/HW	-73.65 $\pm$ 12.35	-61.42 $\pm$ 9.19	-58.37$\pm$11.20
	Safe Reward	-78.99 $\pm$ 12.48	-66.00 $\pm$ 9.45	-62.43$\pm$11.35
	Effi Reward	260.07 $\pm$ 37.21	253.20 $\pm$ 34.42	264.12$\pm$37.18
	Navi-Lane	24.66 $\pm$ 2.77	23.60 $\pm$ 2.49	26.56$\pm$2.58
	Navi-Mission	52.50 $\pm$ 8.00	100.00$\pm$0.00	100.00$\pm$0.00
	Navi Reward	77.16 $\pm$ 6.55	123.60 $\pm$ 2.49	126.56$\pm$2.58
	Rule Reward	58.11 $\pm$ 12.92	56.19 $\pm$ 12.54	59.99$\pm$13.54
	Comf Reward	-22.96 $\pm$ 2.92	-21.28$\pm$2.72	-22.52 $\pm$ 2.93
	Total Reward	293.39 $\pm$ 34.55	345.71 $\pm$ 38.04	365.73$\pm$39.82
2500	Safe-1/TTC	-2.01$\pm$0.17	-2.56 $\pm$ 0.27	-2.43 $\pm$ 0.23
	Safe-MEI	-6.73 $\pm$ 2.73	-1.40 $\pm$ 0.30	-0.92$\pm$0.19
	Safe-RTTC	-0.52 $\pm$ 0.07	-0.45 $\pm$ 0.07	-0.40$\pm$0.07
	Safe-1/HW	-48.46 $\pm$ 8.90	-37.08$\pm$7.58	-38.62 $\pm$ 7.76
	Safe Reward	-57.72 $\pm$ 8.82	-41.50$\pm$7.82	-42.38 $\pm$ 7.79
	Effi Reward	166.31 $\pm$ 22.83	169.41 $\pm$ 23.67	169.58$\pm$23.14
	Navi-Lane	16.61 $\pm$ 1.72	17.08 $\pm$ 1.71	18.03$\pm$1.72
	Navi-Mission	50.00 $\pm$ 8.01	90.00 $\pm$ 4.80	100.00$\pm$0.00
	Navi Reward	66.61 $\pm$ 6.99	107.08 $\pm$ 5.22	118.03$\pm$1.72
	Rule Reward	35.64 $\pm$ 7.38	40.39$\pm$8.56	36.54 $\pm$ 7.67
	Comf Reward	-14.80 $\pm$ 1.85	-14.66 $\pm$ 1.87	-14.46$\pm$1.82
	Total Reward	196.04 $\pm$ 19.29	260.73 $\pm$ 25.71	267.31$\pm$23.59
2000	Safe-1/TTC	-3.93 $\pm$ 0.52	-3.33$\pm$0.34	-4.00 $\pm$ 0.43
	Safe-MEI	-6.94 $\pm$ 4.29	-0.40$\pm$0.08	-0.81 $\pm$ 0.19
	Safe-RTTC	-0.39 $\pm$ 0.07	-0.31$\pm$0.06	-0.33 $\pm$ 0.05
	Safe-1/HW	-92.65 $\pm$ 14.01	-63.95 $\pm$ 9.85	-62.42$\pm$8.78
	Safe Reward	-103.91 $\pm$ 14.75	-67.99 $\pm$ 10.12	-67.56$\pm$9.20

续表 A.4 交通流仿真分流量得分情况 (mean $\pm$ SEM)

Flow (veh/h)	Reward term	IDM+MOBIL	TreeSearch	Graphflow
1500	Effi Reward	310.64 $\pm$ 38.04	316.99 $\pm$ 40.05	319.19$\pm$39.38
	Navi-Lane	29.58 $\pm$ 3.22	29.64 $\pm$ 3.27	30.44$\pm$3.31
	Navi-Mission	50.00 $\pm$ 8.01	75.00$\pm$6.93	75.00$\pm$6.93
	Navi Reward	79.58 $\pm$ 6.43	104.64 $\pm$ 3.79	105.44$\pm$3.75
	Rule Reward	62.71 $\pm$ 12.91	67.59$\pm$14.27	66.13 $\pm$ 13.91
	Comf Reward	-26.75 $\pm$ 3.15	-26.14$\pm$3.20	-26.44 $\pm$ 3.18
	Total Reward	322.27 $\pm$ 34.53	395.08 $\pm$ 39.24	396.75$\pm$38.07
	Safe-1/TTC	-3.55 $\pm$ 0.38	-3.40$\pm$0.30	-3.53 $\pm$ 0.33
	Safe-MEI	-1.94 $\pm$ 0.67	-0.58$\pm$0.13	-0.85 $\pm$ 0.23
	Safe-RTTC	-0.41 $\pm$ 0.08	-0.30$\pm$0.04	-0.32 $\pm$ 0.05
	Safe-1/HW	-75.63 $\pm$ 13.77	-52.70$\pm$9.85	-58.71 $\pm$ 11.53
	Safe Reward	-81.53 $\pm$ 14.53	-56.98$\pm$10.15	-63.41 $\pm$ 11.94
	Effi Reward	295.01 $\pm$ 38.57	304.37$\pm$39.75	299.81 $\pm$ 38.77
	Navi-Lane	28.01 $\pm$ 2.93	28.38$\pm$2.87	27.94 $\pm$ 2.83
	Navi-Mission	50.00 $\pm$ 8.01	87.50 $\pm$ 5.30	97.50$\pm$2.50
	Navi Reward	78.01 $\pm$ 6.58	115.88 $\pm$ 4.08	125.44$\pm$3.19
	Rule Reward	65.26 $\pm$ 13.16	71.01$\pm$14.37	65.89 $\pm$ 13.18
	Comf Reward	-25.28 $\pm$ 3.17	-25.09$\pm$3.22	-24.83 $\pm$ 3.17
	Total Reward	331.47 $\pm$ 36.95	409.20$\pm$41.14	402.90 $\pm$ 42.51

表 A.5 简化半挂液罐车模型参数与变量说明

参数/变量	说明 (i=1,2 分别代表牵引车、挂车)
m_i, m_{si}	车辆总质量、簧载质量
v_{ix}, v_{iy}	纵向/侧向速度
$\dot{\beta}_i$	质心侧偏角变化率
ψ_i, ϕ_i	横摆角、侧倾角
$\dot{\psi}_i$	横摆角速度
$\dot{\phi}_i$	侧倾角速度
h_i	质心到侧倾中心的距离
h_{ic}	牵引销到侧倾轴线的高度
$I_{izz}, I_{ixx}, I_{1xz}$	簧载质量在横摆、侧倾、交叉耦合方向的转动惯量
k_{ri}, c_i	悬架侧倾刚度/阻尼
F_{y1}, F_{y2}, F_{y3}	牵引车等效前轴、后轴, 以及挂车等效后轴的侧向力
F_z	车轮所受垂向力
$F_{y,int}$	挂车作用于牵引车的侧向力
F_x, F_y, M_x, M_y, M_z	液体晃动纵向力、侧向力、侧倾力矩、俯仰力矩、横摆力矩
a, b, c	牵引车前轮轴/后轮轴/牵引销铰接点到质心的距离
d, e	挂车后轮轴/牵引销铰接点到质心的距离
k_{12}	牵引销连接部位的侧倾刚度
k_1, k_2, k_3	牵引车等效前轴、后轴, 以及挂车后轴的侧向刚度
θ_1, θ_2	线性化双摆模型摆角

续表 A.5 简化半挂液罐车模型参数与变量说明

参数/变量	说明 (i=1,2 分别代表牵引车、挂车)
$\dot{\theta}_1, \dot{\theta}_2$	线性化双摆模型前/后摆角速度
δ, δ_d	转向角、期望转向角
a_{deccel}	车辆减速度
c_{M1}	牵引车制动力矩-减速度转换系数
c_{M2}	挂车制动力矩-减速度转换系数
c_{brk}	制动压力-减速度转换系数
τ_v	车速响应时间常数
v_{des}	期望车速
$\Delta v_{thrl d}$	期望车速与实际车速差值阈值
v_{des}^a	给下层控制器的期望速度指令
v_{dev}	静态偏置加速度
p_{brk}^{L1}	牵引车左侧制动压力
p_{brk}^{R1}	牵引车右侧制动压力
p_{brk}^{L2}	挂车左侧制动压力
p_{brk}^{R2}	挂车右侧制动压力
M_{1z}^+	牵引车左侧附加横摆力矩
M_{1z}^-	牵引车右侧附加横摆力矩
M_{2z}^+	挂车左侧附加横摆力矩
M_{2z}^-	挂车右侧附加横摆力矩
T_{w1}	牵引车轮距
T_{w2}	挂车轮距
Y_1	牵引车在大地坐标系下的 Y 轴坐标
X_1	牵引车在大地坐标系下的 X 轴坐标




图 A.14 协同仿真平台 Simulink 模型

A.5 数学表达式

$$M = \begin{bmatrix} m_{11} & I_{1zz} & 0 & m_{14} & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ m_{21} & -I_{1xz} & 0 & m_{24} & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ m_{31} & 0 & 0 & m_{34} & m_{35} & m_{36} & 0 & m_{38} & 0 & m_{310} & 0 & m_{310} & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & m_{45} & m_{46} & 0 & m_{48} & 0 & m_{410} & 0 & m_{412} & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & m_{55} & m_{56} & 0 & m_{58} & 0 & m_{510} & 0 & m_{510} & 0 & 0 & 0 & 0 \\ 1 & -\frac{c}{v_{1x}} & 0 & -\frac{h_{1c}}{v_{1x}} & -1 & -\frac{e}{v_{2x}} & 0 & \frac{h_{2c}}{v_{2x}} & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & \frac{v_{2x}}{l_p} & \frac{x_1}{l_p} & 0 & \frac{h_p}{l_p} & -2 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & \frac{v_{2x}}{l_p} & \frac{x_2}{l_p} & 0 & \frac{h_p}{l_p} & -2 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}_{16 \times 16} \quad (\text{A.69})$$

其中各个子项为:

$$\begin{aligned} m_{11} &= m_1 v_{1x} c, \quad m_{14} = -m_{1s} h_1 c - I_{1xz}, \quad m_{21} = (m_1 h_1 c - m_{1s} h_1) v_{1x}, \\ m_{24} &= I_{1xx} + 2m_{1s} h_1^2 - m_{1s} h_1 h_{1c}, \quad m_{31} = m_1 v_{1x}, \quad m_{34} = -m_{1s} h_1, \\ m_{35} &= m_2 v_{2x} + (m_p + m_0) v_{2x}, \quad m_{36} = x_0 (m_p + m_0), \quad m_{38} = -m_{2s} h_2 - (m_0 h_0 + m_p h_p), \\ m_{310} &= \frac{1}{2} m_p l_p, \quad m_{45} = e m_{35} - x_0 (m_p + m_0) v_{x2}, \quad m_{46} = -I_{2zz} + e m_{36} - \frac{1}{2} (m_p + m_0) (x_1^2 + x_2^2), \\ m_{48} &= I_{2xz} + e m_{38} + x_0 (m_0 h_0 + m_p h_p), \quad m_{410} = e m_{310} - \frac{1}{2} m_p l_p x_1 = \frac{1}{2} (e - x_1) m_p l_p, \\ m_{412} &= e m_{310} - \frac{1}{2} m_p l_p x_2 = \frac{1}{2} (e - x_2) m_p l_p, \\ m_{55} &= (m_2 h_{2c} - m_{2s} h_2) v_{2x} + h_{2c} (m_p + m_0) v_{2x} - v_{x2} (m_0 h_0 + m_p h_p), \\ m_{56} &= -I_{2xz} + h_{2c} m_{36} - x_0 (m_0 h_0 + m_p h_p), \quad m_{58} = I_{2xx} + 2m_{2s} h_2^2 + h_{2c} m_{38} + (m_0 h_0^2 + m_p h_p^2), \\ m_{510} &= h_{2c} m_{310} - \frac{1}{2} m_p h_p l_p = \frac{1}{2} (h_{2c} - h_p) m_p l_p. \end{aligned}$$

$$A_0 = \begin{bmatrix} a_{11} & a_{12} & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ a_{21} & a_{22} & a_{23} & 0 & 0 & 0 & k_{12} & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ a_{31} & a_{32} & 0 & 0 & k_3 & a_{36} & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & a_{45} & a_{46} & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & a_{55} & a_{56} & a_{57} & -c_2 & a_{59} & 0 & a_{59} & 0 & 0 & 0 & 0 \\ 0 & -1 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & -\frac{v_{2x}}{l_p} & -\frac{g}{l_p} & 0 & -\frac{g}{l_p} & -c_d & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & -\frac{v_{2x}}{l_p} & 0 & -\frac{g}{l_p} & 0 & -\frac{g}{l_p} & 0 & 0 & -c_d & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & -\frac{1}{\tau_v} & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix} \quad (\text{A.70})$$

其中各个子项为:

$$\begin{aligned} a_{11} &= (a+c)k_1 + (c-b)k_2, & a_{12} &= \frac{a(a+c)k_1 - b(c-b)k_2}{v_{1x}} - m_1 v_{1x} c, \\ a_{21} &= k_1 h_{1c} + k_2 h_{1c}, & a_{22} &= \frac{(ak_1 - bk_2)h_{1c}}{v_{1x}} + (m_{1s}h_1 - m_1 h_{1c})v_{1x}, \\ a_{23} &= m_{1s}gh_1 - k_{r1} - k_{12}, & a_{31} &= k_1 + k_2, & a_{32} &= \frac{ak_1 - bk_2}{v_{1x}} - m_1 v_{1x}, \\ a_{36} &= -\frac{dk_3}{v_{2x}} - m_2 v_{2x} - (m_0 + m_p)v_{2x}, & a_{45} &= (d+e)k_3, \\ a_{46} &= -\frac{d(e+d)k_3}{v_{2x}} - m_2 v_{2x} e - e(m_0 + m_p)v_{2x} + x_0(m_p + m_0)v_{2x}, & a_{55} &= k_3 h_{2c} e, \\ a_{56} &= -\frac{dk_3 h_{2c}}{v_{2x}} + (m_{2s}h_2 - m_2 h_{2c})v_{2x} + (m_0 h_0 + m_p h_p)v_{2x} - h_{2c}(m_0 + m_p)v_{2x}, \\ a_{57} &= m_{2s}gh_2 - k_{r2} - k_{12} + (m_0 h_0 + m_p h_p)g, & a_{59} &= -\frac{1}{2}m_p l_p g. \end{aligned}$$

$$B_0 = \begin{bmatrix} -(c+a)k_1 & \frac{c_{brk}}{c_M} & -\frac{c_{brk}}{c_M} & 0 & 0 & 0 \\ -k_1 h_{1c} & 0 & 0 & 0 & 0 & 0 \\ -k_1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & -\frac{c_{brk}}{c_M} & \frac{c_{brk}}{c_M} & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & -c_{brk} & -c_{brk} & -c_{brk} & -c_{brk} & \frac{1}{\tau_v} \\ 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}_{14 \times 6} \quad (A.71)$$

$$T_c = \text{diag}([v_{1x} \ 1 \ 1 \ 1 \ v_{2x} \ 1 \ 1 \ 1 \ 1 \ 1 \ 1 \ 1 \ 1])_{14 \times 14} \quad (A.72)$$

参考文献

- [A.1] Cunningham A G, Galceran E, Eustice R M, et al. MPDM: Multipolicy decision-making in dynamic, uncertain environments for autonomous driving[C/OL]//Proceedings of the IEEE International Conference on Robotics and Automation. IEEE, 2015: 1670-1677. DOI: 10.1109/ICRA.2015.7139412.
- [A.2] Galceran E, Cunningham A G, Eustice R M, et al. Multipolicy decision-making for autonomous driving via changepoint-based behavior prediction: Theory and experiment[J/OL]. Autonomous Robots, 2017, 41(6): 1-16. DOI: 10.1007/s10514-017-9619-z.
- [A.3] Ding W, Zhang L, Chen J, et al. EPSILON: An efficient planning system for automated vehicles in highly interactive environments[J]. IEEE Transactions on Robotics, 2022(2): 38.
- [A.4] Zhang L, Ding W, Chen J, et al. Efficient uncertainty-aware decision-making for automated driving using guided branching[C/OL]//2020 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2020. DOI: 10.1109/ICRA40945.2020.9197302.
- [A.5] Ding W, Zhang L, Chen J, et al. Safe trajectory generation for complex urban environments using spatio-temporal semantic corridor[J/OL]. IEEE Robotics and Automation Letters, 2019, 4(3): 2997-3004. DOI: 10.1109/LRA.2019.2923954.

-
- [A.6] Bae S, Isele D, Nakhaei A, et al. Lane-change in dense traffic with model predictive control and neural networks[J/OL]. IEEE Transactions on Control Systems Technology, 2023, 31(2): 646-659. DOI: 10.1109/TCST.2022.3193923.
- [A.7] Salvado J, Custodio L M M, Heß D. Contingency planning for automated vehicles in urban traffic[C/OL]//2016 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2016. DOI: 10.1109/IROS.2016.7759442.
- [A.8] Huang H J, Huang K C, et al. Planning on a (risk) budget: Safe non-conservative planning in probabilistic dynamic environments[EB/OL]. 2021[2024-10-01]. DOI: 10.48550/arXiv.2106.09127.
- [A.9] Da F. Comprehensive reactive safety: no need for a trajectory if you have a strategy[C/OL]//2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). Kyoto, Japan: IEEE, 2022: 2903-2910. DOI: 10.1109/IROS47612.2022.9981757.
- [A.10] Li N, Kolmanovsky I, Girard A, et al. Game theoretic modeling of vehicle interactions at unsignalized intersections and application to autonomous vehicle control[C/OL]//2018 Annual American Control Conference (ACC). IEEE, 2018. DOI: 10.23919/ACC.2018.8430842.
- [A.11] Li N, Yao Y, Kolmanovsky I, et al. Game-theoretic modeling of multi-vehicle interactions at uncontrolled intersections[J/OL]. IEEE Transactions on Intelligent Transportation Systems, 2020. DOI: 10.1109/TITS.2020.3026160.
- [A.12] Le Cleac'h S, Schwager M, Manchester Z. LUCIDGames: Online unscented inverse dynamic games for adaptive trajectory prediction and planning[EB/OL]. 2020. DOI: 10.48550/arXiv.2011.08152.
- [A.13] Le Cleac'h S, Schwager M, Manchester Z. ALGAMES: a fast augmented lagrangian solver for constrained dynamic games[J]. Autonomous Robots, 2022(1): 46.
- [A.14] Li T, Zhang L, Liu S, et al. MARC: multipolicy and risk-aware contingency planning for autonomous driving[J]. IEEE Robotics and Automation Letters, 2023, 8(10): 6587-6594.
- [A.15] Sun L, Zhan W, Tomizuka M, et al. Courteous autonomous cars[C/OL]//2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2018. DOI: 10.1109/IROS.2018.8593969.
- [A.16] Sheng Z, Liu L, Li J D. A cooperation-aware lane change method for automated vehicles[J]. IEEE Transactions on Intelligent Transportation Systems, 2023, 24(3): 3236-3251.
- [A.17] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[EB/OL]. arXiv, 2017. DOI: 10.48550/arXiv.1706.03762.
- [A.18] Chen L, Wu P, Chitta K, et al. End-to-end autonomous driving: Challenges and frontiers[J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023. DOI: 10.1109/TPAMI.2024.3435937.
- [A.19] Cheng J, Chen Y, Mei X, et al. Rethinking imitation-based planner for autonomous driving [EB/OL]. arXiv, 2023. <https://arxiv.org/abs/2309.10443>.
- [A.20] Cheng J, Chen Y, Chen Q. PLUTO: Pushing the limit of imitation learning-based planning for autonomous driving[EB/OL]. arXiv, 2024. <https://arxiv.org/abs/2404.14327>.

- [A.21] Zhang D, Liang J, Guo K, et al. Carplanner: Consistent auto-regressive trajectory planning for large-scale reinforcement learning in autonomous driving[C/OL]//2025 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2025. DOI: 10.1109/CVPR52734.2025.01607.
- [A.22] Nayakanti N, Al-Rfou R, Zhou A, et al. Wayformer: Motion forecasting via simple & efficient attention networks[EB/OL]. arXiv, 2022. <https://arxiv.org/abs/2207.05844>.
- [A.23] Phillion J, Peng X B, Fidler S. Trajenglish: Traffic modeling as next-token prediction[EB/OL]. arXiv, 2024. <https://arxiv.org/abs/2312.04535>.
- [A.24] Tang X, Kan M, Shan S, et al. Plan-R1: Safe and feasible trajectory planning as language modeling[EB/OL]. 2025.
- [A.25] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[EB/OL]. arXiv, 2020. DOI: 10.48550/arXiv.2010.11929.
- [A.26] Carion N, Massa F, Synnaeve G, et al. End-to-end object detection with transformers[C/OL]//European Conference on Computer Vision (ECCV). 2020. DOI: 10.1007/978-3-030-58452-8_13.
- [A.27] Zhu X, Su W, Lu L, et al. Deformable DETR: Deformable transformers for end-to-end object detection[EB/OL]. arXiv, 2020. DOI: 10.48550/arXiv.2010.04159.
- [A.28] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6): 1137-1149. DOI: 10.1109/TPAMI.2016.2577031.
- [A.29] He K, Gkioxari G, Dollár P, et al. Mask R-CNN[J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2018. DOI: 10.1109/TPAMI.2018.2844175.
- [A.30] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection [C/OL]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2016. DOI: 10.1109/CVPR.2016.91.
- [A.31] Chitta K, Prakash A, Jaeger B, et al. Transfuser: Imitation with transformer-based sensor fusion for autonomous driving[EB/OL]. arXiv, 2022. <https://arxiv.org/abs/2205.15997>.
- [A.32] Phillion J, Fidler S. Lift, splat, shoot: Encoding images from arbitrary camera rigs by implicitly unprojecting to 3d[EB/OL]. arXiv, 2020. <https://arxiv.org/abs/2008.05711>.
- [A.33] Li Z, Wang W, Xie E, et al. Panoptic segformer: Delving deeper into panoptic segmentation with transformers[EB/OL]. arXiv, 2022. <https://arxiv.org/abs/2109.03814>.
- [A.34] Li Z, Wang W, Li H, et al. BEVFormer: Learning bird's-eye-view representation from multi-camera images via spatiotemporal transformers[EB/OL]. arXiv, 2022. <https://arxiv.org/abs/2203.17270>.
- [A.35] Liao B, Chen S, Wang X, et al. MapTR: Structured modeling and learning for online vectorized HD map construction[EB/OL]. arXiv, 2023. <https://arxiv.org/abs/2208.14437>.
- [A.36] Wei Y, Zhao L, Zheng W, et al. Surroundocc: Multi-camera 3d occupancy prediction for autonomous driving[EB/OL]. arXiv, 2023. <https://arxiv.org/abs/2303.09551>.

- [A.37] Yadav H, Schaefer M, Zhao K, et al. CASPFormer: Trajectory prediction from BEV images with deformable attention[C/OL]//European Conference on Computer Vision (ECCV). 2024. DOI: 10.1007/978-3-031-78447-7_28.
- [A.38] Hu Y, Yang J, Chen L, et al. Goal-oriented autonomous driving[EB/OL]. arXiv(2022-12-20) [2023-05-26].
- [A.39] Jiang B, Chen S, Xu Q, et al. VAD: Vectorized scene representation for efficient autonomous driving[C/OL]//2023 IEEE/CVF International Conference on Computer Vision (ICCV). Paris, France: IEEE, 2023: 8306-8316. DOI: 10.1109/ICCV51070.2023.00766.
- [A.40] Guo M, Zhang Z, He Y, et al. End-to-end autonomous driving without costly modularization and 3d manual annotation[EB/OL]. 2024[2024-07-12]. <https://arxiv.org/abs/2212.10156>.
- [A.41] Sun W, Lin X, Shi Y, et al. Sparsedrive: End-to-end autonomous driving via sparse scene representation[EB/OL]. arXiv, 2024. <https://arxiv.org/abs/2405.19620>.
- [A.42] Chen S, Jiang B, Gao H, et al. VADv2: End-to-end vectorized autonomous driving via probabilistic planning[EB/OL]. arXiv, 2024. <https://arxiv.org/abs/2402.13243>.
- [A.43] Li Z, Yu Z, Lan S, et al. Is ego status all you need for open-loop end-to-end autonomous driving? [C/OL]//2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2024. DOI: 10.1109/CVPR52733.2024.01408.
- [A.44] Li Z, Li K, Wang S, et al. Hydra-MDP: End-to-end multimodal planning with multi-target hydra-distillation[EB/OL]. 2024.
- [A.45] Gao Z, Mu Y, Chen C, et al. Enhance sample efficiency and robustness of end-to-end urban autonomous driving via semantic masked world model[J/OL]. IEEE Transactions on Intelligent Transportation Systems, 2022. DOI: 10.1109/TITS.2024.3400227.
- [A.46] Ho J, Jain A, Abbeel P. Denoising diffusion probabilistic models[EB/OL]. arXiv, 2020. DOI: 10.48550/arXiv.2006.11239.
- [A.47] Song J, Meng C, Ermon S. Denoising diffusion implicit models[EB/OL]. arXiv, 2020. DOI: 10.48550/arXiv.2010.02502.
- [A.48] Song Y, Sohl-Dickstein J, Kingma D P, et al. Score-based generative modeling through stochastic differential equations[C]//International Conference on Learning Representations (ICLR). 2021.
- [A.49] Lu C, Zhou Y, Bao F, et al. DPM-Solver: A fast ODE solver for diffusion probabilistic model sampling in around 10 steps[EB/OL]. arXiv, 2022. <https://arxiv.org/abs/2206.00927>.
- [A.50] Zheng K, Lu C, Chen J, et al. DPM-Solver-v3: Improved diffusion ODE solver with empirical model statistics[EB/OL]. 2023.
- [A.51] Lu C, Zhou Y, Bao F, et al. DPM-Solver++: Fast solver for guided sampling of diffusion probabilistic models[J/OL]. Machine Intelligence Research, 2025, 22(4): 730-751. <http://dx.doi.org/10.1007/s11633-025-1562-4>.
- [A.52] Rombach R, Blattmann A, Lorenz D, et al. High-resolution image synthesis with latent diffusion models[EB/OL]. arXiv, 2021. DOI: 10.48550/arXiv.2112.10752.
- [A.53] Esser P, Rombach R, Ommer B. Taming transformers for high-resolution image synthesis [EB/OL]. arXiv, 2020. DOI: 10.48550/arXiv.2012.09841.

- [A.54] Zheng Y, Liang R, Zheng K, et al. Diffusion-based planning for autonomous driving with flexible guidance[EB/OL]. arXiv, 2025. <https://arxiv.org/abs/2501.15564>.
- [A.55] Lipman Y, Chen R T Q, Ben-Hamu H, et al. Flow matching for generative modeling[EB/OL]. arXiv, 2023. <https://arxiv.org/abs/2210.02747>.
- [A.56] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision[EB/OL]. arXiv, 2021. DOI: 10.48550/arXiv.2103.00020.
- [A.57] Ramesh A, Dhariwal P, Nichol A, et al. Hierarchical text-conditional image generation with CLIP latents[EB/OL]. arXiv, 2022. DOI: 10.48550/arXiv.2204.06125.
- [A.58] Zou J, Chen S, Liao B, et al. Diffusiondrive2: Reinforcement learning-constrained truncated diffusion modeling in end-to-end autonomous driving[EB/OL]. arXiv, 2025. <https://arxiv.org/abs/2512.07745>.
- [A.59] Xing Z, Zhang X, Hu Y, et al. Goalflow: Goal-driven flow matching for multimodal trajectories generation in end-to-end autonomous driving[EB/OL]. arXiv, 2025. <https://arxiv.org/abs/2503.05689>.
- [A.60] 万滢. 液罐车辆车—液耦合动力学特性与防侧翻控制方法研究[D]. 长春: 吉林大学, 2020.
- [A.61] Mnih V, Kavukcuoglu K, Silver D, et al. Playing atari with deep reinforcement learning[A/OL]. 2013. arXiv: 1312.5602. <https://arxiv.org/abs/1312.5602>.
- [A.62] Bellemare M G, Dabney W, Munos R. A distributional perspective on reinforcement learning [A/OL]. 2017. arXiv: 1707.06887. <https://arxiv.org/abs/1707.06887>.
- [A.63] Mnih V, Badia A P, Mirza M, et al. Asynchronous methods for deep reinforcement learning [A/OL]. 2016. arXiv: 1602.01783. <https://arxiv.org/abs/1602.01783>.
- [A.64] Schulman J, Levine S, Moritz P, et al. Trust region policy optimization[A/OL]. 2017. arXiv: 1502.05477. <https://arxiv.org/abs/1502.05477>.
- [A.65] Schulman J, Wolski F, Dhariwal P, et al. Proximal policy optimization algorithms[A/OL]. 2017. arXiv: 1707.06347. <https://arxiv.org/abs/1707.06347>.
- [A.66] Lillicrap T P, Hunt J J, Pritzel A, et al. Continuous control with deep reinforcement learning [A/OL]. 2019. arXiv: 1509.02971. <https://arxiv.org/abs/1509.02971>.
- [A.67] Fujimoto S, van Hoof H, Meger D. Addressing function approximation error in actor-critic methods[A/OL]. 2018. arXiv: 1802.09477. <https://arxiv.org/abs/1802.09477>.
- [A.68] Haarnoja T, Zhou A, Abbeel P, et al. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor[A/OL]. 2018. arXiv: 1801.01290. <https://arxiv.org/abs/1801.01290>.
- [A.69] Kuznetsov A, Shvechikov P, Grishin A, et al. Controlling overestimation bias with truncated mixture of continuous distributional quantile critics[A/OL]. 2020. arXiv: 2005.04269. <https://arxiv.org/abs/2005.04269>.
- [A.70] Andrychowicz M, Wolski F, Ray A, et al. Hindsight experience replay[A/OL]. 2018. arXiv: 1707.01495. <https://arxiv.org/abs/1707.01495>.
- [A.71] Plappert M, Andrychowicz M, Ray A, et al. Multi-goal reinforcement learning: Challenging robotics environments and request for research[A/OL]. 2018. arXiv: 1802.09464. <https://arxiv.org/abs/1802.09464>.

- [A.72] Mania H, Guy A, Recht B. Simple random search provides a competitive approach to reinforcement learning[A/OL]. 2018. arXiv: 1803.07055. <https://arxiv.org/abs/1803.07055>.
- [A.73] Hiraoka T, Imagawa T, Hashimoto T, et al. Dropout q-functions for doubly efficient reinforcement learning[C]//ICLR: International Conference on Learning Representations. Virtual Event, 2022.
- [A.74] Bhatt A, Palenicek D, et al. Batch normalization in deep reinforcement learning for greater sample efficiency and simplicity[C]//ICLR: International Conference on Learning Representations. 2024.
- [A.75] Lee H, Hwang D, Kim D, et al. Simba: Simplicity bias for scaling up parameters in deep reinforcement learning[C]//International Conference on Learning Representations. Virtual Event, 2025.
- [A.76] Cheng H, Jiang Y, Zhang H, et al. Emergency index (ei): A two-dimensional surrogate safety measure considering vehicles' interaction depth[J/OL]. Transportation Research Part C: Emerging Technologies, 2025, 174: 104289. DOI: 10.1016/j.trc.2025.104289.
- [A.77] Chen K, Cheng H, Jiang Y, et al. MEI: A motion-enhanced emergency index for surrogate safety assessment in complex interactions[C]//2025 IEEE 28th International Conference on Intelligent Transportation Systems (ITSC). 2025: 1-8.
- [A.78] 唐泽月, 刘海鸥, 薛明轩, 等. 基于 MPC-MFAC 的双侧独立电驱动无人履带车辆轨迹跟踪控制[J/OL]. 兵工学报, 2023, 44(1): 129-139. DOI: 10.12382/bgxb.2022.0886.
- [A.79] Hou Z, Jin S. Data-driven model-free adaptive control for a class of MIMO nonlinear discrete-time systems[J/OL]. IEEE Transactions on Neural Networks, 2011, 22(12): 2173-2187. DOI: 10.1109/TNN.2011.2176141.

致 谢

衷心感谢导师 ××× 教授和物理系 ×× 副教授对本人的精心指导。他们的言传身教将使我终生受益。

在美国麻省理工学院化学系进行九个月的合作研究期间，承蒙 Robert Field 教授热心指导与帮助，不胜感激。

感谢 ××××× 实验室主任 ××× 教授，以及实验室全体老师和同窗们学的热情帮助和支持！

本课题承蒙国家自然科学基金资助，特此致谢。

声 明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的成果。尽我所知，除文中已经注明引用的内容外，本学位论文的研究成果不包含任何他人享有著作权的内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明。

签 名：_____ 日 期：_____

个人简历、在学期间完成的相关学术成果

个人简历

2000 年 12 月 1 日出生于山东省威海市.

2019 年 9 月考入吉林大学汽车工程学院工业设计专业,2023 年 7 月本科毕业并获得工学学士学位.

2023 年 9 月免试进入清华大学车辆与运载学院攻读工学硕士至今.

在学期间完成的相关学术成果

学术论文:

- [1] **Qi X**, Luo Y G, Gao B L, Zhong W. Anti-rollover Path Tracking Control for an Autonomous Semi-trailer Tank Truck[J]. IEEE Transactions on Intelligent Transportation System, 2025, 26(7):9932-9947.DOI:10.1109/TITS.2025.3563475.
- [2] **戚笑景**, 肖雅月, 钟薇, 高博麟, 王勇, 孙棣华, 李克强. 智能网联汽车信息物理系统分场景 MBSOSE 建模方法 [J]. 机械工程学报, 2026, 62(07):1-25.DOI:10.3901/JME.260143.
- [3] **Qi X**, Zhang Y C, Gao B L. Observing Liquid Sloshing Based on a Multi-Degree-of-Freedom Pendulum Model and Free Surface Fluctuation Sensor[J]. Sensors (Basel). 2023 Oct 30;23(21):8831.
- [4] 卢彦博, 肖壮锐, 钟薇, 高博麟, 殷国栋, 王彤, **戚笑景**. 车路云一体化城市预测性巡航系统架构设计研究 [J]. 机械工程学报, 2026.(in press 已被机械工程学报录用).

专利:

- [5] 高博麟, **戚笑景**, 刘彦斌, 等. 液罐车罐内液体晃动的建模方法、装置、电子设备及其介质: 中国, CN117422009A[P]. 2024-01-19.
- [6] 高博麟, **戚笑景**. 自由液面波动传感器及液罐车: 中国, CN117451142A [P]. 2024-01-26.
- [7] 高博麟, **戚笑景**. 一种计算液罐车车液耦合动力学的联合仿真方法: 中国, CN116842860A [P]. 2023-10-03.
- [8] 高博麟, **戚笑景**. 液罐车防侧翻控制方法、装置、云端、液罐车及控制系统: 中国, CN117601746A [P]. 2023-09-25.
- [9] 高博麟, **戚笑景**. 用于复杂信息物理系统设计的 RFL (C&P) 方法: 中

国,CN117908844A [P]. 2023-12-20.

- [10] 高博麟, 戚笑景. 液罐车防侧翻控制方法、装置、云端、液罐车及控制系统: PCT 美国,WO2025065992A1 [P]. 2024-01-26.
- [11] 高博麟, 戚笑景. 信息物理孪生概率化周车交互式预测模型识别方法: 中国,CN119940685A [P]. 2024-11-22.
- [12] 高博麟, 戚笑景, 钟薇, 卢彦博. 基于车云协同的行驶轨迹规划方法及装置: 中国,CN119590445A [P]. 2024-10-29.
- [13] 钟薇, 戚笑景, 肖雅月, 高博麟, 王勇, 何雷, 等. 一种基于体系工程的智能网联汽车信息物理系统架构设计方法: 中国,CN120110928A [P]. 2025-01-22.
- [14] 高博麟, 刘家熙, 周光, 卢彦博, 戚笑景, 熊宣威. 动态数据溯源方法、装置、电子设备及存储介质: 中国,CN202410395637.9 [P]. 2024-04-02.
- [15] 高博麟, 戚笑景, 钟薇, 卢彦博. 一种液罐车罐内液体晃动高精度建模方法: 中国,[P]. (专利申请号).
- [16] 高博麟, 戚笑景, 徐熙标, 王怡然, 钟薇. 多轴转向重载车辆封闭环境轨迹规划与跟踪控制方法、系统: 中国,[P]. (专利申请号).
- [17] 钟薇, 戚笑景, 何瑞坤, 肖壮锐, 高博麟. 液罐车横纵向耦合自适应防侧翻轨迹跟踪控制方法、系统: 中国,[P]. (专利申请号).

参与项目:

- [18] 科技部国家重点研发计划“智能汽车信息物理系统关键技术研究”, 项目编号:2021YFB2501000, 起止时间: 2023.3-2026.1
- [19] 科技部国家重点研发计划“机场室内外全场景自动装卸与智能运输装备研制”, 项目编号: 2023YFB4301800, 起止时间: 2025.6-至今
- [20] 清华-东风合作项目“商用车整车控制技术开发”, 起止时间: 2025.6-至今
- [21] 国家自然科学基金面上项目“极限工况下半挂式载重车辆罐液耦合机制与行驶安全控制研究”, 起止时间: 2025.6-至今
- [22] 国重实验室自主课题“车云协同半挂式智能液罐车防侧翻轨迹规划与稳定控制研究”, 起止时间: 2023.3-2026.1

获得的奖励:

- [23] 清华大学硕士生国家奖学金, 2025.10
- [24] 首届 HitchOpen 世界 AI 竞速锦标赛全国总冠军, 2025.10
- [25] 第三届 Onsite 自动驾驶挑战赛第六赛道大件运输全国冠军, 2025.5
- [26] 首届车路云一体化挑战赛二等奖, 2024.10
- [27] 清华大学车辆学院研究生学术论坛口头报告二等奖, 2024.10

指导教师评语

论文提出了……

答辩委员会决议书

论文提出了……

论文取得的主要创新性成果包括：

1. ……

2. ……

3. ……

论文工作表明作者在 ××××× 具有 ××××× 知识，具有 ×××× 能力，论文 ××××，
答辩 ××××。

答辩委员会表决，（× 票/一致）同意通过论文答辩，并建议授予 ×××（姓名）
×××（门类）学博士/硕士学位。